Avaliação de estratégias de treinamento com YOLOv8 para detecção de defeitos pequenos em cartas Pokémon TCG com baixo volume de dados

Matheus da Silva Marini
Orientador: Prof. Afonso César Lelis Brandão
Ciência da Computação, SENAC Santo Amaro, 2026

SUMÁRIO

Ordem da apresentação

1

Introdução

2

Revisão bibliográfica

3

Desenvolvimento e resultados

4

Conclusão

INTRODUÇÃO

Contextualização do problema

75 bi

de dólares é a projeção do mercado de cartas colecionáveis para 2034

4

critérios físicos definem a nota da carta

Manual

a avaliação exige atenção cuidadosa e pode ser demorada

A IDEIA

Localizar os defeitos na imagem, para indicar em que pontos da carta concentrar a inspeção

INTRODUÇÃO

Formulação do problema

Poucos dados

A rede se ajusta aos exemplos de treino e erra em imagens novas: é o sobreajuste

Defeitos pequenos

Cada ponto do mapa da rede resume um bloco de pixels: um defeito menor que o bloco fica diluído no fundo

Pergunta: com baixo volume de dados anotados, quais estratégias de treinamento melhoram a detecção de defeitos em cartas Pokémon?

INTRODUÇÃO

Objetivos

OBJETIVO GERAL

Avaliar estratégias de treinamento aplicadas ao YOLOv8 para detecção de defeitos pequenos em cartas Pokémon TCG com baixo volume de dados

OBJETIVOS ESPECÍFICOS

Preparar o conjunto de dados com classe única

Comparar quatro configurações de aumento de dados e entrada

Avaliar a cabeça P2 e a resolução na melhor configuração

Medir com precisão, revocação, F1 e mAP@0,5

Avaliar a curva de aprendizado

Analisar o que funciona com poucos dados

INTRODUÇÃO

Hipóteses

H1

O aumento de dados melhora o detector

H2

O realce de micro-relevo melhora o detector

H3

A combinação dos dois é a melhor

H4

A cabeça P2 encontra mais defeitos menores que 8 pixels

INTRODUÇÃO

Justificativa

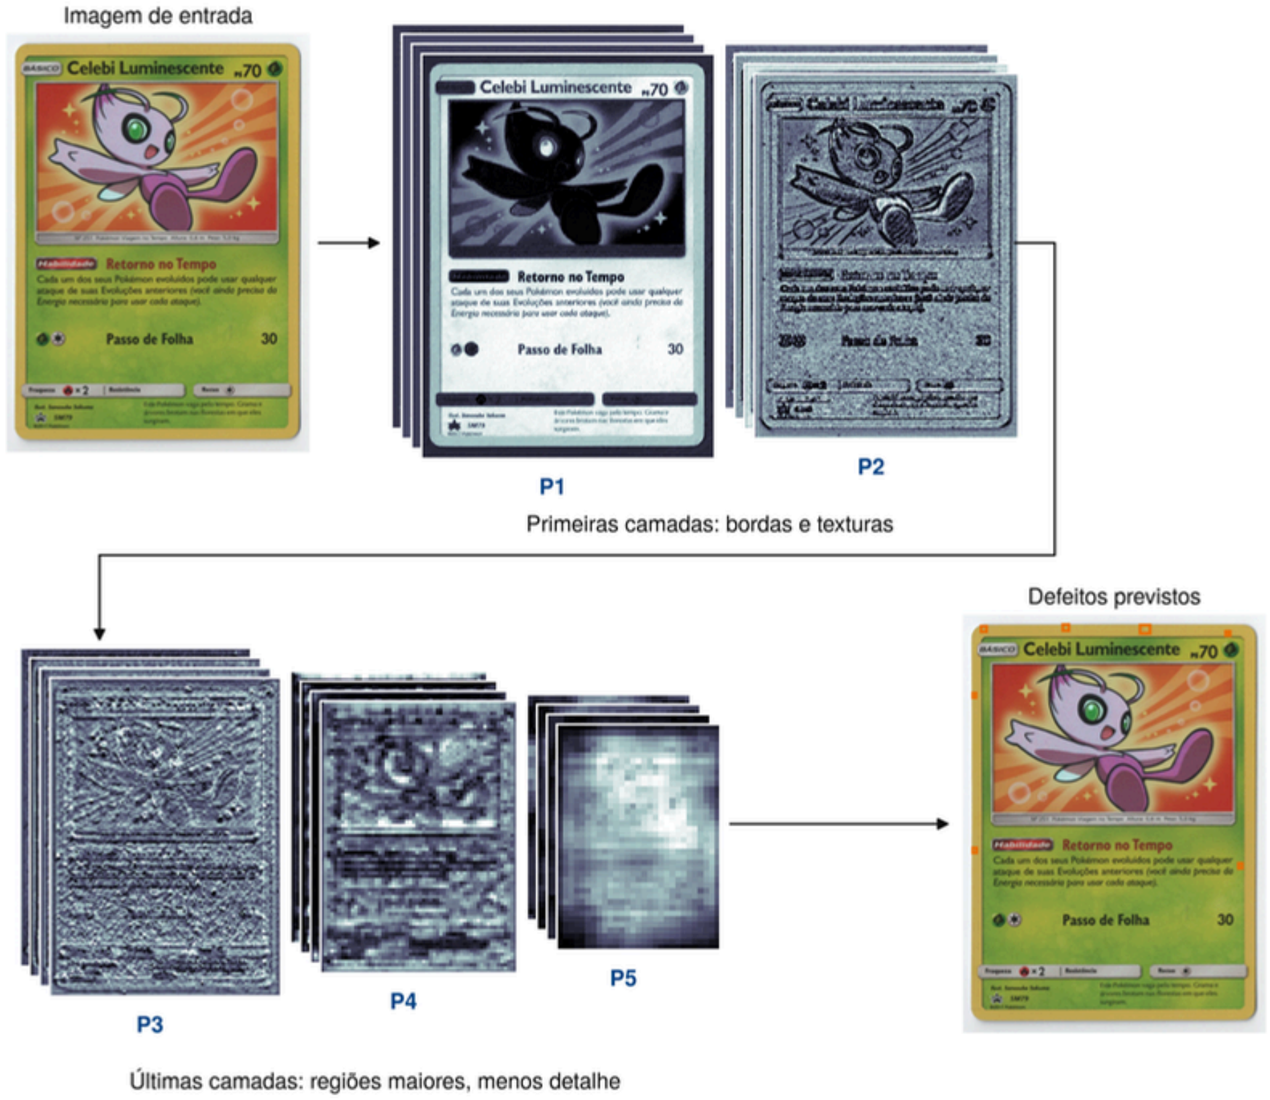
Científica

Faltava avaliar de forma sistemática as estratégias de treinamento na detecção localizada, com baixo volume de dados, em cartas colecionáveis.

Prática

Indica quais estratégias priorizar com poucos dados. Um resultado negativo também orienta quem vier depois.

Redes neurais convolucionais



Fonte: Elaborado pelo autor (2026).

Mapas

Cada pilha reúne mapas de uma mesma etapa, e cada mapa reage a um padrão

Etapas

Do início ao fim, a rede passa de bordas e texturas para regiões maiores

Consequência

A imagem encolhe a cada etapa, e o detalhe de um defeito pequeno se perde

Critérios de avaliação



Critérios de avaliação no processo de graduação de cartas TCG

Fonte: Elaborado pelo autor (2026).

Bordas

Desgaste, whitening, lascas e marcas ao longo das laterais

Cantos

Desgaste, arredondamento, dobras e amassados nas pontas

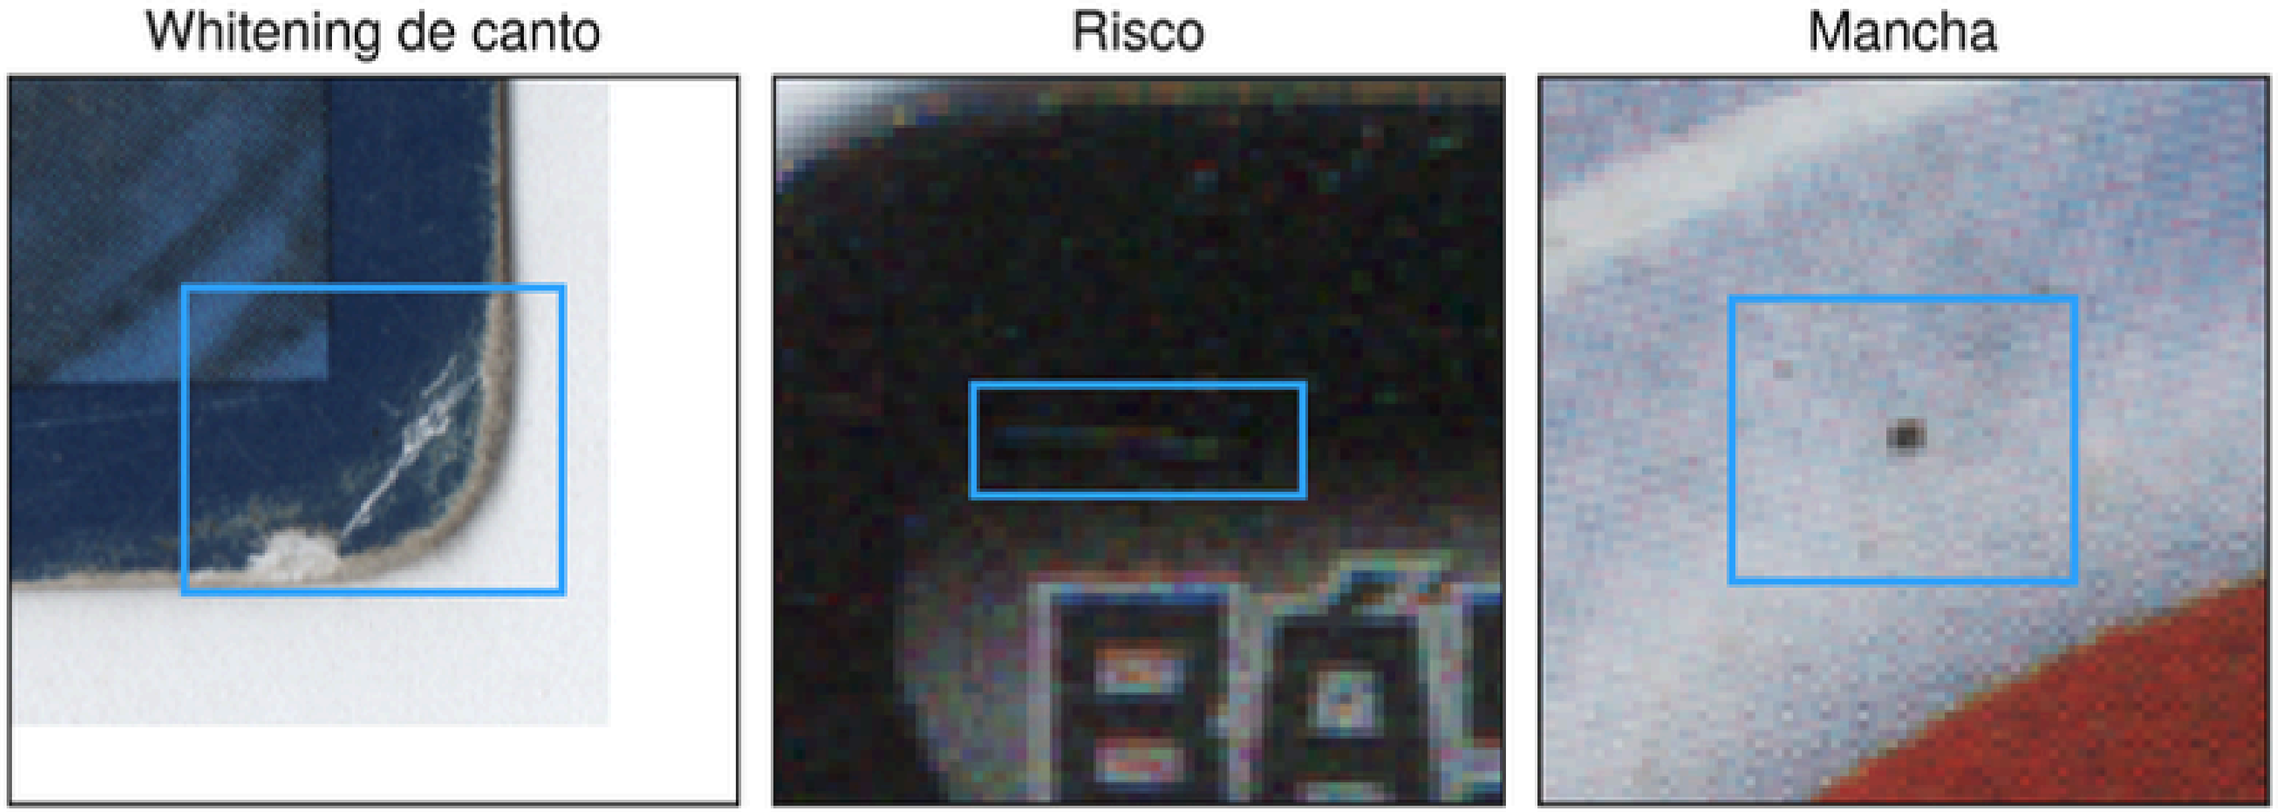
Superfície

Riscos, manchas, perda de brilho e arranhões na área plana

Centralização

Alinhamento da impressão em relação às margens; fica fora da detecção

Defeitos em cartas colecionáveis



Fonte: Elaborado pelo autor (2026).

Riscos, whitening e manchas ocupam poucos pixels da imagem

Classificação e detecção de objetos

Classificador

Atribui um rótulo à imagem inteira ou a um recorte dela. Em um canto da carta, dá uma nota para aquela região, sem indicar a posição nem a extensão.

Detector de objetos

Identifica vários objetos em posições diferentes. Para cada um, retorna a caixa delimitadora, a classe e um escore de confiança.

Neste trabalho: detecção com uma única classe, defeito. O modelo localiza cada defeito, mas não distingue o tipo nem a gravidade.

Métricas de avaliação

Precisão

$$\frac{TP}{TP + FP}$$

Das detecções realizadas, qual proporção corresponde a defeitos reais?

Revocação

$$\frac{TP}{TP + FN}$$

Dos defeitos reais existentes, qual proporção foi detectada?

F1 Score

$$2 \cdot \frac{\text{Precisão} \times \text{Revocação}}{\text{Precisão} + \text{Revocação}}$$

Média harmônica entre precisão e revocação

mAP@0,5

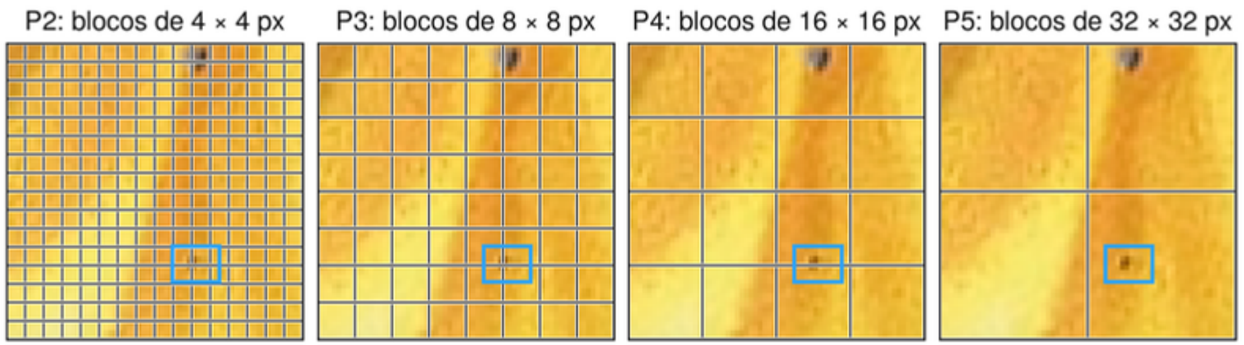
$$\frac{1}{N} \sum_{i=1}^{N} AP_i$$

Precisão média. Conta como acerto com IoU, a sobreposição das caixas, de pelo menos 0,5

TP (verdadeiro positivo): detecção correta de um defeito
FP (falso positivo): detecção sem defeito anotado
FN (falso negativo): defeito anotado não encontrado

AP (precisão média): área sob a curva de precisão e revocação
N: número de classes; neste trabalho, 1

Arquitetura YOLO: níveis P1 a P5



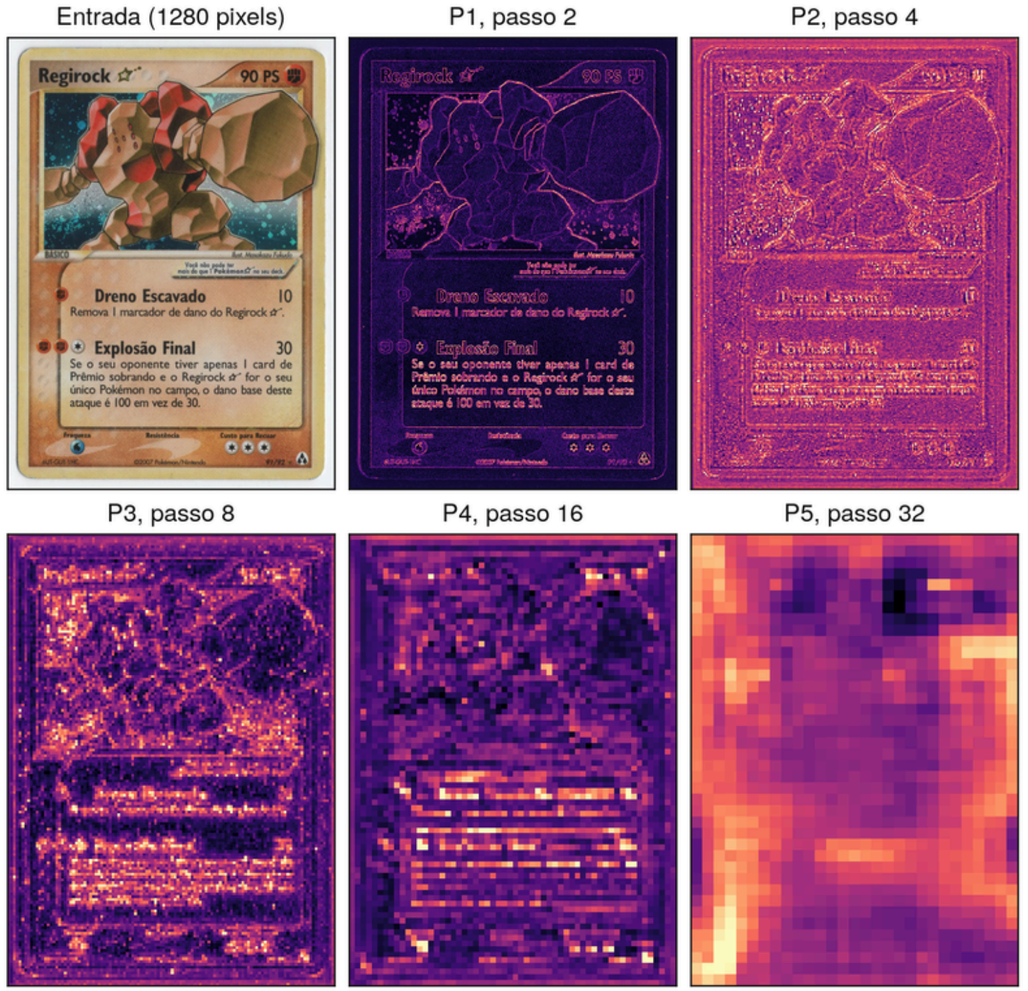
Fonte: Elaborado pelo autor (2026).

YOLOv8 padrão

Faz predições a partir de P3, P4 e P5, e o menor passo é de 8 pixels

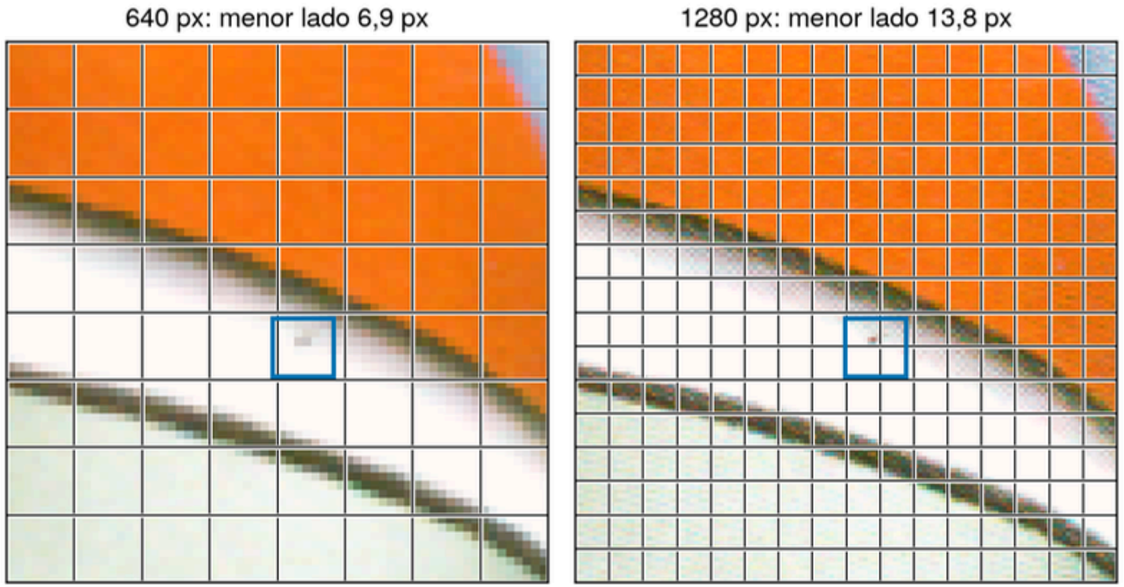
Cabeça P2

Acrescenta uma saída de passo 4, voltada a defeitos pequenos

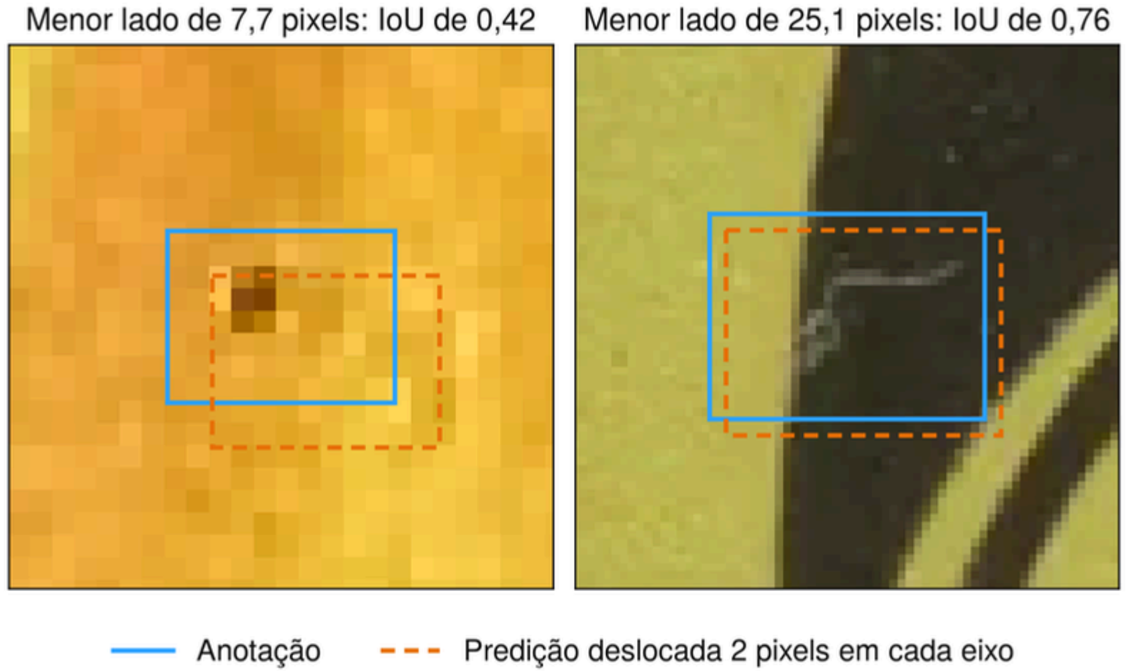


Fonte: Elaborado pelo autor (2026).

Detecção de objetos pequenos e IoU



Fonte: Elaborado pelo autor (2026).



Fonte: Elaborado pelo autor (2026).

0,5 foi o IoU mínimo para contar uma detecção como acerto

REVISÃO BIBLIOGRÁFICA

Trabalhos correlatos

Nahar et al. (2025a)

Classificam cantos de cartas esportivas

Chen et al. (2024)

Melhoram o YOLOv8 em defeitos de superfície

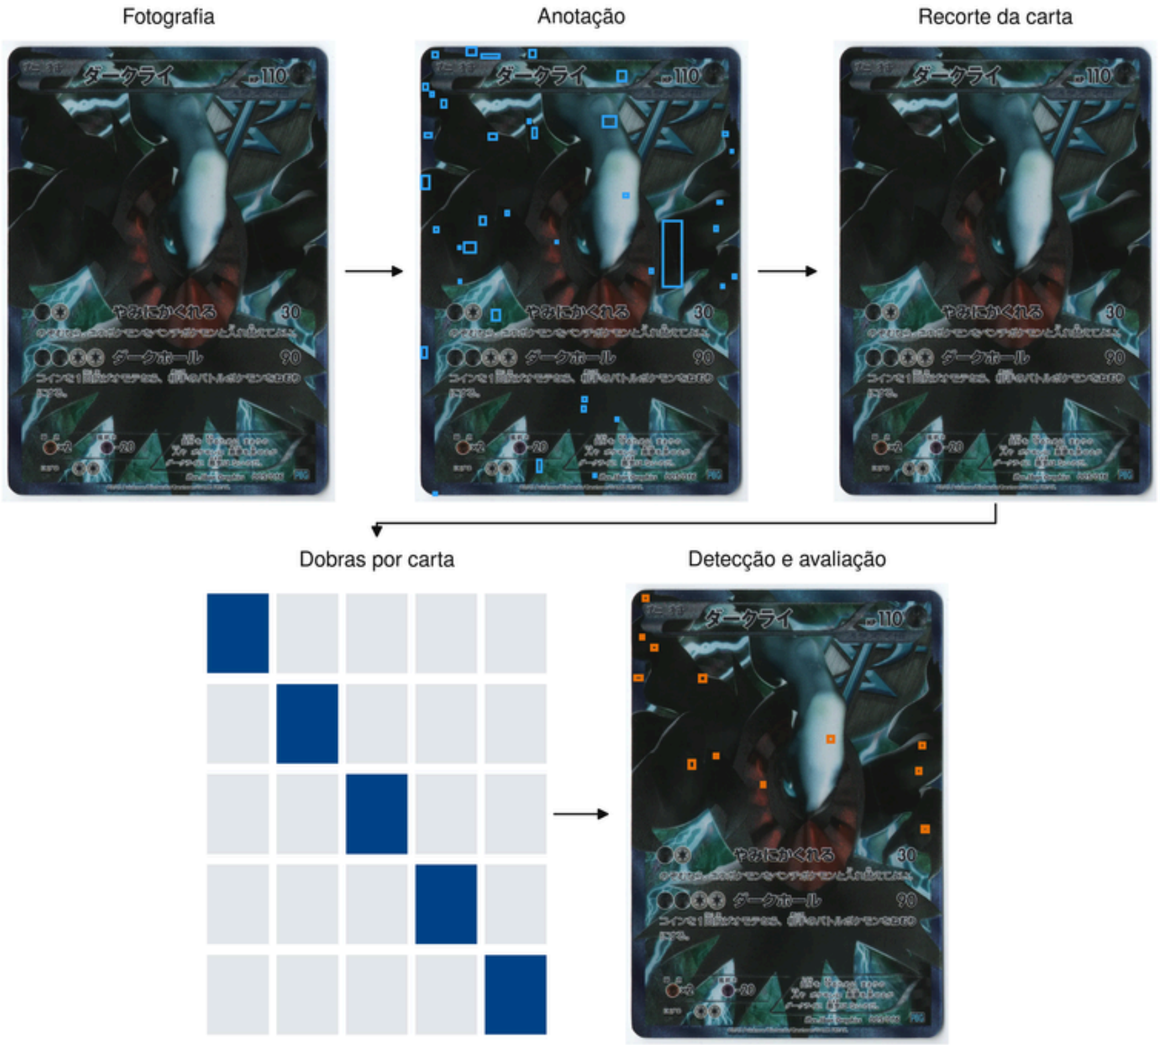
Liu e Juang (2026)

Comparam resolução e cabeça P2 em imagens de drone

Este trabalho: detecção em cartas Pokémon, estudo fatorial e teste pareado por carta

DESENVOLVIMENTO

Visão geral do trabalho



Fonte: Elaborado pelo autor (2026).

DESENVOLVIMENTO

Conjunto de dados

206

cartas

412

imagens

4.808

defeitos anotados

517

menores que 8 pixels a 1280

Um único anotador. Mediana de 6 anotações por imagem, com máximo de 174. Desgaste difuso sem caixa própria em 15 imagens de 9 cartas.

DESENVOLVIMENTO

Revisão da anotação

892

sugestões aceitas, 18,6% das 4.808 caixas

414

sugestões rejeitadas

963

caixas novas traçadas à mão na mesma revisão

Os modelos usavam RGB com aumento de dados, o que pode favorecer essas configurações. Por isso, o estudo fatorial e a cabeça P2 foram avaliados com e sem essas caixas.

Como se chegou à anotação completa

3.109 − 156 + 892 + 963 = 4.808

primeira etapa, menos as removidas, mais as sugeridas aceitas, mais as novas

DESENVOLVIMENTO

Resolução de entrada

A 640, mais da metade dos defeitos fica menor que o bloco de 8 pixels. A 1280 há detalhe real: o lado maior da imagem supera 1280 em 407 das 412 imagens.

57,6% → 10,8%

das caixas abaixo de 8 pixels, de 640 para 1280

7,25 → 14,51

pixels na mediana do menor lado da caixa

2,1 → 7,1 GB

de memória, e o tempo por época de 7,7 para 27,7 segundos

Validação cruzada

Iteração	Dobra 1	Dobra 2	Dobra 3	Dobra 4	Dobra 5	Treino efetivo	Validação interna
1	Avaliação 39 cartas	Treino	Treino	Treino	Treino	133 cartas	34 cartas
2	Treino	Avaliação 39 cartas	Treino	Treino	Treino	134 cartas	33 cartas
3	Treino	Treino	Avaliação 38 cartas	Treino	Treino	134 cartas	34 cartas
4	Treino	Treino	Treino	Avaliação 45 cartas	Treino	129 cartas	32 cartas
5	Treino	Treino	Treino	Treino	Avaliação 45 cartas	129 cartas	32 cartas

Treino efetivo: 129 a 134 cartas por iteração, usadas para ajustar os pesos
Validação interna: 32 a 34 cartas por iteração, sorteadas das quatro dobras de treino
Avaliação: a dobra da iteração, com 38 a 45 cartas, avaliada uma única vez

Frente e verso de cada carta, e cartas de mesma ilustração, ficaram sempre na mesma dobra.

Fonte: Elaborado pelo autor (2026).

DESENVOLVIMENTO

Testes estatísticos

F1 por carta

Um valor por carta, e não um só para a dobra inteira

Wilcoxon

Cada carta vira um par: o teste verifica se as diferenças pendem para um lado

Correção de Holm

Ajusta o valor-p das cinco comparações, para reduzir o risco de achar efeito por acaso

Diferença significativa: valor-p ajustado abaixo de 0,05, nível definido antes do treinamento

Cinco comparações: 2 e 1; 4 e 3; 3 e 1; 4 e 2; 2 com e sem P2

DESENVOLVIMENTO

Configurações do estudo fatorial

Configuração 1

RGB, sem aumento de dados

Configuração 2

RGB, com aumento de dados

Configuração 3

Realce, sem aumento de dados

Configuração 4

Realce, com aumento de dados

Com aumento de dados

Rotação de até 10 graus, translação, espelhamento e, nas imagens RGB, variação de cor

Sem mosaico e sem escala

O mosaico pode cortar defeitos e reúne partes de quatro cartas; reduzir a escala encolhe defeitos já pequenos

Realce de micro-relevo



3 canais

Luminosidade, **luminosidade com CLAHE** e **medida de Frangi**. As cores da figura são só de exibição.

Fonte: Elaborado pelo autor (2026).

RESULTADOS

Desempenho das configurações

Estudo fatorial: F1 por carta médio, 5 dobras, anotação completa

	Sem aumento de dados	Com aumento de dados
RGB	0,332 — Configuração 1	0,376 — Configuração 2: a melhor
Realce	0,294 — Configuração 3	0,354 — Configuração 4

A partir da Configuração 2: o que mudou

Cabeça P2	5 dobras: F1 caiu de 0,376 para 0,339	piorou
Resolução de 640 pixels	Dobra 5: F1 caiu de 0,399 para 0,266	piorou
YOLOv8m	Dobra 5: F1 de 0,431 contra 0,399, sem significância	inconclusivo
Mais cartas de treino	Dobras 3 e 5: de 50% para 100% das cartas, mAP@0,5 +0,044 e +0,051	melhorou

Fonte: Elaborado pelo autor (2026).

RESULTADOS

Efeito das caixas sugeridas

Anotação completa

0,376 × 0,354

F1 por carta: a Configuração 2 superou a 4 (p = 0,002)

Sem as caixas sugeridas

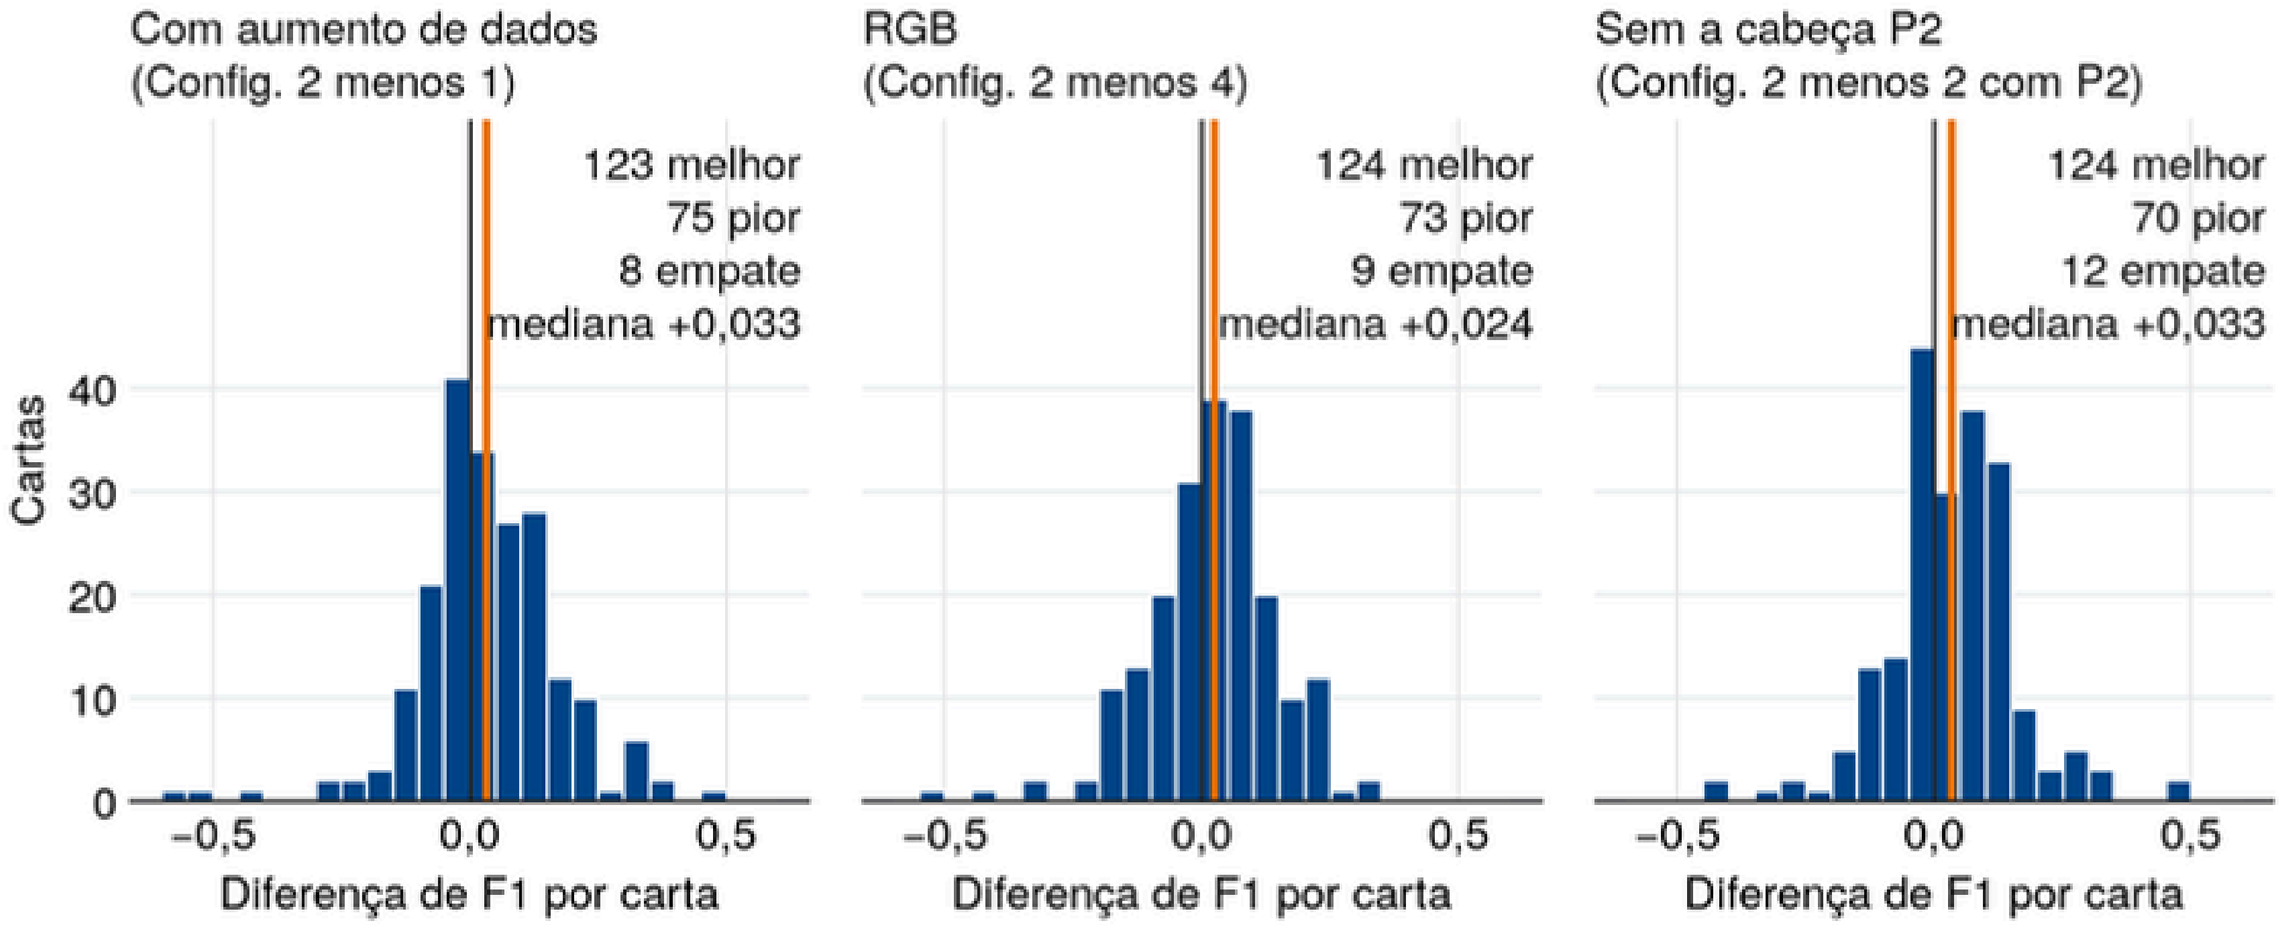
0,304 × 0,306

F1 por carta: sem diferença significativa (p = 0,59)

No mAP@0,5, a ordem foi a mesma nas duas: Configuração 2 com 0,247 e 0,173, e Configuração 4 com 0,202 e 0,149.

RESULTADOS

Comparações pareadas

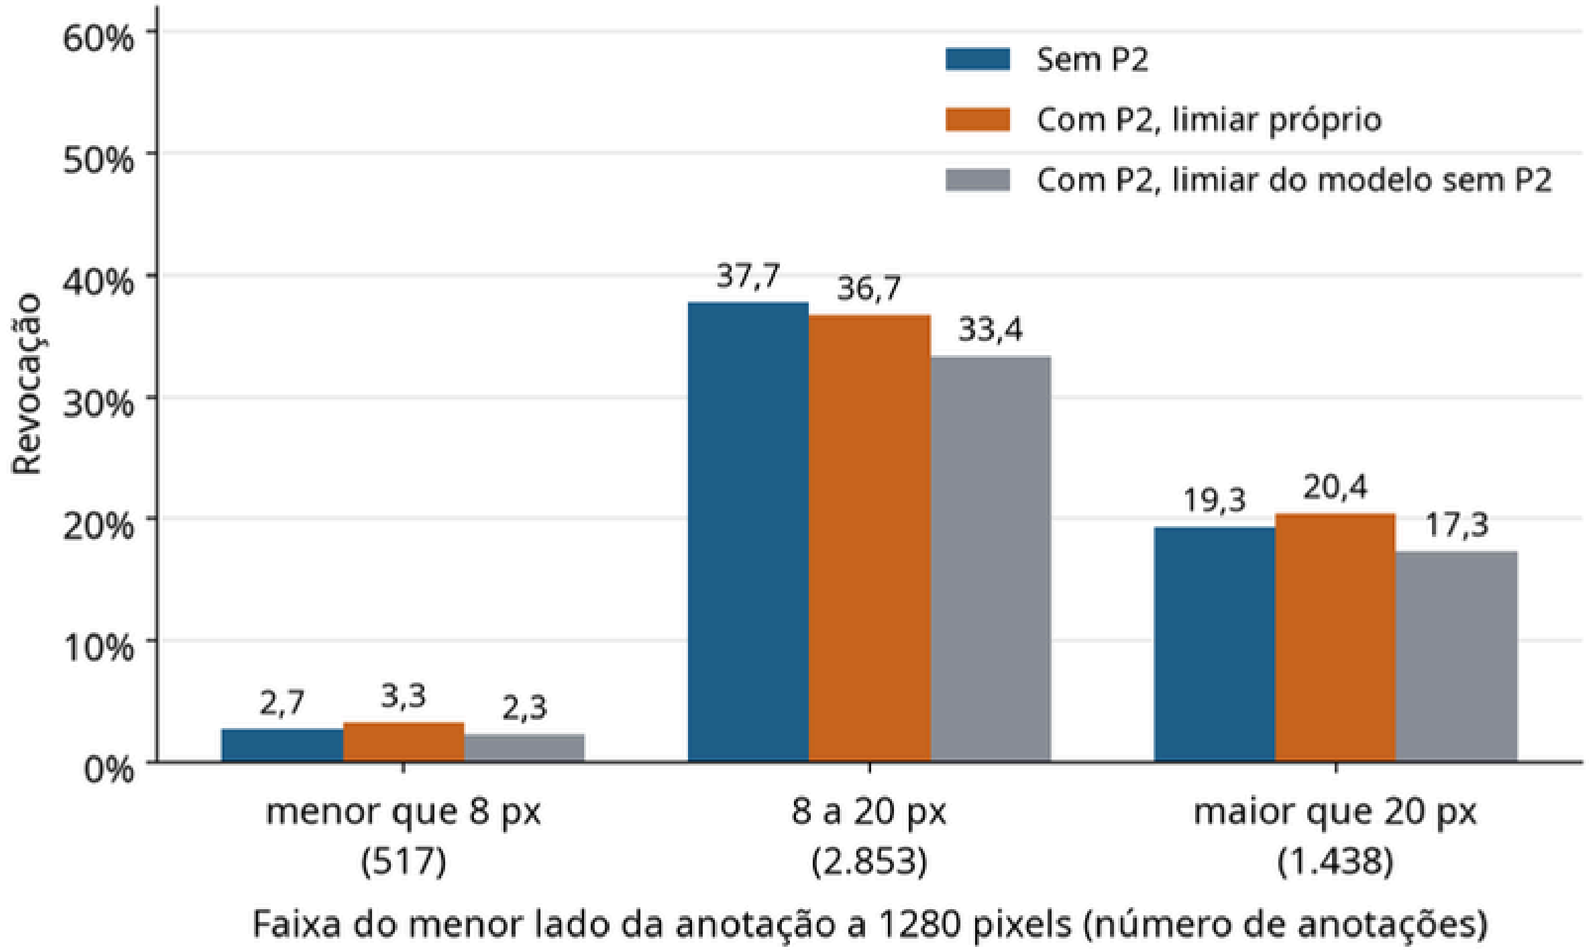


Fonte: Elaborado pelo autor (2026).

Wilcoxon pareado com correção de Holm, 206 cartas: $p < 0{,}001$, $p = 0{,}002$ e $p < 0{,}001$

RESULTADOS

Cabeça P2



14 → 17

defeitos encontrados de 517. Com o mesmo limiar, o ganho não se manteve.

Fonte: Elaborado pelo autor (2026).

RESULTADOS

Resolução e capacidade do modelo

640 pixels

0,266

de F1 por carta e mAP@0,5 de 0,161

1280 pixels

0,399

de F1 por carta e mAP@0,5 de 0,313

YOLOv8m a 1280

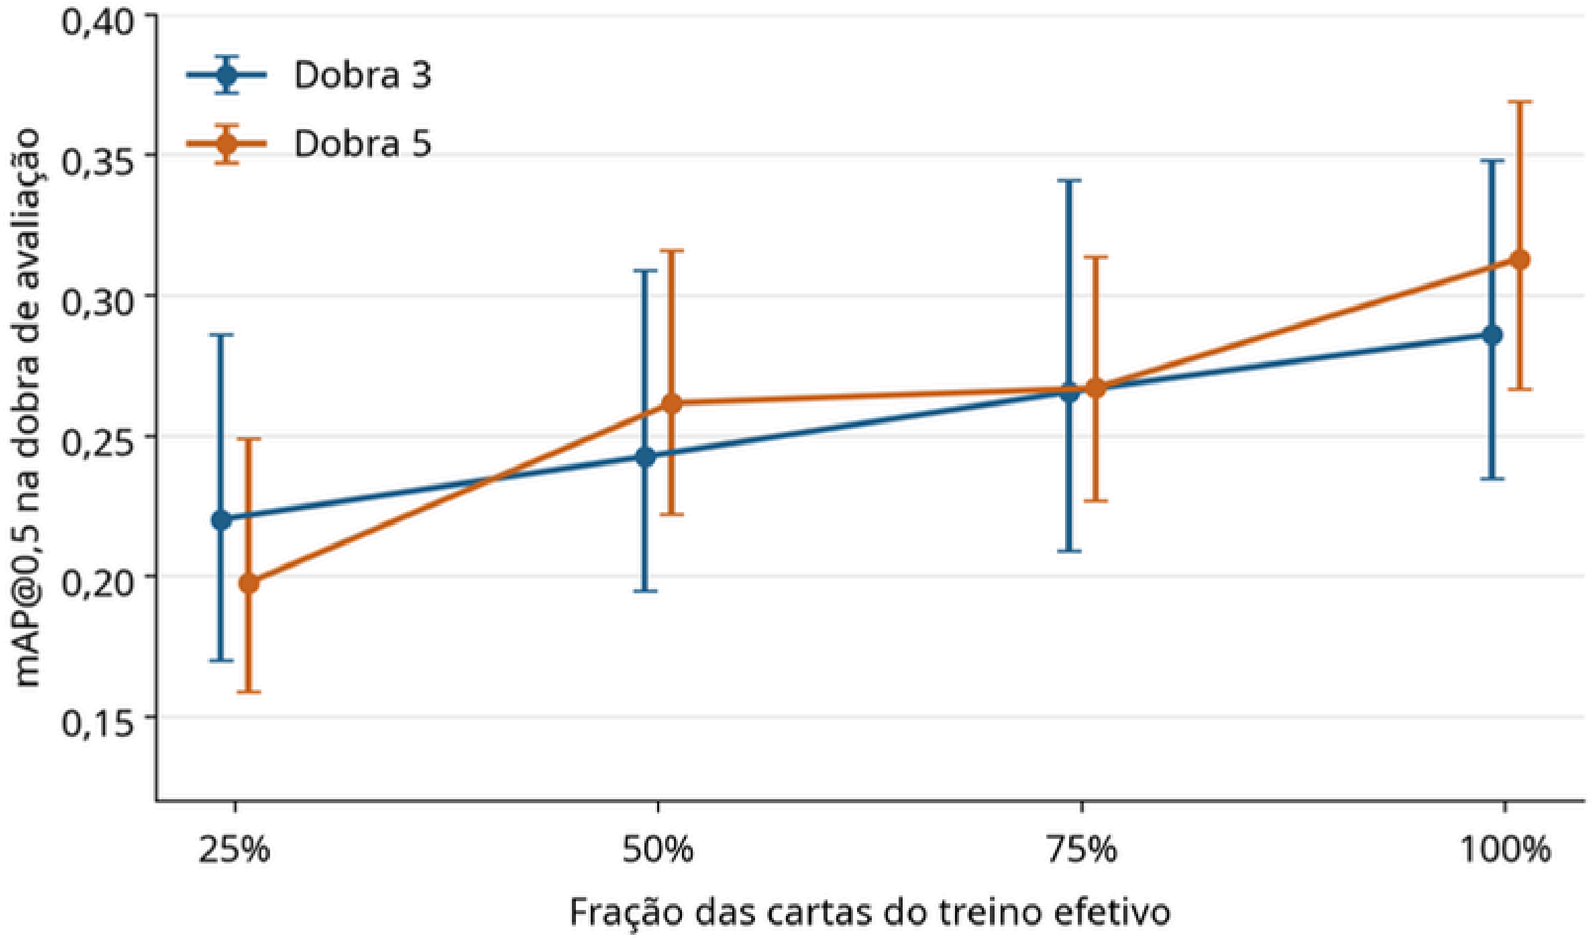
0,431

de F1 e mAP@0,5 de 0,308; p = 0,25, inconclusivo

É um indício em uma única dobra, escolhida depois do estudo fatorial, a confirmar nas demais.

RESULTADOS

Curva de aprendizado



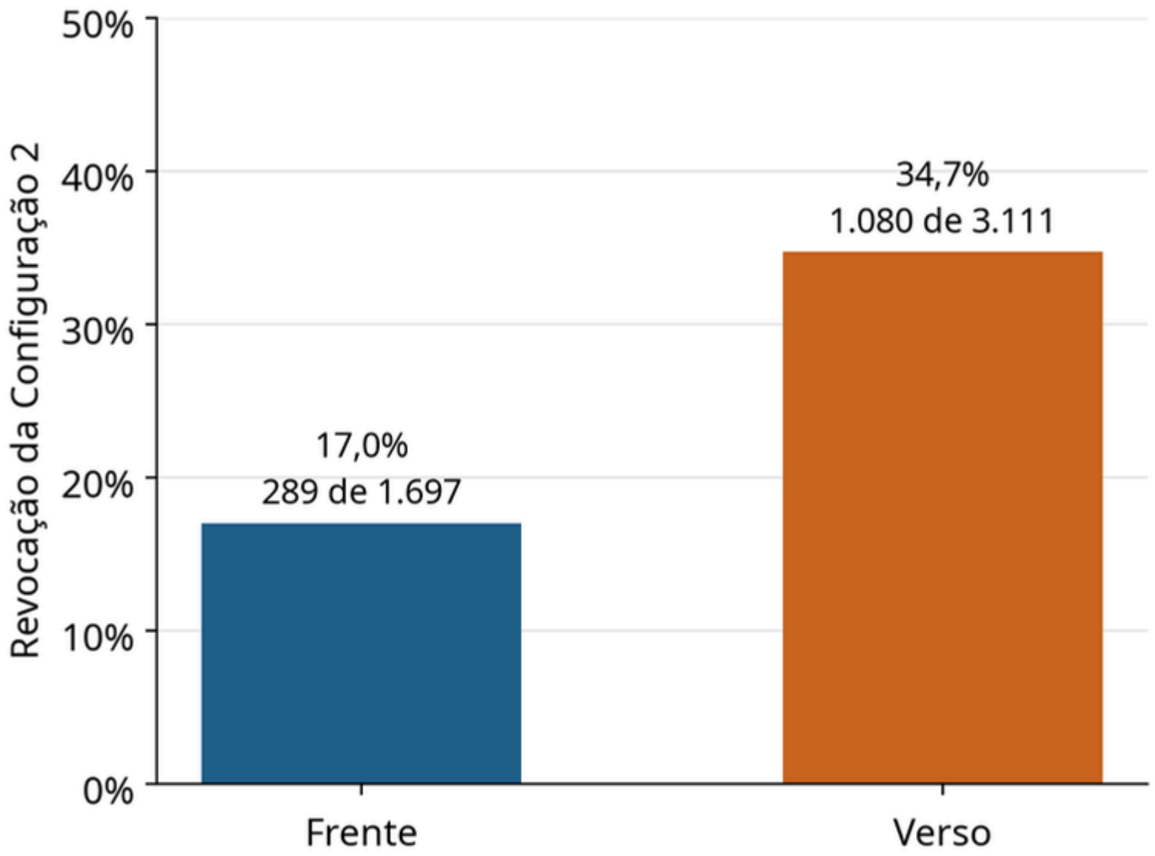
+0,044 e +0,051

de mAP@0,5, de 50% para 100% das cartas, nas Dobras 3 e 5

Fonte: Elaborado pelo autor (2026).

RESULTADOS

Frente e verso



Fonte: Elaborado pelo autor (2026).

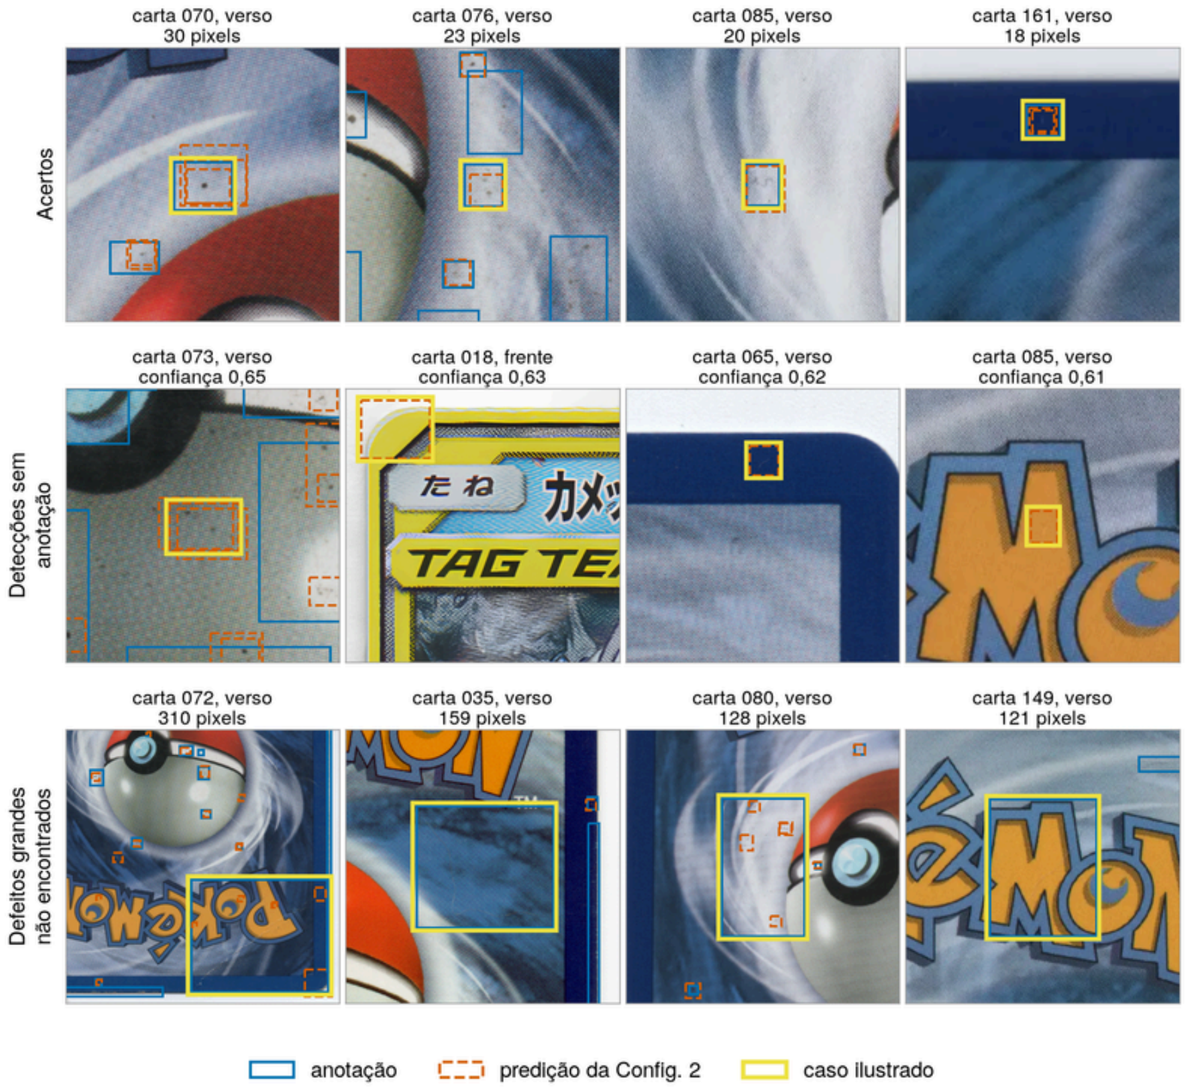
0,170 × 0,347

de revocação na frente e no verso

Sem as nove cartas com desgaste difuso, a revocação geral vai de 0,285 para 0,327

RESULTADOS

Exemplos de acertos e erros



Fonte: Elaborado pelo autor (2026).

Acertos

A predição coincidiu com a caixa anotada

Detecções sem anotação

Podem ser erro do modelo ou defeito não anotado

Não encontrados

Defeitos grandes que o modelo não localizou

Exemplos ilustrativos

Sem indicar padrão de erro. Os falsos positivos não foram caracterizados

RESULTADOS

Resultado das hipóteses

H1 — Aumento de dados — **Confirmada**

Melhorou nas duas representações: 0,376 × 0,332 e 0,354 × 0,294

H2 — Realce de micro-relevo — **Refutada**

Abaixo do RGB; sem as caixas sugeridas, refutada só na comparação sem aumento de dados

H3 — Combinação dos dois — **Não confirmada**

Refutada com a anotação completa; sem as caixas sugeridas, sem diferença significativa

H4 — Cabeça P2 — **Passou no critério, ganho não se manteve**

17 × 14 com o limiar de cada modelo; com o mesmo limiar, a vantagem sumiu

RESULTADOS

Discussão: tamanho dos defeitos

0,285

de revocação da Configuração 2

15%

dos defeitos perdidos têm menos de 8 pixels

0,39

seria a revocação achando todos eles

Mesmo assim, abaixo de 8 pixels, no máximo 26 de 517 foram encontrados, e com aumento de dados foram 14 contra 26 no RGB, em análise exploratória.

Causas possíveis, não testadas: volume de dados, rigidez do IoU, anotador único, desgaste difuso e reflexo.

CONCLUSÃO

Conclusão

Estudo fatorial

Comparação carta a carta em cartas colecionáveis, com poucos dados

Dois negativos

Realce e cabeça P2 não trouxeram ganho nestas condições

Repositório público

Scripts e resultados em repositório público

O detector ainda não é suficiente para a graduação automática.

CONCLUSÃO

Limitações e trabalhos futuros

Limitações

Um único anotador

Um treinamento por dobra

Resolução e YOLOv8m em uma dobra

Realce sem controle da cor

P2 sem pré-treino completo

Próximos passos

Recortes sobrepostos da imagem

Mais cartas e curva nas demais dobras

Segundo anotador

Captura com controle de reflexo

Obrigado pela atenção

APOIO

De onde vieram as imagens?

206

cartas de uma empresa brasileira de graduação

412

fotografias, frente e verso, feitas pela própria empresa

16

cartas com fundo vermelho; as demais, fundo branco

Sem controle deste trabalho sobre iluminação ou equipamento. A frente de todas as cartas é holográfica.

APOIO

Por que 4.808 caixas ainda são pouco dado?

129 a 134

cartas no treino efetivo de cada rodada

13

caixas na mediana por carta

+0,05

de mAP@0,5 de 50% para 100% das cartas

O que conta é o número de cartas, porque caixas da mesma carta não são independentes. A curva ainda subia.

APOIO

Cinco cartas têm de 215 a 270 caixas

2,4%

das cartas: 5 de 206

215 a 270

caixas por carta nessas cinco

13

caixas na mediana por carta

Ficaram nas Dobras 1 e 4. As Dobras 3 e 5, usadas nas análises complementares, não as contêm.

APOIO

Por que a entrada ficou em 1280 pixels?

10,8%

das caixas abaixo de 8 pixels, contra 57,6% a 640

7,1 GB

de memória, contra 2,1 GB a 640

27,7 s

por época, contra 7,7 s a 640

O lado maior médio das imagens recortadas foi de cerca de 1.827 pixels. Foram comparados 640 e 1280.

APOIO

Por que falar em apoio com precisão de 0,413?

0,413

de precisão da Configuração 2

0,285

de revocação da Configuração 2

200 de 206

cartas com ao menos um defeito encontrado

Apoio é uma finalidade possível, não avaliada aqui. O detector ainda não é suficiente para a graduação automática.

APOIO

Qual corte de tamanho foi usado?

< 8 px

menor lado da caixa, na entrada de 1280 pixels

517

caixas nessa faixa, 10,8% do total

8 px

passo do nível P3, o mais fino do modelo padrão

Faixas por tamanho: 517 abaixo de 8 pixels, 2.853 de 8 a 20 pixels e 1.438 acima de 20 pixels.

APOIO

Com um treinamento por dobra, o teste generaliza para quê?

Generaliza para

Outras cartas, com os modelos tratados como fixos

Não generaliza para

Outro treinamento: a variação entre treinamentos não foi medida

APOIO

Como a variante de realce foi escolhida?

8,45%

foi a margem da variante e sobre a segunda colocada, no F1 da validação interna

F1 na validação interna da Dobra 1

0,208	Três canais (variante e)
0,192	Emboss e CLAHE
0,161	Frangi
0,151	CLAHE e emboss em oito direções

Uma rodada por variante, sem teste: foi seleção de hiperparâmetro, não resultado. No mAP@0,5, a margem foi de 2%.