

Matheus da Silva Marini

**Avaliação de estratégias de treinamento com
YOLOv8 para detecção de defeitos em cartas
Pokémon TCG em cenários com baixo volume
de dados**

São Paulo

2026

Matheus da Silva Marini

**Avaliação de estratégias de treinamento com YOLOv8
para detecção de defeitos em cartas Pokémon TCG em
cenários com baixo volume de dados**

Trabalho de Conclusão de Curso II apresentado ao SENAC Santo Amaro como requisito parcial para conclusão do curso de Ciência da Computação.

SENAC – Serviço Nacional de Aprendizagem Comercial
Unidade Santo Amaro
Curso de Ciência da Computação

Orientador: Prof. Afonso César Lelis Brandão

São Paulo
2026

Resumo

Este trabalho avaliou o impacto de diferentes estratégias de treinamento aplicadas ao YOLOv8 na detecção de defeitos superficiais em cartas Pokémon TCG (*Trading Card Game*). O objetivo foi identificar quais combinações apresentam melhor desempenho com um conjunto limitado de imagens. A escolha do tema baseou-se na escassez de estudos que avaliam sistematicamente essas estratégias no domínio de cartas colecionáveis. Nesse domínio, a graduação avalia a condição física de cada exemplar, mas a inspeção manual é lenta e sujeita à subjetividade do avaliador. Essas limitações motivam a sua automação por visão computacional. A anotação de defeitos, porém, é cara, e a busca bibliográfica realizada não identificou conjuntos de dados públicos de cartas Pokémon TCG com defeitos localizados. Nos experimentos, o modelo partiu de um YOLOv8s com *transfer learning* a partir de pesos pré-treinados no conjunto público de imagens COCO. Quatro configurações cruzaram o uso ou não de aumento de dados com duas representações de entrada: imagens RGB convencionais e imagens de realce de micro-relevo. Sobre a configuração de melhor desempenho, avaliou-se o efeito de uma cabeça de detecção adicional para objetos pequenos (P2) e da resolução de entrada. O conjunto de dados reuniu 206 cartas, 412 imagens e 4.808 anotações, parte delas sugerida por um modelo preliminar e validada pelo autor. O desempenho foi medido pelo mAP@0,5, pela precisão, pela revocação e pelo F1, em validação cruzada com cinco dobras. O F1 dá uma única nota por carta, o que permitiu comparar as configurações carta a carta pelo teste de Wilcoxon pareado, com correção de Holm. O aumento de dados melhorou o detector: a Configuração 2, com imagens RGB e aumento de dados, obteve o melhor desempenho, com F1 por carta de 0,376, contra 0,332 da mesma configuração sem aumento de dados. O realce de micro-relevo foi inferior ao RGB quando não havia aumento de dados. Com aumento de dados, essa diferença desapareceu quando a avaliação desconsiderou as anotações sugeridas pelo modelo preliminar. A cabeça P2 apresentou desempenho inferior à configuração vencedora, com a mesma revocação e menor precisão. Essa variante não partiu de pesos pré-treinados na cabeça de detecção nem em parte das camadas intermediárias, e por isso o efeito isolado da cabeça P2 não pôde ser separado da ausência de pré-treino. Em uma dobra avaliada (45 cartas), aumentar a resolução de entrada de 640 para 1280 pixels elevou o mAP@0,5 de 0,156 para 0,309 e o F1 por carta de 0,266 para 0,399; esta última diferença foi confirmada pelo teste de Wilcoxon pareado. Uma curva de aprendizado com intervalo de confiança por *bootstrap*, em duas dobras, mostrou que o desempenho ainda não havia estabilizado com o volume de dados disponível. A evidência do aumento de dados vem de cinco dobras, e a da resolução de entrada, de uma só. Por isso, com poucos dados, o aumento de dados melhorou o detector nas duas representações de entrada, e a maior resolução de entrada também o melhorou, mas com evidência mais limitada. O realce de micro-relevo não trouxe ganho.

Palavras-chave: Visão Computacional. Detecção de Defeitos. Pokémon TCG. Conjuntos de Dados Reduzidos. YOLOv8. Realce de Micro-Relevo.

Abstract

This work evaluated the impact of different training strategies applied to YOLOv8 on the detection of surface defects in Pokémon TCG (*Trading Card Game*) cards. The objective was to identify which combinations perform best with a limited set of images. The choice of topic was based on the scarcity of studies that systematically evaluate these strategies in the domain of collectible cards. In this domain, grading assesses the physical condition of each item, but manual inspection is slow and subject to the evaluator’s subjectivity. These limitations motivate its automation through computer vision. Defect annotation, however, is expensive, and the bibliographic search carried out did not identify public datasets of Pokémon TCG cards with localized defects. In the experiments, the model started from a YOLOv8s with *transfer learning* from weights pre-trained on the public COCO image dataset. Four configurations crossed the use or not of data augmentation with two input representations: conventional RGB images and micro-relief enhancement images. On top of the best-performing configuration, the effect of an additional detection head for small objects (P2) and of the input resolution was also evaluated. The dataset comprised 206 cards, 412 images, and 4,808 annotations, part of them suggested by a preliminary model and validated by the author. Performance was measured by mAP@0.5, precision, recall and F1, in five-fold cross-validation. F1 gives a single score per card, which allowed the configurations to be compared card by card using a paired Wilcoxon test with Holm correction. Data augmentation improved the detector: Configuration 2, with RGB images and data augmentation, achieved the best performance, with a per-card F1 of 0.376, against 0.332 for the same configuration without data augmentation. Micro-relief enhancement was inferior to RGB when there was no data augmentation. With data augmentation, this difference disappeared when the evaluation disregarded the annotations suggested by the preliminary model. The P2 head presented lower performance than the winning configuration, with the same recall and lower precision. This variant did not start from pre-trained weights in the detection head or in part of the intermediate layers, so the isolated effect of the P2 head could not be separated from the lack of pre-training. In one evaluated fold (45 cards), increasing the input resolution from 640 to 1280 pixels raised mAP@0.5 from 0.156 to 0.309 and the per-card F1 from 0.266 to 0.399; the latter difference was confirmed by the paired Wilcoxon test. A learning curve with a bootstrap confidence interval, over two folds, showed that performance had not yet stabilized with the available data volume. The evidence for data augmentation comes from five folds, and that for input resolution from only one. Therefore, with limited data, data augmentation improved the detector in both input representations, and higher input resolution also improved it, but with more limited evidence. Micro-relief enhancement brought no gain.

Keywords: Computer Vision. Defect Detection. Pokémon TCG. Small Datasets. YOLOv8. Micro-Relief Enhancement.

Lista de ilustrações

Figura 1 – Critérios de avaliação no processo de graduação de cartas TCG: cantos, bordas, superfície e centralização, ilustrados sobre carta do conjunto de dados.	23
Figura 2 – Exemplo de carta do conjunto de dados nas duas representações disponíveis: imagem RGB convencional e imagem de realce de micro-relevo.	40
Figura 3 – Esquema da validação cruzada estratificada em cinco dobras aplicada ao conjunto de 82 cartas. Em cada rodada, quatro folds são utilizados para treinamento e um fold é reservado para avaliação, mantendo frente e verso da mesma carta no mesmo fold. Do bloco de treinamento de cada rodada, aproximadamente 20% das cartas (cerca de 13) são separadas aleatoriamente como <i>validation set</i> para monitoramento do <i>early stopping</i> , permanecendo o fold de avaliação completamente isolado durante o treinamento.	41
Figura 4 – Cronograma de atividades do TCC2 para o segundo semestre de 2026 – Diagrama de Gantt	55

Lista de tabelas

Tabela 1	– Strings de busca utilizadas na pesquisa bibliográfica	20
Tabela 2	– Comparação entre trabalhos relacionados	36
Tabela 3	– Distribuição do tamanho dos defeitos anotados em função da resolução de entrada	39
Tabela 4	– Parâmetros de aumento de dados por configuração experimental	47

Lista de Abreviaturas e Siglas

A lista a seguir reúne, em ordem alfabética, as abreviaturas e siglas utilizadas neste trabalho, acompanhadas de seus respectivos significados.

Abreviatura/Sigla	Significado
AP	<i>Average Precision</i> (Precisão Média)
AVI	<i>Automated Visual Inspection</i> (Inspeção Visual Automatizada)
C2f	<i>Cross Stage Partial Bottleneck with two Convolutions</i> (módulo convolucional do YOLOv8)
CIELAB	Espaço de cor definido pela <i>Commission Internationale de l'Éclairage</i> , com um canal de luminância (L) e dois de cor (a, b)
CLAHE	<i>Contrast Limited Adaptive Histogram Equalization</i>
CNN	<i>Convolutional Neural Network</i> (Rede Neural Convolucional)
COCO	<i>Common Objects in Context</i>
FN	<i>False Negative</i> (Falso Negativo)
FP	<i>False Positive</i> (Falso Positivo)
GPU	<i>Graphics Processing Unit</i> (Unidade de Processamento Gráfico)
HSV	<i>Hue, Saturation, Value</i> (Matiz, Saturação, Valor)
IoU	<i>Intersection over Union</i>
mAP	<i>mean Average Precision</i> (Média das Precisas Médias)
P2–P5	Níveis da pirâmide de características do YOLOv8, identificados pelo passo de subamostragem em relação à imagem de entrada (P2 = passo 4 a P5 = passo 32)
PANet	<i>Path Aggregation Network</i>
PSA	<i>Professional Sports Authenticator</i>
R-CNN	<i>Region-based Convolutional Neural Network</i> (Rede Neural Convolucional Baseada em Regiões)
RGB	<i>Red, Green, Blue</i>
SENAC	Serviço Nacional de Aprendizagem Comercial
SPPF	<i>Spatial Pyramid Pooling Fast</i>
SSD	<i>Single Shot Detector</i>
TCC	Trabalho de Conclusão de Curso
TCG	<i>Trading Card Game</i> (Jogo de Cartas Colecionáveis)
TL	<i>Transfer Learning</i>
TP	<i>True Positive</i> (Verdadeiro Positivo)
UAV	<i>Unmanned Aerial Vehicle</i> (Veículo Aéreo Não Tripulado)
YOLO	<i>You Only Look Once</i>

Sumário

1	INTRODUÇÃO	11
1.1	Contextualização do problema	12
1.2	Formulação do problema	14
1.3	Objetivos e hipótese	15
1.3.1	Objetivo geral	15
1.3.2	Objetivos específicos	15
1.3.3	Hipótese ou critério de validação	16
1.4	Justificativa	17
2	REVISÃO BIBLIOGRÁFICA / TRABALHOS RELACIONADOS	19
2.1	Metodologia da pesquisa bibliográfica	19
2.2	Fundamentos teóricos	21
2.2.1	Deep Learning e Redes Neurais Convolucionais	21
2.2.2	Visão Computacional e Inspeção Visual Automatizada	22
2.2.3	Defeitos visuais em cartas colecionáveis	23
2.2.4	Detecção de Objetos	24
2.2.5	Arquitetura YOLO	25
2.2.6	Transfer Learning	27
2.2.7	Detecção de Objetos em Cenários com Dados Limitados	27
2.2.8	Aumento de Dados	28
2.2.9	Pré-processamento e realce de micro-relevo	29
2.2.10	Detecção de objetos pequenos	30
2.2.11	Estudo de Ablação	31
2.2.12	Validação Cruzada	31
2.2.13	Comparação estatística entre configurações	32
2.2.14	Métricas de Avaliação	33
2.3	Trabalhos correlatos	34
2.3.1	Trabalho 1: <i>Automated corner grading of trading cards: Defect identification and confidence calibration through deep learning</i>	34
2.3.2	Trabalho 2: <i>NHD-YOLO: Improved YOLOv8 using optimized neck and head for product surface defect detection with data augmentation</i>	35
2.3.3	Trabalho 3: <i>A transfer learning-based YOLO network for sewer defect detection in comparison to classic object detection methods</i>	35
3	DESENVOLVIMENTO / IMPLEMENTAÇÃO / EXPERIMENTOS	37
3.1	Metodologia da pesquisa	37

3.1.1	Visão geral da proposta	37
3.1.2	Organização e preparação do conjunto de dados	38
3.1.3	Critérios de validação	42
3.2	Detalhes da implementação	43
3.2.1	Modelo base	43
3.2.2	Hiperparâmetros de treinamento	44
3.2.3	Tecnologias e ferramentas	45
3.3	Experimentos e cenário de testes	46
3.3.1	Estratégias de treinamento avaliadas	46
3.3.2	Estudo de ablação	48
3.4	Resultados e análises	48
4	CONCLUSÃO	49
4.1	Retomada do problema e dos objetivos	49
4.2	Contribuições para a Computação	49
4.3	Limitações e trabalhos futuros	49
	REFERÊNCIAS	50
	APÊNDICES	53
	APÊNDICE A – CRONOGRAMA PREVISTO NO TCC1	54

1 Introdução

Trading Card Games (TCG) são jogos de cartas colecionáveis nos quais cada carta possui atributos únicos, como raridade, ilustração, edição, condição física e valor comercial. Além de sua função no contexto do jogo, essas cartas são negociadas entre jogadores e colecionadores, o que contribui para a formação de um mercado voltado à compra, venda, troca e avaliação de exemplares. Representado por franquias como Pokémon e Magic: The Gathering, esse mercado deve movimentar aproximadamente 20 bilhões de dólares globalmente em 2026, com projeção de ultrapassar 76 bilhões até 2035 ([Business Research Insights, 2026](#)). Nesse contexto, o valor comercial de uma carta está diretamente ligado ao seu estado de conservação física. Para certificar essa condição e conferir segurança às transações, consolidou-se o serviço especializado de gradação de cartas (*card grading*), no qual profissionais avaliam cada exemplar segundo critérios padronizados e atribuem uma nota que sintetiza sua qualidade ([NAHAR et al., 2025a](#)). A PSA (*Professional Sports Authenticator*), pioneira nessa padronização, estabeleceu uma escala de 10 pontos que se tornaria norma do setor ([NAHAR et al., 2025a](#)), enquanto a Beckett Grading Services introduziu, posteriormente, subnotas para atributos individuais da carta, ampliando o detalhamento do processo de avaliação ([SHEN; WEI, 2025](#)).

O processo de gradação, no entanto, ainda é realizado de forma predominantemente manual. Os avaliadores inspecionam cada carta com auxílio de instrumentos ópticos, como microscópios, o que torna a análise demorada, sujeita à subjetividade de cada profissional e difícil de escalar para acompanhar a demanda. Além disso, o manuseio durante a inspeção pode causar desgaste à própria carta. Em um mercado no qual uma carta pode valer de poucos dólares a centenas de milhares, conforme a raridade e o estado de conservação, a precisão dessa avaliação tem papel crítico no preço ([NAHAR et al., 2025a](#); [NAHAR et al., 2025b](#)).

Como resposta a esses desafios, a automação baseada em visão computacional tem sido investigada como alternativa à inspeção manual. Na indústria de manufatura, sistemas de inspeção visual automatizada (*Automated Visual Inspection – AVI*) já empregam arquiteturas de *Deep Learning* e Redes Neurais Convolucionais (CNNs) para detectar defeitos em superfícies com alta velocidade e reprodutibilidade ([ZHENG et al., 2021](#)). A adaptação dessas abordagens ao contexto de cartas colecionáveis, contudo, não é direta: as características visuais particulares das cartas e as condições reais de captura introduzem desafios técnicos específicos que limitam a transferência imediata das soluções desenvolvidas para domínios industriais convencionais ([NAHAR et al., 2025a](#)).

Um obstáculo adicional diz respeito à disponibilidade de dados. Em tarefas de detecção de objetos em domínios especializados, a construção de conjuntos de dados anotados em larga escala é custosa e trabalhosa, pois cada imagem exige rotulagem especializada

com caixas delimitadoras precisas para cada instância de defeito (SITU et al., 2023). No contexto de cartas TCG, essa restrição é ainda mais pronunciada: a anotação requer avaliação especializada de defeitos segundo critérios técnicos de graduação, e o principal estudo identificado no domínio, conduzido sobre cartas esportivas, contou com o apoio de um parceiro da indústria para viabilizar seu conjunto de dados (NAHAR et al., 2025a).

Pesquisadores já investigaram o uso de técnicas de visão computacional para classificar defeitos em cartas colecionáveis (NAHAR et al., 2025a), porém ainda há uma carência de estudos que avaliem sistematicamente o impacto de diferentes estratégias de treinamento em cenários com baixo volume de dados nesse domínio específico. Durante a busca bibliográfica deste trabalho não foi identificado um conjunto de dados público de imagens de cartas Pokémon TCG com os defeitos localizados por caixas delimitadoras. O único conjunto público encontrado difere do necessário neste trabalho em dois pontos: reúne cartas esportivas, e não cartas Pokémon TCG, e traz recortes rotulados para classificação, sem a posição de cada defeito (NAHAR et al., 2025b). Isso reforça a necessidade de construção de um conjunto próprio. Diante disso, este trabalho realizou uma análise comparativa de estratégias de treinamento para detecção de defeitos em cartas Pokémon TCG, conduzida sobre um conjunto de dados composto por 206 cartas fornecido por uma empresa brasileira especializada em graduação. Sobre um YOLOv8s com *transfer learning* a partir de pesos pré-treinados no conjunto COCO, foram avaliados o aumento de dados (*data augmentation*) e o realce de micro-relevo (uma transformação da imagem que destaca variações locais de intensidade associadas ao relevo da superfície, como vincos e amassados) como representação de entrada. Essas duas estratégias foram cruzadas em um estudo fatorial, que resultou em quatro configurações comparadas entre si. Em seguida, sobre a configuração de melhor desempenho nessa comparação, foram avaliadas uma cabeça de detecção adicional para objetos pequenos (P2) e a resolução de entrada de 1280 pixels, em comparação com a resolução padrão de 640 pixels. A avaliação foi realizada por meio de métricas quantitativas consolidadas na literatura, com o objetivo de identificar as combinações mais eficazes em cenários com dados limitados.

1.1 Contextualização do problema

Na graduação de cartas colecionáveis, a avaliação segue critérios físicos padronizados que consideram superfície, bordas, cantos e centralização como atributos independentes, cada um passível de apresentar tipos específicos de defeito (NAHAR et al., 2025a). Do ponto de vista visual, esses defeitos tendem a ser localizados em regiões específicas da carta e podem ocupar áreas reduzidas da imagem, o que os torna difíceis de identificar tanto manualmente quanto por meio de modelos computacionais (NAHAR et al., 2025a).

Do ponto de vista computacional, a detecção desses defeitos apresenta desafios semelhantes aos encontrados em inspeção industrial automatizada, mas agravados pelas

características específicas das cartas TCG. O primeiro deles é a iluminação durante a captura das imagens: quando a iluminação não produz bom contraste entre o defeito e o fundo, ou quando introduz ruído na imagem, o reconhecimento de defeitos por métodos supervisionados se torna mais difícil (ZHENG et al., 2021). No contexto de cartas colecionáveis, esse efeito pode ser intensificado pela presença de artes visualmente complexas, superfícies holográficas e defeitos de baixa visibilidade. Para mitigar seu impacto sobre a detecção de defeitos sutis, operadores de filtragem têm sido aplicados como etapa de pré-processamento em sistemas de inspeção visual (SAWADA; FUJI; AIKAWA, 2024; JIANG et al., 2023).

O segundo desafio são os reflexos em superfícies holográficas (*foil*). Em superfícies altamente refletoras, artefatos de reflexo podem mascarar as características visuais necessárias para identificar defeitos (KIM; OKWUOSA; HUR, 2026). De modo análogo, o brilho da superfície holográfica pode reduzir o contraste entre o defeito e a região ao redor, e reflexos e sombras já são reconhecidos como fonte de problema na captura de imagens de cartas (NAHAR et al., 2025a). Entre as estratégias avaliadas neste trabalho, o realce de micro-relevo aumenta o contraste local da imagem e pode atenuar em parte essa perda de contraste; nenhuma delas, porém, atua sobre a captura da imagem, etapa em que o reflexo se forma.

Um terceiro desafio diz respeito à natureza da tarefa de inspeção em si. Abordagens de classificação atribuem um rótulo à imagem, ou a um recorte dela, como um canto da carta, sem fornecer informação sobre a localização do defeito (HUSSAIN, 2023). Um canto pode apresentar *whitening* restrito à sua extremidade, mas o classificador produz apenas uma nota global para aquela região, sem indicar a posição ou a extensão do dano. Quando essa informação é necessária, a detecção de objetos, que localiza cada instância por caixa delimitadora e lhe atribui uma classe (RAMOS; SAPPA, 2025), é apontada como preferível à classificação de imagens em inspeção de defeitos (HUSSAIN, 2023). Neste trabalho, a detecção foi conduzida com uma única classe, denominada *defeito*: o modelo localiza cada instância, mas não distingue o tipo de defeito nem sua gravidade. Mesmo sem essas informações, a localização tem valor próprio, pois indica ao avaliador em que pontos da carta concentrar a inspeção.

Um quarto desafio diz respeito ao tamanho dos defeitos. Antes de entrar na rede, a imagem é redimensionada para a resolução de entrada: na resolução de 640 pixels, por exemplo, ela é redimensionada, mantendo a proporção, até que seu lado maior meça 640 pixels. A rede, por sua vez, reduz essa imagem em etapas, e cada nível de detecção trabalha sobre um mapa de características em que um único ponto resume um bloco de pixels da imagem de entrada; o lado desse bloco é chamado de passo. No nível de passo 8, por exemplo, cada ponto resume um bloco de 8×8 pixels, e o sinal de um defeito cujo menor lado é menor que 8 pixels ocupa só uma parte de cada bloco em que aparece e fica diluído no ponto que resume esse bloco. Na resolução de entrada de 640 pixels, que é a

resolução padrão do YOLOv8, 57,6% dos defeitos deste conjunto de dados têm o menor lado da caixa delimitadora abaixo de 8 pixels, o passo do nível de detecção mais fino do YOLOv8 original (P3); essa proporção cai para 10,8% quando a resolução de entrada sobe para 1280 pixels. Essa restrição motivou a avaliação de uma cabeça de detecção adicional voltada a objetos pequenos (P2, de passo 4) e da resolução de entrada como estratégias deste trabalho.

Por fim, a construção de conjuntos de dados anotados nesse domínio impõe restrições práticas que delimitam diretamente o escopo de investigação possível. Mesmo o principal estudo identificado no domínio trabalhou com um conjunto que os próprios autores caracterizam como pequeno (NAHAR et al., 2025a), o que evidencia por que cenários com poucos exemplos rotulados constituem uma restrição real que demanda estratégias de treinamento específicas. Um sistema integrado de graduação automática, apresentado por seus autores como pronto para uso em produção, avalia cantos, bordas e superfície de forma unificada, com algumas centenas de cartas (593 para cantos, 134 para bordas e 150 para superfície) (NAHAR et al., 2025b). Esse sistema, porém, classifica recortes da carta, sem localizar os defeitos na imagem. A diferença para este trabalho é, portanto, sobretudo de tarefa: aqui, o modelo detecta cada defeito e o localiza por caixa delimitadora.

1.2 Formulação do problema

Diante desses desafios, o problema investigado neste trabalho pode ser formulado pela seguinte pergunta: com um conjunto reduzido de imagens anotadas, quais estratégias de treinamento aplicadas ao YOLOv8, entre aumento de dados, realce de micro-relevo como representação de entrada, cabeça de detecção adicional para objetos pequenos e resolução de entrada, melhoram a detecção de defeitos superficiais em cartas Pokémon TCG? O trabalho restringe-se à detecção de defeitos com uma classe única, sem atribuir a nota de graduação da carta, e à comparação dessas estratégias sobre um mesmo conjunto de dados e um mesmo protocolo de avaliação.

As anotações de defeito usadas neste trabalho foram feitas por um único anotador, o próprio autor, com apoio nos laudos de graduação emitidos pela empresa que forneceu o conjunto de dados e no próprio julgamento sobre a imagem, inclusive para defeitos não registrados nesses laudos. A referência contra a qual o detector é medido é, portanto, o julgamento desse anotador apoiado nos laudos, e não o laudo em si; sem um segundo anotador, não foi possível medir a concordância entre avaliadores, e o desempenho que é possível medir fica limitado pela consistência dessa anotação. Parte das caixas delimitadoras, 892 de 4.808 (18,6%), foi sugerida por um modelo de detecção treinado previamente e validada individualmente pelo autor. Esse modelo usava imagens coloridas convencionais (RGB), com aumento de dados, e as sugestões para cada carta vieram de modelos treinados sem essa carta. Como esse modelo via as imagens da mesma forma que as configurações

que usam imagens RGB, as caixas sugeridas podem favorecer essas configurações na comparação com o realce de micro-relevo; por esse motivo, os resultados apresentados no Capítulo 3 foram verificados também desconsiderando essas caixas sugeridas.

1.3 Objetivos e hipótese

Os objetivos a seguir decorrem da lacuna e da restrição apresentadas nas seções anteriores: há carência de estudos que avaliem sistematicamente estratégias de treinamento para detectar defeitos em cartas colecionáveis, e o conjunto de dados disponível reúne apenas 206 cartas. Por isso, o objetivo é comparativo: em vez de propor um modelo novo, o trabalho avalia quais estratégias melhoram um detector já estabelecido, o YOLOv8, nesse cenário.

1.3.1 Objetivo geral

Avaliar o desempenho de estratégias de treinamento aplicadas ao modelo YOLOv8 para detecção de defeitos em cartas Pokémon TCG em cenários com baixo volume de dados.

1.3.2 Objetivos específicos

Para alcançar o objetivo geral, foram definidos os seguintes objetivos específicos:

1. Organizar e preparar um conjunto de dados de imagens de cartas Pokémon TCG, adotando uma classe única de detecção denominada *defeito*.
2. Implementar quatro configurações experimentais baseadas em YOLOv8 com *transfer learning*, cruzando o uso de aumento de dados (*data augmentation*) com duas representações de entrada, imagens RGB convencionais e imagens de realce de micro-relevo, e comparar as quatro combinações resultantes.
3. Avaliar, sobre a configuração de melhor desempenho nessa comparação, o efeito de uma cabeça de detecção adicional voltada a objetos menores (P2), pela revocação (a proporção dos defeitos anotados que o modelo encontra) dos defeitos cujo menor lado da caixa delimitadora é menor que 8 pixels, e o efeito da resolução de entrada, comparando 1280 e 640 pixels pelo F1 por carta, com teste de Wilcoxon pareado.
4. Comparar o desempenho das diferentes configurações por meio de métricas quantitativas consolidadas em detecção de objetos, incluindo precisão (*Precision*), revocação (*Recall*), F1-score e *mean Average Precision* (mAP@0,5).
5. Avaliar, por meio de uma curva de aprendizado, se o desempenho do detector aumenta com o número de cartas disponíveis para treino.

6. Analisar os resultados obtidos, identificando quais estratégias de treinamento apresentam melhor desempenho em cenários com conjuntos de dados reais e limitados no domínio de inspeção de cartas TCG.

1.3.3 Hipótese ou critério de validação

A partir da revisão da literatura, foram formuladas as hipóteses H1 a H3; a hipótese H4 foi formulada depois, a partir da análise do tamanho das anotações apresentada na Seção 1.1. As quatro hipóteses foram formuladas antes do treinamento dos modelos usados para testá-las:

- H1** O aumento de dados (*data augmentation*) melhora o desempenho do detector em relação à configuração sem aumento de dados.
- H2** O uso de imagens de realce de micro-relevo como representação de entrada melhora o desempenho do detector em relação às imagens RGB.
- H3** A combinação de aumento de dados e realce de micro-relevo (Configuração 4) produz o melhor desempenho entre as quatro configurações avaliadas.
- H4** A cabeça de detecção adicional P2 aumenta a revocação (*recall*) dos defeitos cujo menor lado da caixa delimitadora é menor que 8 pixels, na resolução de entrada de 1280 pixels.

A métrica usada para testar H1 a H3 foi o F1 por carta, que resume em um único valor a precisão e a revocação das detecções de cada carta; seu cálculo é descrito no Capítulo 3. H1 foi testada pela comparação pareada por carta entre a Configuração 2 (RGB com aumento de dados) e a Configuração 1 (RGB sem aumento de dados), e entre a Configuração 4 (realce com aumento de dados) e a Configuração 3 (realce sem aumento de dados). H2 foi testada pela comparação entre a Configuração 3 e a Configuração 1, e entre a Configuração 4 e a Configuração 2. H3 seria refutada se alguma das outras configurações superasse a Configuração 4, o que foi verificado pelas mesmas comparações da Configuração 4 com as Configurações 2 e 3, sem teste adicional. Todas essas comparações usaram o teste de Wilcoxon pareado bilateral, com nível de significância $\alpha = 0,05$, definido antes do treinamento das quatro configurações; a correção de Holm para o conjunto de comparações foi aplicada na análise dos resultados.

Para H4, o critério, definido antes do treinamento da variante com a cabeça P2, foi a revocação dos defeitos cujo menor lado da caixa é menor que 8 pixels na resolução de 1280 pixels, somados todos os defeitos desse grupo, comparando a configuração de melhor desempenho com e sem a cabeça P2. Mesmo nessa resolução, parte dos defeitos permanece abaixo do passo do nível P3 (Seção 1.1), o que justificou testar a P2 nessa resolução. Já se sabia, antes desse treinamento, que a variante com a cabeça P2 não receberia pesos

pré-treinados na cabeça de detecção nem em parte das camadas intermediárias; por isso, o teste de H4 não separa o efeito da cabeça P2 do efeito da falta de pré-treino.

A resolução de entrada e a curva de aprendizado foram análises exploratórias, decididas depois dos resultados do estudo fatorial e sem hipótese formulada previamente; seus resultados indicam direções a confirmar. A confirmação ou a refutação de cada hipótese é apresentada nos resultados e retomada na conclusão.

1.4 Justificativa

No âmbito científico, os estudos existentes sobre automação da graduação de cartas colecionáveis apresentam contribuições relevantes, mas com lacunas que abrem espaço para a investigação realizada neste trabalho. [Nahar et al. \(2025a\)](#) propõem um modelo baseado em *transfer learning* para classificar a severidade de defeitos em cantos, alcançando 83% de acurácia média em um conjunto de 4.744 imagens de cantos obtidas de 593 cartas esportivas, mas o estudo está restrito a um único critério de avaliação e não analisa sistematicamente o impacto de diferentes estratégias de treinamento no desempenho do modelo. Embora o sistema integrado descrito na Seção 1.1 alcance acurácias de 81% a 94% na classificação de recortes ([NAHAR et al., 2025b](#)), a investigação sistemática do impacto de estratégias de treinamento na detecção localizada de defeitos, com conjuntos reduzidos de dados reais, permanece uma lacuna no domínio de cartas colecionáveis, que este trabalho investigou sobre um conjunto de 206 cartas e 412 imagens.

A relevância de investigar estratégias como *transfer learning* e aumento de dados em cenários com amostras escassas é sustentada pela literatura de inspeção visual automatizada. [Chen et al. \(2021\)](#) identificam o problema de pequenas amostras (*small sample problem*) como um dos problemas centrais da detecção de defeitos superficiais industriais com aprendizado profundo, associado ao risco de sobreajuste, e apontam quatro linhas de solução: aumento de dados, modelos não supervisionados ou semissupervisionados, *transfer learning* e otimização da estrutura da rede. Um exemplo quantitativo é apresentado por [Wang, Li e Wang \(2022\)](#), na detecção de defeitos superficiais em aço: com apenas cinco imagens rotuladas por categoria, pré-treinar o detector em outras categorias de defeito antes do ajuste fino elevou o mAP de 9,4% para 24,1%, em relação ao mesmo modelo treinado somente com essas imagens. Nesse mesmo experimento, o aumento de dados, uma das estratégias avaliadas neste trabalho, acrescentou até 2,3 pontos percentuais ao mAP.

Na prática, avaliar essas estratégias (aumento de dados, realce de micro-relevo, a cabeça de detecção adicional P2 e a resolução de entrada) sobre um YOLOv8s com *transfer learning* a partir do conjunto COCO indica quais delas merecem ser priorizadas quando o volume de dados de treinamento é pequeno, um cenário comum em domínios especializados como o de cartas colecionáveis. Um resultado negativo (uma estratégia que não melhora o

desempenho nesse cenário) também constitui uma contribuição, pois evita que trabalhos futuros repitam o mesmo investimento sem o ganho esperado. Essa análise é relevante para contextos em que a anotação é cara e o volume de dados é limitado ([SITU et al., 2023](#); [CHEN et al., 2021](#)), e busca subsidiar a detecção automática de defeitos como apoio à inspeção visual ([NAHAR et al., 2025a](#)).

2 Revisão Bibliográfica / Trabalhos Relacionados

Este capítulo apresenta os fundamentos teóricos e os trabalhos relacionados que sustentam a proposta deste TCC. Inicialmente, são discutidos conceitos essenciais de visão computacional aplicados à inspeção visual automatizada, com ênfase em *Deep Learning*, redes neurais convolucionais, detecção de objetos e na arquitetura YOLO. Em seguida, são abordadas estratégias relevantes para cenários com baixo volume de dados, como *transfer learning*, aumento de dados e uso de imagens de realce de micro-relevo, além das métricas utilizadas na avaliação de detectores. Por fim, são analisados trabalhos relacionados ao problema investigado, com o objetivo de situar a pesquisa no estado da arte e evidenciar a lacuna que motiva a proposta deste trabalho.

2.1 Metodologia da pesquisa bibliográfica

A pesquisa bibliográfica foi realizada por meio das bases Google Scholar, IEEE Xplore, ScienceDirect e MDPI, utilizando combinações de termos em inglês diretamente relacionados aos temas centrais do trabalho. As strings de busca utilizadas, bem como os quantitativos de artigos triados e selecionados em cada etapa, estão apresentados na Tabela 1. A triagem considerou título e resumo como critérios iniciais de relevância, com leitura completa reservada aos trabalhos selecionados para inclusão.

Tabela 1 – Strings de busca utilizadas na pesquisa bibliográfica

String de busca	Bases	Triados	Selecionados
<i>“trading card” AND “Pokemon TCG”</i>	GS, IEEE, SD, MDPI	2	1
<i>“trading card” OR “collectible card” AND “computer vision”</i>	GS, IEEE, SD, MDPI	6	2
<i>“card grading” AND “automated” OR “machine learning”</i>	GS, IEEE, SD, MDPI	6	2
<i>“surface defect detection” AND “computer vision” AND “scratch” OR “wear”</i>	GS, IEEE, SD, MDPI	9	3
<i>“ablation study” AND “object detection” AND “transfer learning”</i>	GS, IEEE, SD, MDPI	5	2
<i>“dataset COCO” AND “object detection” AND “YOLO pretraining”</i>	GS, IEEE, SD, MDPI	3	1
<i>“emboss filter” AND “surface defect” AND “deep learning”</i>	GS, IEEE, SD, MDPI	5	1
<i>“CLAHE filter” AND “surface defect” AND “deep learning”</i>	GS, IEEE, SD, MDPI	8	1
<i>“YOLOv8” AND “defect detection” AND “transfer learning”</i>	GS, IEEE, SD, MDPI	11	4
<i>“cross-validation” AND “YOLO” AND “defect detection”</i>	GS, IEEE, SD, MDPI	6	1
<i>“statistical comparison” AND “classifiers” AND “cross-validation”</i>	GS, IEEE, SD, MDPI	3	1
<i>“Neural Networks” AND “Early Stopping”</i>	GS, IEEE, SD, MDPI	2	1
<i>“filter” AND “surface defect detection” AND “deep learning”</i>	GS, IEEE, SD, MDPI	5	1
<i>“small object detection” AND “input resolution” OR “image size”</i>	GS, IEEE, SD, MDPI	9	3
<i>“highly reflective” surface defect detection YOLO</i>	MDPI	9	1
Fontes não acadêmicas (contextualização de mercado e documentação técnica)	Diversas	—	2
Total		89	27

GS = Google Scholar; IEEE = IEEE Xplore; SD = ScienceDirect; MDPI = Multidisciplinary Digital Publishing Institute. Fonte: Elaborado pelo autor (2026).

Foram priorizados trabalhos acadêmicos publicados entre 2021 e 2026, em língua inglesa, disponíveis em periódicos ou anais de conferências. A seleção considerou principalmente estudos revisados por pares e *surveys* recentes quando diretamente relacionados ao problema investigado ou necessários para fundamentar conceitos técnicos específicos. Excepcionalmente, foram incluídos quatro trabalhos anteriores a 2021 por se tratarem de referências fundacionais: o *dataset COCO* (LIN et al., 2014), base de pré-treinamento do YOLOv8; Kohavi (1995), referência fundacional sobre validação cruzada em cenários com dados limitados, diretamente aplicável ao contexto deste trabalho; Demšar (2006),

referência fundacional sobre comparação estatística entre algoritmos de aprendizado, cuja recomendação metodológica fundamenta o procedimento de comparação adotado na Seção 2.2.13; e [Prechelt \(1998\)](#), referência fundacional sobre a escolha do critério de parada antecipada, que fundamenta o valor de paciência adotado na Seção 3.2.2.

De forma complementar, também foram consultadas fontes não acadêmicas, como páginas institucionais e relatórios setoriais, utilizadas exclusivamente para contextualização do mercado e caracterização do domínio de aplicação ([Business Research Insights, 2026](#)). A relevância de cada trabalho foi avaliada com base em sua aderência ao problema de pesquisa, isto é, a detecção automatizada de defeitos visuais em cenários com baixo volume de dados, com ênfase em aplicações de visão computacional em domínios especializados.

2.2 Fundamentos teóricos

Esta seção apresenta os principais conceitos teóricos necessários para fundamentar a proposta deste trabalho. São discutidos os fundamentos de *Deep Learning*, Redes Neurais Convolucionais, visão computacional, inspeção visual automatizada, defeitos visuais em cartas colecionáveis, detecção de objetos, arquitetura YOLO, *transfer learning*, detecção de objetos em cenários com dados limitados, aumento de dados, pré-processamento e realce de micro-relevo, detecção de objetos pequenos, estudo de ablação, validação cruzada, comparação estatística entre configurações e métricas de avaliação. Esses conceitos sustentam a metodologia experimental adotada e permitem compreender as decisões técnicas envolvidas na comparação das estratégias de treinamento avaliadas.

2.2.1 Deep Learning e Redes Neurais Convolucionais

Deep Learning é uma subárea do aprendizado de máquina que utiliza redes neurais artificiais com múltiplas camadas para aprender representações diretamente a partir dos dados. Em visão computacional, essa abordagem reduziu a dependência de características projetadas manualmente, permitindo que os modelos extraíssem padrões visuais complexos a partir das próprias imagens ([ZHENG et al., 2021](#)). Nesse contexto, as Redes Neurais Convolucionais (CNNs, do inglês *Convolutional Neural Networks*) tornaram-se a arquitetura central para tarefas como classificação de imagens, detecção de objetos e inspeção de defeitos, pois utilizam camadas convolucionais para aprender características visuais em diferentes níveis de abstração ([HUSSAIN, 2023](#)).

A relevância das CNNs em visão computacional foi consolidada por arquiteturas como AlexNet, VGGNet, GoogLeNet, ResNet e DenseNet, que demonstraram a eficácia de redes profundas na extração automática de características visuais ([ZHENG et al., 2021](#); [HUSSAIN, 2023](#)). Embora apresentem diferenças estruturais, essas arquiteturas compartilham a ideia de aprender representações hierárquicas da imagem, nas quais

camadas iniciais capturam padrões simples, como bordas e texturas, enquanto camadas mais profundas representam formas e estruturas mais complexas.

Na inspeção visual automatizada, essa capacidade é especialmente importante porque defeitos de superfície podem variar em forma, escala, textura e contraste. Segundo [Zheng et al. \(2021\)](#), métodos tradicionais dependiam de atributos manualmente projetados, o que os tornava sensíveis a variações nas condições de captura e no tipo de defeito. Já métodos baseados em *deep learning* integram a extração e a aprendizagem de características em um mesmo processo, favorecendo maior adaptação a diferentes cenários de inspeção.

Essa base também sustenta arquiteturas modernas de detecção, como a família YOLO, nas quais redes convolucionais são utilizadas para extrair características visuais que posteriormente são empregadas na localização e classificação dos objetos de interesse ([HUSSAIN, 2023](#)). Assim, a compreensão das CNNs é necessária para fundamentar o uso de detectores baseados em *deep learning* na identificação de defeitos visuais em cartas TCG.

2.2.2 Visão Computacional e Inspeção Visual Automatizada

A visão computacional é a área da ciência da computação que desenvolve métodos para que sistemas digitais interpretem e analisem imagens e vídeos automaticamente. Uma de suas aplicações mais relevantes na prática industrial está nos sistemas de inspeção visual automatizada (*Automated Visual Inspection* – AVI), cuja função é substituir ou apoiar a inspeção manual de qualidade em linhas de produção ([ZHENG et al., 2021](#)).

Um sistema AVI é composto, em geral, por três etapas principais: aquisição de imagem, detecção de defeitos e controle de qualidade. A etapa de aquisição utiliza câmeras digitais combinadas com sistemas de iluminação controlada para garantir contraste adequado entre as características do produto e possíveis defeitos. Em seguida, a etapa de detecção aplica algoritmos de processamento de imagem para identificar e classificar anomalias. Por fim, os resultados são enviados ao sistema de controle de qualidade, que determina a aceitação ou rejeição do produto ([ZHENG et al., 2021](#)).

Antes da consolidação do *Deep Learning*, muitos sistemas AVI dependiam de características projetadas manualmente por especialistas, o que os tornava sensíveis a variações nas condições de aplicação ([ZHENG et al., 2021](#)). Com o avanço das CNNs, passaram a ser desenvolvidos métodos capazes de aprender padrões diretamente a partir dos dados de treinamento, superando parte das limitações dos métodos tradicionais. Na prática industrial, sistemas baseados em CNNs têm sido aplicados com sucesso na inspeção de defeitos em semicondutores, aço e tecidos, atingindo taxas de acurácia superiores a 99% em alguns casos ([ZHENG et al., 2021](#)).

2.2.3 Defeitos visuais em cartas colecionáveis

A inspeção visual de cartas colecionáveis envolve a identificação de defeitos físicos distribuídos ao longo de regiões específicas da carta. O processo de graduação avalia quatro critérios independentes: cantos, bordas, superfície e centralização, cada um passível de apresentar tipos específicos de defeito (NAHAR et al., 2025a). A Figura 1 ilustra essas regiões e os principais tipos de imperfeição associados a cada critério.

Figura 1 – Critérios de avaliação no processo de graduação de cartas TCG: cantos, bordas, superfície e centralização, ilustrados sobre carta do conjunto de dados.



Critérios de avaliação no processo de graduação de cartas TCG

Fonte: Elaborado pelo autor a partir de imagem fornecida por empresa parceira (2026).

Do ponto de vista computacional, compreender as características visuais desses defeitos é essencial para definir a formulação adequada da tarefa de detecção automática. Os tipos de defeito mais relevantes para a inspeção visual automatizada incluem:

- **Riscos superficiais (*scratches*):** arranhões ou marcas lineares na superfície da carta, causados por atrito com outras cartas ou superfícies abrasivas. Podem ocorrer tanto na face frontal quanto no verso e variam em comprimento, profundidade e visibilidade (NAHAR et al., 2025a).

- **Dobras e vincos (*creases*):** deformações resultantes de dobramento parcial da carta. São considerados defeitos graves por comprometer a integridade estrutural do substrato e por serem facilmente perceptíveis mesmo em condições normais de iluminação (NAHAR et al., 2025a).
- **Whitening:** perda de pigmentação nas bordas ou cantos da carta, que se tornam visivelmente mais claros ou esbranquiçados em relação ao restante da superfície. É um dos indicadores mais comuns de desgaste e um critério central na avaliação de cantos e bordas (NAHAR et al., 2025a).
- **Desgaste de cantos (*corner wear*):** arredondamento ou fratura das extremidades da carta causado por manuseio frequente. Cantos originalmente pontiagudos progressivamente perdem definição, o que reduz diretamente a nota atribuída nesse critério (NAHAR et al., 2025a).
- **Desgaste de bordas (*edge fraying*):** deterioração das margens da carta, com possível separação de fibras do substrato. Manifesta-se como irregularidades visíveis ao longo das quatro bordas e pode ser acompanhado de *whitening* nas regiões afetadas (NAHAR et al., 2025a).

Do ponto de vista computacional, esses defeitos apresentam características que dificultam sua detecção automática. Em geral, ocupam regiões pequenas em relação à área total da carta e exibem baixo contraste com a superfície adjacente, especialmente em cartas com estampas complexas ou superfícies holográficas (*foil*) (NAHAR et al., 2025a; CHEN et al., 2021). Defeitos sutis em superfícies com texturas e padrões visuais complexos representam um desafio reconhecido na literatura de inspeção visual, motivando o desenvolvimento de detectores específicos para esse tipo de cenário (ZHANG et al., 2024). Além disso, a aparência dos defeitos pode variar de acordo com as condições de iluminação durante a captura, a posição da câmera e o tipo de impressão da carta, o que torna a tarefa sensível às condições do sistema de aquisição de imagens (ZHENG et al., 2021).

A relevância de um sistema automatizado de detecção está diretamente relacionada a essas dificuldades. Em um processo de graduação manual, o avaliador inspeciona cada carta com lupas e iluminação controlada, e a subjetividade inerente a essa análise pode introduzir inconsistências na nota atribuída (NAHAR et al., 2025a). A automação baseada em visão computacional busca reduzir essa variabilidade ao produzir avaliações reprodutíveis e rastreáveis, com localização espacial explícita de cada defeito identificado.

2.2.4 Detecção de Objetos

A detecção de objetos é uma tarefa de visão computacional que combina dois problemas distintos: a classificação de objetos presentes em uma imagem e a localização precisa de cada instância por meio de caixas delimitadoras (*bounding boxes*) (HUSSAIN, 2023).

Diferentemente da classificação de imagens, que atribui um único rótulo à imagem inteira, a detecção de objetos é capaz de identificar múltiplos objetos em posições diferentes, retornando para cada um deles suas coordenadas espaciais, a classe correspondente e um escore de confiança (RAMOS; SAPPA, 2025).

A qualidade de uma detecção é medida pela métrica *Intersection over Union* (IoU), que quantifica a sobreposição entre a caixa delimitadora predita e a caixa de referência (*ground truth*). O IoU é calculado como a razão entre a área de interseção e a área de união das duas caixas, assumindo valores entre 0 e 1, onde valores mais próximos de 1 indicam maior precisão de localização (RAMOS; SAPPA, 2025). A partir de um limiar de IoU predefinido, geralmente 0,5, uma predição é considerada verdadeiro positivo (TP) quando corresponde a uma caixa de referência e sua sobreposição atinge ou supera esse limiar. Predições que não correspondem adequadamente a nenhuma caixa de referência são contabilizadas como falsos positivos (FP). Caixas de referência que não são associadas a nenhuma predição válida são contabilizadas como falsos negativos (FN). (RAMOS; SAPPA, 2025).

As arquiteturas de detecção de objetos são geralmente classificadas em dois grupos: detectores de dois estágios (*two-stage*) e detectores de um estágio (*one-stage*) (HUSSAIN, 2023). Os detectores de dois estágios, como a família R-CNN, dividem o processo em uma etapa de geração de propostas de regiões candidatas e uma etapa posterior de classificação e refinamento. Embora apresentem alta acurácia, esse design resulta em maior custo computacional e menor velocidade de inferência (SITU et al., 2023). Os detectores de um estágio, por sua vez, realizam a classificação e a localização em uma única passagem pela rede, obtendo melhor desempenho em tempo real com menor demanda computacional (HUSSAIN, 2023).

No contexto deste trabalho, a detecção de objetos é mais adequada do que a classificação pura porque os defeitos de interesse não precisam apenas ser reconhecidos, mas também localizados na imagem. Em cartas TCG, riscos superficiais, desgastes e pequenas dobras podem ocupar regiões específicas e reduzidas da superfície, de modo que a localização espacial do defeito é parte central da análise (HUSSAIN, 2023; RAMOS; SAPPA, 2025). Assim, a escolha por uma tarefa de detecção, e não apenas de classificação, está diretamente associada ao tipo de problema investigado.

2.2.5 Arquitetura YOLO

A família YOLO (*You Only Look Once*) representa uma das abordagens de detecção de objetos do tipo *one-stage* mais difundidas na literatura recente, destacando-se pelo equilíbrio entre velocidade de inferência e acurácia (RAMOS; SAPPA, 2025). Desde sua formulação inicial, a arquitetura trata a detecção como um problema unificado, prevendo caixas delimitadoras e probabilidades de classe diretamente a partir da imagem em uma única passagem pela rede (HUSSAIN, 2023). Essa característica diferencia os modelos

YOLO de detectores em duas etapas, nos quais a geração de regiões candidatas e a classificação são realizadas em fases separadas.

Ao longo do tempo, diferentes versões da família YOLO incorporaram melhorias voltadas ao tratamento de objetos em múltiplas escalas, à otimização do treinamento e à eficiência computacional (HUSSAIN, 2023; RAMOS; SAPP, 2025). O YOLOv8, lançado em 2023, mantém a estrutura modular composta por *backbone*, *neck* e *head*, mas introduz mudanças relevantes em relação a versões anteriores. Entre elas, destacam-se a adoção de um paradigma *anchor-free*, a substituição do módulo C3 pelo C2f, o uso de estruturas como PANet e SPPF para agregação de características em múltiplas escalas e uma cabeça de detecção com ramos desacoplados para classificação e regressão (RAMOS; SAPP, 2025).

O paradigma *anchor-free* reduz a dependência de caixas âncora pré-definidas, permitindo que o modelo estime diretamente os centros dos objetos. Essa característica simplifica o treinamento e pode favorecer a adaptação a *datasets* específicos, nos quais as proporções e distribuições dos objetos não seguem necessariamente os padrões de bases genéricas (RAMOS; SAPP, 2025). Já o módulo C2f busca melhorar o reaproveitamento de características intermediárias, aumentando a capacidade de representação do *backbone* sem comprometer a eficiência computacional. Além disso, a combinação entre PANet e SPPF contribui para a fusão de informações em diferentes resoluções, aspecto relevante para tarefas que envolvem objetos pequenos ou localizados em regiões específicas da imagem (RAMOS; SAPP, 2025).

O treinamento oficial do YOLOv8 é realizado sobre o dataset COCO (*Common Objects in Context*), uma base de larga escala composta por mais de 328.000 imagens com 2,5 milhões de instâncias anotadas em 91 categorias de objetos comuns em cenas do cotidiano (LIN et al., 2014). Os pesos resultantes desse pré-treinamento são disponibilizados publicamente pela Ultralytics e constituem o ponto de partida padrão para adaptação do YOLOv8 a novos domínios, seja por meio de inferência direta ou de *fine-tuning* (DOBRZYCKI; BERNARDOS; CASAR, 2025; SITU et al., 2023).

No presente trabalho, a escolha do YOLOv8 está relacionada à sua adequação ao problema investigado. Como os defeitos em cartas TCG podem ser pequenos, localizados e visualmente sutis, a tarefa exige um detector capaz de preservar informações espaciais e operar de forma eficiente. Em comparação com detectores de dois estágios, como a família R-CNN, o YOLOv8 oferece menor custo computacional e maior velocidade de inferência sem comprometer a acurácia de localização, o que o torna mais adequado para o contexto experimental deste trabalho (SITU et al., 2023; HUSSAIN, 2023). Além disso, o YOLOv8 possui variantes com diferentes relações entre custo computacional e desempenho, o que favorece sua aplicação em estudos experimentais com conjuntos reduzidos de dados (RAMOS; SAPP, 2025). Em cenários de adaptação de modelos pré-treinados, Dobrzycki, Bernardos e Casar (2025) investigam estratégias de *transfer learning* em arquiteturas

YOLOv8 e YOLOv10, demonstrando que a escolha da configuração de treinamento depende das características do conjunto de dados e dos recursos computacionais disponíveis.

O modelo base (*baseline*) adotado neste trabalho corresponde ao YOLOv8 inicializado com pesos pré-treinados no COCO e submetido a *fine-tuning* sobre o conjunto de imagens RGB de cartas Pokémon TCG, com a classe única *defeito*. Essa configuração serve como referência do estudo de ablação, permitindo quantificar o ganho de desempenho atribuível ao aumento de dados e ao uso de imagens de realce de micro-relevo, conforme detalhado no Capítulo 3.

2.2.6 Transfer Learning

Transfer learning é uma estratégia de aprendizado de máquina que consiste em aproveitar o conhecimento adquirido por um modelo treinado em um domínio fonte para melhorar o desempenho em um domínio alvo distinto (SITU et al., 2023). A motivação para essa abordagem reside na observação de que modelos profundos aprendem representações hierárquicas de características visuais que tendem a ser transferíveis entre domínios, especialmente nas camadas mais rasas da rede, que capturam padrões genéricos como bordas, texturas e gradientes (SITU et al., 2023).

Na prática, o *transfer learning* em visão computacional é implementado por meio de *fine-tuning*: um modelo pré-treinado em um dataset de larga escala, como ImageNet ou COCO, tem seus pesos utilizados como ponto de partida, sendo então re-treinado total ou parcialmente sobre o dataset alvo (DOBRZYCKI; BERNARDOS; CASAR, 2025). Essa abordagem permite que o modelo se adapte às características específicas do novo domínio sem partir de uma inicialização aleatória, reduzindo significativamente a quantidade de dados rotulados necessária para alcançar bom desempenho (SITU et al., 2023).

Em cenários com baixo volume de dados, o *transfer learning* é especialmente relevante. Modelos treinados do zero em datasets pequenos tendem a sofrer com *overfitting*, pois o número de parâmetros livres é desproporcional à quantidade de exemplos disponíveis. Ao inicializar com pesos pré-treinados, o modelo parte de uma representação já rica em padrões visuais, o que atua como uma forma de regularização implícita e melhora a capacidade de generalização (DOBRZYCKI; BERNARDOS; CASAR, 2025). Situ et al. (2023) demonstraram que modelos YOLO com *transfer learning* a partir de backbones pré-treinados superam consistentemente modelos treinados do zero em tarefas de detecção de defeitos com datasets reduzidos, tanto em precisão quanto em velocidade de convergência.

2.2.7 Detecção de Objetos em Cenários com Dados Limitados

A detecção de objetos em cenários com dados limitados constitui um problema relevante em visão computacional, especialmente em domínios nos quais a coleta e a anotação de imagens são custosas. Neste trabalho, o termo *baixo volume de dados* refere-se a conjuntos

nos quais o número de exemplos anotados é insuficiente para treinar modelos de detecção profundos com capacidade de generalização adequada, tornando necessário o uso de estratégias complementares como *transfer learning* e aumento de dados (CHEN et al., 2021). Não há um limiar absoluto universalmente aceito para esse conceito, pois o volume considerado limitado depende da complexidade visual da tarefa e da arquitetura utilizada (WANG; LI; WANG, 2022). No presente trabalho, esse cenário é caracterizado pelo conjunto de 82 cartas disponível, volume substancialmente inferior ao utilizado nos estudos de referência do domínio (NAHAR et al., 2025a).

Em tarefas de detecção, além de reconhecer a classe de interesse, o modelo também deve localizar espacialmente cada instância na imagem por meio de caixas delimitadoras (RAMOS; SAPPA, 2025). Essa exigência torna o processo mais sensível à escassez de exemplos rotulados, uma vez que, além da imagem, é necessário dispor de anotações consistentes indicando a localização de cada objeto ou defeito de interesse (SITU et al., 2023). Em conjuntos reduzidos, modelos baseados em *deep learning* tendem a apresentar maior risco de *overfitting* e menor capacidade de generalização, pois há poucos exemplos disponíveis para representar adequadamente a variabilidade visual dos objetos ou defeitos (WANG; LI; WANG, 2022). Esse problema torna-se ainda mais crítico em aplicações de inspeção visual, nas quais os defeitos podem ser pequenos, sutis, desbalanceados e difíceis de distinguir do fundo da imagem (CHEN et al., 2021; WANG; LI; WANG, 2022). Por esse motivo, a pesquisa não adota um protocolo formal de *Few-Shot Object Detection*, mas se insere no contexto da detecção de objetos com baixo volume de dados, avaliando estratégias como *transfer learning*, aumento de dados e uso de imagens de realce de micro-relevo para melhorar o desempenho do detector (SITU et al., 2023).

2.2.8 Aumento de Dados

O aumento de dados (*data augmentation*) é um conjunto de técnicas que busca ampliar artificialmente a diversidade do conjunto de treinamento por meio de transformações aplicadas às imagens existentes, sem a necessidade de coletar novos exemplos (SITU et al., 2023). O princípio subjacente é expor o modelo a variações plausíveis dos dados durante o treinamento, de modo que a representação aprendida seja mais robusta e generalizável a condições não vistas (SITU et al., 2023).

As técnicas de aumento de dados podem ser agrupadas em duas categorias principais. As transformações geométricas incluem operações como espelhamento horizontal e vertical, rotação, recorte aleatório (*random crop*) e variação de escala. Essas transformações alteram a posição e a orientação dos objetos na imagem sem modificar suas características visuais intrínsecas (DOBRZYCKI; BERNARDOS; CASAR, 2025). As transformações fotométricas, por sua vez, modificam as propriedades de cor e iluminação da imagem, incluindo variações de brilho, contraste, saturação e adição de ruído. Essas técnicas são

especialmente úteis para treinar modelos mais robustos a variações nas condições de captura (SITU et al., 2023).

Em cenários com conjuntos de dados reduzidos, o aumento de dados desempenha um papel crítico na prevenção de *overfitting*. Ao aumentar a diversidade efetiva do conjunto de treinamento, essa estratégia reduz a dependência do modelo em relação a padrões específicos dos exemplos disponíveis, favorecendo a generalização (CHEN et al., 2021). No contexto específico de detecção de defeitos com YOLOv8, Chen et al. (2024) propõem uma técnica de aumento de dados voltada para objetos pequenos, demonstrando que estratégias de augmentation direcionadas ao tipo de defeito presente no dataset produzem ganhos mais consistentes do que transformações genéricas aplicadas indiscriminadamente. No contexto do presente trabalho, técnicas de aumento de dados serão incorporadas ao pipeline experimental como uma das estratégias avaliadas no estudo de ablação, permitindo quantificar seu impacto individual e combinado no desempenho do modelo.

2.2.9 Pré-processamento e realce de micro-relevo

A qualidade das imagens de entrada é um fator determinante para o desempenho de modelos de visão computacional aplicados à inspeção visual. Em condições reais de captura, variações de iluminação, sombras e reflexos podem introduzir ruídos visuais que dificultam a identificação de defeitos sutis (ZHENG et al., 2021). Métodos baseados em filtragem, como transformada de Fourier, filtros de Gabor e transformada *wavelet*, integram o repertório clássico de detecção de defeitos em superfícies (CHEN et al., 2021). Em abordagens baseadas em aprendizado profundo, operadores dessa natureza têm sido empregados como etapa de pré-processamento, amplificando variações locais de textura e relevo pouco evidentes na imagem RGB convencional (SAWADA; FUJI; AIKAWA, 2024; JIANG et al., 2023).

No contexto da inspeção visual automatizada, filtros de gradiente direcional têm sido aplicados como etapa de pré-processamento para realce de defeitos em superfícies industriais. Sawada, Fuji e Aikawa (2024) empregam filtro *emboss* de oito direções na etapa de extração de defeitos em superfícies pintadas, dentro de um pipeline clássico de morfologia matemática que antecede a classificação por rede convolucional. Os autores não avaliam isoladamente a contribuição do realce por gradiente, de modo que o trabalho evidencia a aplicabilidade da técnica ao problema, e não sua superioridade sobre a ausência de pré-processamento. De forma complementar, Jiang et al. (2023) aplicam *Contrast Limited Adaptive Histogram Equalization* (CLAHE) como etapa de pré-processamento anterior à detecção com YOLO, evidenciando que a equalização adaptativa de histograma pode amplificar detalhes finos relevantes para detectores de objetos. Os operadores de gradiente direcional respondem à taxa de variação da intensidade, isto é, a bordas. Defeitos como riscos e vincos, contudo, não constituem bordas, e sim estruturas alongadas de espessura reduzida com intensidade semelhante nos dois lados, que correspondem a estruturas de

segunda ordem. Gruber e Haselmann (2021) sustentam que a filtragem baseada nos autovalores da matriz Hessiana é adequada à inspeção de superfícies precisamente porque os defeitos observados são acompanhados de estruturas dessa natureza, e registram que o desvio padrão do núcleo gaussiano determina a escala das estruturas amplificadas. Essa seletividade de escala é relevante no presente caso, uma vez que a carta apresenta arte impressa cujos contornos possuem escala e contraste superiores aos dos defeitos investigados, e que operadores de primeira ordem amplificam de forma indistinta.

No presente trabalho, o realce de micro-relevo é obtido no canal de luminância do espaço de cor CIELAB, e não sobre os três canais RGB, de modo que a equalização adaptativa atue sobre a informação de brilho, em que o relevo se manifesta, sem introduzir desvio cromático. A variante específica do operador de realce foi definida por teste preliminar, descrito na Seção 3.2.2, no qual foram comparadas alternativas de primeira e de segunda ordem sobre a mesma dobra. Até onde a revisão bibliográfica identificou, o emprego de uma representação de realce de micro-relevo como entrada alternativa de um detector YOLOv8 não foi investigado na literatura de inspeção de cartas colecionáveis. O estudo de ablação avaliará empiricamente se essa representação contribui para o desempenho do detector no cenário de baixo volume de dados considerado neste trabalho.

2.2.10 Detecção de objetos pequenos

A detecção de objetos pequenos constitui um subcampo com dificuldades próprias, distintas das que caracterizam a detecção em cenários com dados limitados. Cheng et al. (2023) identificam a perda de informação como um de seus desafios centrais: detectores convencionais reduzem progressivamente a resolução espacial ao longo do *backbone*, e a decisão da cabeça de detecção é tomada sobre a representação resultante. Essa perda praticamente não afeta objetos grandes e médios, cujas características sobrevivem à subamostragem, mas é determinante para objetos pequenos, dos quais resta pouca informação nas camadas finais.

O limite inferior de detectabilidade está associado ao passo (*stride*) da camada de detecção mais fina. No YOLOv8, essa camada é a P3, com passo 8, de modo que uma imagem de 640×640 pixels produz uma grade de 80×80 células, cada qual correspondendo a uma região de 8×8 pixels da imagem redimensionada. Um objeto menor que essa região não dispõe de suporte espacial para ser separado do fundo, pois a célula inteira é representada por um único vetor de características. O critério adotado pelo *dataset* COCO classifica como *small* os objetos com área inferior a 32^2 pixels (LIN et al., 2014).

A dificuldade não se restringe à arquitetura: alcança também a métrica de avaliação. Xu et al. (2022) demonstram que a *Intersection over Union* é altamente sensível ao desvio de localização quando o objeto é diminuto. Para um objeto de 5×8 pixels, um pequeno deslocamento da caixa predita reduz a IoU de 0,54 para 0,14; para um objeto de 200×320 pixels, o mesmo deslocamento a reduz apenas de 0,97 para 0,91. Em termos práticos,

quanto menor o objeto, menor a tolerância a erro de localização admitida pela métrica, o que estabelece um teto para o desempenho mensurável independentemente da capacidade do detector de perceber o defeito.

2.2.11 Estudo de Ablação

O estudo de ablação é uma estratégia experimental utilizada para avaliar a contribuição de componentes específicos de um modelo ou *pipeline*. Em redes neurais profundas, esse tipo de estudo consiste em medir o desempenho do modelo após a remoção ou alteração de determinados componentes, permitindo compreender a contribuição relativa desses elementos para o desempenho geral (SHEIKHOLESAMI et al., 2021). Em vez de analisar apenas o desempenho de uma configuração final completa, a ablação compara diferentes versões do experimento, adicionando, removendo ou modificando elementos de forma controlada. Dessa forma, torna-se possível identificar quais componentes efetivamente contribuem para a melhoria do desempenho e quais apresentam impacto reduzido ou dependente do contexto.

Em modelos de detecção de objetos baseados em YOLO, esse tipo de análise é especialmente relevante para avaliar estratégias de treinamento e adaptação de modelos pré-treinados. Liu, Quijano e Crawford (2022) conduziram um estudo de ablação explícito em uma arquitetura YOLOv5 modificada para detecção de objetos pequenos em imagens de UAV com dados limitados, avaliando a contribuição individual de cada componente proposto e demonstrando que a ablação permite identificar quais elementos efetivamente melhoram o desempenho do detector. Dobrzycki, Bernardos e Casar (2025) investigaram sistematicamente diferentes configurações de *transfer learning* em arquiteturas YOLOv8 e YOLOv10, comparando treinamento do zero, *fine-tuning* completo e congelamento parcial de camadas, demonstrando que não há estratégia universalmente superior e que o desempenho depende das características do conjunto de dados. Chen et al. (2024) conduzem ablação explícita sobre três componentes independentes do detector, avaliando sua contribuição individual e combinada sobre o mesmo conjunto de dados, ilustrando como o desenho fatorial permite atribuir ganhos de desempenho a componentes específicos do pipeline. No presente trabalho, o *fine-tuning* será aplicado sem congelamento de camadas, concentrando a análise comparativa nas estratégias de preparação dos dados e pré-processamento.

2.2.12 Validação Cruzada

A validação cruzada é um método de estimação de desempenho que busca reduzir a dependência dos resultados em relação a um particionamento específico dos dados (KOHAVI, 1995). Na variante estratificada em k dobras (*k-fold stratified cross-validation*), o conjunto de dados é dividido em k subconjuntos de tamanho aproximadamente igual, preservando a proporção de classes em cada fold. Em cada uma das k rodadas, um fold

distinto é reservado para avaliação enquanto os demais são utilizados para treinamento. As métricas são reportadas como média e desvio padrão sobre as k rodadas, fornecendo uma estimativa mais estável do que uma única divisão (KOHAVI, 1995). Quando o objetivo não é apenas estimar o desempenho de um modelo, mas comparar configurações entre si, a média sobre as rodadas é insuficiente: ela descarta o pareamento entre configurações que foram avaliadas sobre exatamente as mesmas partições (DEMŠAR, 2006).

Em cenários com baixo volume de dados, essa abordagem é especialmente relevante: com poucos exemplos, um único particionamento pode produzir resultados otimistas ou pessimistas dependendo de quais amostras caem no conjunto de avaliação (KOHAVI, 1995). Wang, Li e Wang (2022) adotaram princípio equivalente em detecção de defeitos industriais com dados escassos, executando experimentos independentes sobre múltiplos grupos de exemplos e reportando a média para reduzir a influência de fatores aleatórios. No presente trabalho, será adotada a variante com $k=5$, mantendo os folds fixos entre todas as configurações experimentais para garantir comparabilidade direta entre as estratégias avaliadas. A escolha de $k=5$ equilibra o tamanho do conjunto de avaliação, com cerca de 16 cartas por fold, com o volume disponível para treinamento em cada rodada, evitando que conjuntos de avaliação excessivamente pequenos introduzam instabilidade nas estimativas (KOHAVI, 1995).

Em cada rodada, o bloco de treinamento será subdividido internamente em um conjunto de treino efetivo e um *validation set*, constituído por aproximadamente 20% das cartas do bloco de treinamento. Esse subconjunto interno é utilizado exclusivamente para monitoramento do critério de parada antecipada (*early stopping*), sem participar da atualização dos pesos do modelo. O fold de avaliação permanece completamente isolado durante todo o treinamento, sendo utilizado apenas para reportar o desempenho final de cada rodada.

2.2.13 Comparação estatística entre configurações

Reportar a média e o desvio padrão de uma métrica sobre as rodadas da validação cruzada descreve o desempenho de uma configuração, mas não é suficiente para afirmar que uma configuração supera outra. Em cenários com baixo volume de dados, a variação entre as rodadas costuma ser maior que a diferença entre as configurações comparadas, de modo que os intervalos definidos pela média e pelo desvio se sobrepõem mesmo quando existe diferença sistemática (DEMŠAR, 2006).

A alternativa é o teste pareado. Quando as mesmas partições são utilizadas em todas as configurações, cada unidade de avaliação é observada uma vez em cada configuração, e a comparação pode ser feita sobre a diferença dentro de cada par. Esse procedimento cancela a dificuldade intrínseca de cada unidade, que é comum a todas as configurações e constitui ruído na comparação.

O teste de Wilcoxon pareado (*Wilcoxon signed-ranks test*) é a alternativa não paramétrica ao teste t pareado. As diferenças observadas em cada par são ordenadas pelo valor absoluto e recebem postos; somam-se separadamente os postos das diferenças positivas (R^+) e das negativas (R^-), e a estatística do teste é $T = \min(R^+, R^-)$, comparada ao valor crítico tabelado para o número de pares. Demšar (2006) recomenda esse teste para a comparação de algoritmos por não pressupor normalidade das diferenças e por ser menos sensível a desempenhos extremos observados em poucas unidades. A recomendação é sustentada por comparação empírica entre quatro estatísticas sobre mil seleções aleatórias de conjuntos de dados, na qual o teste de Wilcoxon apresentou maior poder que as variantes do teste t .

O número de pares condiciona o menor valor-p que o teste pode alcançar. Com n pares existem 2^n arranjos de sinais igualmente prováveis sob a hipótese nula, de modo que o menor valor-p bilateral possível é $2/2^n$. Para $n = 5$ esse limite vale 0,0625, superior ao nível de significância usual de 0,05: com cinco pares o teste não rejeita a hipótese nula ainda que todas as diferenças apontem no mesmo sentido. A escolha da unidade de análise, portanto, condiciona a própria possibilidade de conclusão do experimento.

2.2.14 Métricas de Avaliação

A avaliação de modelos de detecção de objetos requer métricas que considerem simultaneamente a acurácia de classificação e a qualidade de localização espacial (RAMOS; SAPP, 2025). As métricas fundamentais são a Precisão (*Precision*) e a Revocação (*Recall*), definidas respectivamente como:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.1)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.2)$$

onde TP são os verdadeiros positivos, FP os falsos positivos e FN os falsos negativos (RAMOS; SAPP, 2025). A Precisão mede a proporção de detecções corretas entre todas as detecções realizadas, enquanto a Revocação mede a proporção de objetos reais que foram corretamente detectados. O *F1-score* combina ambas as métricas em um único valor por meio da média harmônica (RAMOS; SAPP, 2025):

$$F1 = 2 \cdot \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.3)$$

A métrica principal para avaliação de detectores de objetos é o *mean Average Precision* (mAP), que resume o desempenho do modelo ao calcular a média das precisões médias (*Average Precision* – AP) para cada classe (RAMOS; SAPP, 2025). A AP de uma classe é calculada como a área sob a curva precisão-revocação, que varia conforme o limiar de

confiança das predições. O mAP é então a média das APs sobre todas as classes (RAMOS; SAPP, 2025):

$$\text{mAP} = \frac{1}{N} \sum_{i=1}^N AP_i \quad (2.4)$$

onde N é o número de classes. Duas variantes são frequentemente reportadas na literatura: o mAP@0.5, que utiliza um limiar de IoU de 0,5 para classificar predições como TP, e o mAP@0.5:0.95, que calcula a média sobre múltiplos limiares de IoU entre 0,5 e 0,95 (RAMOS; SAPP, 2025). No presente trabalho, o estudo de ablação utilizará o mAP@0.5 como métrica principal de comparação entre as diferentes configurações experimentais, complementado por Precision, Recall e F1-score para uma análise mais granular do desempenho de cada estratégia.

2.3 Trabalhos correlatos

Os trabalhos relacionados selecionados nesta seção foram escolhidos com base no critério de proximidade com o problema investigado neste TCC, isto é, a detecção de defeitos visuais com apoio de visão computacional em cenários de dados limitados, com aplicação à graduação de cartas colecionáveis. Embora nem todos os trabalhos estejam inseridos exatamente no mesmo domínio, todos enfrentam desafios práticos ou metodológicos muito próximos ao deste estudo, seja no contexto direto de cartas TCG, seja na comparação de estratégias de detecção de defeitos com uso de *transfer learning* e arquiteturas baseadas em YOLO.

2.3.1 Trabalho 1: *Automated corner grading of trading cards: Defect identification and confidence calibration through deep learning*

Nahar et al. (2025a) abordaram o problema da automação da inspeção de defeitos em cartas colecionáveis, com foco específico na graduação de cantos, um dos critérios mais relevantes e subjetivos do processo de avaliação manual. Esse problema é diretamente relacionado ao presente trabalho, pois ambos investigam o uso de visão computacional para apoiar a identificação de defeitos visuais em cartas TCG. Para resolvê-lo, os autores propuseram um modelo baseado em *transfer learning* utilizando a arquitetura DenseNet201 para classificar defeitos em cantos de cartas em quatro níveis de severidade, além de incorporar técnicas de calibração de confiança e um mecanismo de *human-in-the-loop*. Os resultados reportaram acurácia média de 83%, posteriormente elevada para 85% após realimentação com amostras mal classificadas. No entanto, o trabalho apresenta limitações importantes: o estudo está restrito apenas ao critério de cantos, utiliza um conjunto relativamente pequeno de 593 cartas (4.744 imagens de cantos) e não realiza comparação sistemática entre diferentes estratégias de treinamento em cenários de baixo volume de

dados. O presente trabalho diferencia-se por ampliar o foco para a detecção de defeitos visuais em cartas TCG em um cenário explicitamente caracterizado por poucos dados, comparando, por meio de um estudo de ablação, o impacto de diferentes estratégias de treinamento sobre o desempenho do modelo.

2.3.2 Trabalho 2: *NHD-YOLO: Improved YOLOv8 using optimized neck and head for product surface defect detection with data augmentation*

Chen et al. (2024) investigam o problema da detecção de defeitos em superfícies de produtos industriais, propondo melhorias arquiteturais sobre o YOLOv8 combinadas com estratégias específicas de aumento de dados. Assim como no presente trabalho, os autores buscam aprimorar o desempenho de detectores baseados em YOLOv8 para identificação de defeitos em superfícies visualmente complexas. A metodologia proposta introduz modificações nos módulos de *neck* e *head* da arquitetura e emprega uma técnica de aumento de dados baseada em cópia-e-cola seletiva para pequenos objetos. Os experimentos foram conduzidos em três conjuntos de dados: defeitos em aço da Northeastern University (NEU-DET), placas de circuito impresso da Peking University (PKU-Market-PCB) e o dataset COCO. Os resultados indicam que as modificações propostas resultam em ganhos consistentes de acurácia de detecção, com velocidade de inferência e capacidade de generalização preservadas. Apesar da proximidade metodológica com o presente trabalho em termos de arquitetura e uso de aumento de dados, o estudo apresenta limitações para o contexto deste TCC: utiliza datasets de defeitos industriais já estabelecidos, com volumes substanciais de exemplos rotulados, e não avalia o impacto comparativo de estratégias de treinamento em cenários com poucos dados reais. O presente trabalho avança ao concentrar a investigação especificamente nesse cenário restritivo, aplicado ao domínio de cartas colecionáveis, no qual a anotação especializada limita o volume de dados disponível.

2.3.3 Trabalho 3: *A transfer learning-based YOLO network for sewer defect detection in comparison to classic object detection methods*

Situ et al. (2023) trataram do problema da detecção automática de defeitos visuais em um ambiente de inspeção, comparando uma rede YOLO com *transfer learning* contra diferentes métodos clássicos e múltiplos *backbones* pré-treinados. Embora o domínio de aplicação seja distinto, o problema metodológico é muito próximo ao deste TCC: avaliar o impacto de diferentes estratégias e configurações de modelos de detecção em tarefas de defeito visual com limitação prática de dados rotulados. Para isso, os autores utilizaram uma YOLO_v2 associada a 11 CNNs pré-treinadas e a compararam com quatro detectores tradicionais (R-CNN, Fast R-CNN, Faster R-CNN e SSD), medindo precisão de detecção, tempo computacional e IoU. Os resultados mostraram que os métodos baseados em YOLO com *transfer learning* superaram os demais detectores, e que o uso de *transfer learning* foi

necessário para melhorar o desempenho em cenários com dados rotulados limitados ou ambientes desafiadores. A principal limitação do estudo, no entanto, está na distância de domínio em relação ao presente trabalho, já que o experimento foi conduzido com defeitos em redes de esgoto e não em cartas colecionáveis. Ainda assim, o trabalho é altamente relevante por oferecer uma referência metodológica sólida para comparação entre arquiteturas, *backbones* e estratégias de treinamento. O presente trabalho diferencia-se por transferir esse raciocínio comparativo para o domínio específico de cartas Pokémon TCG, com ênfase na análise de defeitos sutis e na avaliação de estratégias em um cenário real de baixo volume de dados.

Uma tabela comparativa ajuda a sintetizar as diferenças entre os trabalhos:

Tabela 2 – Comparação entre trabalhos relacionados

Critério	Nahar2025	Chen2024	Situ2023	Este trabalho
Objetivo	Graduação automática de cantos	Detecção de defeitos em superfícies de produtos	Comparação de YOLO + TL para defeitos	Comparação de estratégias em low-data para cartas TCG
Tecnologia	DenseNet201 + TL + calibração	YOLOv8 modificado + augmentation	YOLO_v2 + 11 CNNs pré-treinadas + TL	YOLOv8 + TL + augmentation + imagens de realce de micro-relevo
Validação	Acurácia e calibração de confiança	mAP em NEU-DET, PKU-PCB e COCO	Precisão, tempo computacional e IoU	Precisão, recall, F1-score e mAP
Limitação	Restrito a cantos e dataset pequeno	Datasets industriais consolidados, sem foco em low-data	Domínio diferente do problema de cartas	Dataset restrito a 82 cartas e a um único modelo (YOLOv8), sem validação em conjuntos externos

Fonte: Elaborado pelo autor (2026)

3 Desenvolvimento / Implementação / Experimentos

Neste capítulo, apresenta-se a metodologia experimental proposta para o desenvolvimento do trabalho no TCC2, bem como o cronograma previsto para a execução das etapas planejadas.

3.1 Metodologia da pesquisa

Esta seção descreve o protocolo metodológico adotado para avaliar as estratégias de treinamento propostas. São apresentados o processo de organização do conjunto de dados, a formulação da tarefa de detecção, o modelo base utilizado, os hiperparâmetros de treinamento, as configurações experimentais avaliadas e o procedimento de comparação dos resultados. O objetivo é garantir que os experimentos sejam conduzidos de forma controlada e comparável, permitindo analisar o impacto individual e combinado das estratégias investigadas.

3.1.1 Visão geral da proposta

A proposta deste trabalho consiste no desenvolvimento de um pipeline experimental para detecção de defeitos visuais em cartas Pokémon TCG utilizando o modelo YOLOv8. O objetivo não é construir um sistema completo de graduação automática, mas avaliar, em um cenário com baixo volume de dados, como diferentes estratégias de treinamento influenciam o desempenho do detector.

O recorte metodológico adotado concentra-se na identificação de defeitos superficiais visíveis na imagem, como riscos, desgastes e pequenas dobras, por serem compatíveis com a formulação do problema como tarefa de detecção de objetos. Critérios de graduação que exigem tratamento geométrico próprio, como centralização, não integram o escopo experimental desta etapa.

A investigação será conduzida sobre um conjunto de 82 cartas fornecido por uma empresa brasileira especializada em graduação. A partir desse conjunto, será construída uma base de experimentação compatível com o formato exigido pelo YOLOv8, permitindo comparar, de forma controlada, diferentes estratégias de treinamento em contexto de dados limitados.

3.1.2 Organização e preparação do conjunto de dados

A primeira etapa do desenvolvimento consistirá na organização e preparação do conjunto de dados. Nessa fase, as imagens serão revisadas quanto à qualidade, padronizadas em nomenclatura e estrutura de diretórios, e convertidas para o formato de anotação compatível com o YOLOv8.

As imagens do conjunto de dados foram capturadas em formato RGB, com 24 bits por pixel, em resoluções heterogêneas: 1280×1771 pixels em 110 imagens, 2560×3540 em 25, 1654×2352 em 23, e seis variações pontuais nas seis imagens restantes. Após o recorte automático descrito nesta seção, a dimensão média do conjunto é de 1447×1997 pixels. Para o treinamento do YOLOv8, as imagens serão redimensionadas para a resolução de entrada do modelo, fixada em 1280×1280 pixels, em vez do valor de 640×640 adotado em trabalhos recentes de *transfer learning* com YOLOv8 (DOBRZYCKI; BERNARDOS; CASAR, 2025). O redimensionamento da imagem de entrada é uma operação de subamostragem, e a perda de informação dela decorrente, pouco relevante para objetos grandes, é determinante para objetos pequenos (CHENG et al., 2023). Liu e Juang (2026) quantificam esse efeito em comparação controlada com YOLOv8: elevar a resolução de entrada de 640 para 1280 produziu ganho de 25% no mAP@0,5, de 12,7% para 15,9%, superando o ganho de 6% obtido pela adição de uma camada de detecção P2 sob condições experimentais idênticas. O valor de 1280×1280 tampouco é arbitrário do ponto de vista arquitetural: corresponde à resolução de entrada da variante P6 do Scaled-YOLOv4 (RAMOS; SAPPA, 2025).

A justificativa específica deste trabalho está na Tabela 3. Em 640×640 , 46,1% das instâncias anotadas apresentam dimensão menor inferior a 8 px, valor correspondente ao passo (*stride*) da camada de detecção P3 do YOLOv8, abaixo do qual o objeto não ocupa mais que uma célula da grade de detecção; em 1280×1280 essa fração é reduzida a 9,2%. O custo é computacional: Liu e Juang (2026) reportam aumento de aproximadamente 300% no número de operações de ponto flutuante e queda da taxa de inferência de cerca de 30 para 8 quadros por segundo, além de exigir redução do tamanho do lote. Como o presente trabalho não possui requisito de operação em tempo real, esse custo é admissível. A viabilidade de 1280×1280 no hardware disponível será verificada nos testes preliminares previstos na Seção 3.2.2, e a mesma resolução será mantida nas quatro configurações experimentais, sob pena de a ablação perder comparabilidade.

Além das imagens RGB convencionais, que preservam a aparência visual original das cartas, também será construída uma representação de realce de micro-relevo a partir dessas imagens. Essa representação é gerada a partir do canal de luminância das imagens RGB originais, com o objetivo de realçar variações locais de textura, relevo e possíveis irregularidades superficiais (CHEN et al., 2021). Três variantes do operador de realce foram comparadas em teste preliminar: gradiente direcional seguido de equalização adaptativa de histograma; equalização adaptativa seguida de gradiente direcional de oito direções, na formulação de Sawada, Fuji e Aikawa (2024); e resposta multiescala aos autovalores

Tabela 3 – Distribuição do tamanho dos defeitos anotados em função da resolução de entrada


	640 × 640	1280 × 1280
<i>Dimensão menor da caixa delimitadora (px)</i>		
Percentil 5	3,55	7,10
Percentil 25	5,69	11,38
Mediana	8,64	17,29
Percentil 75	17,05	34,11
<i>Frações do conjunto</i>		
Abaixo de 8 px (<i>stride</i> da camada P3)	46,1%	9,2%
Exigem erro de localização inferior a 2 px	29,7%	2,7%
Classificadas como <i>small</i> pelo critério COCO	80,4%	59,0%

Medições sobre as 1.038 instâncias anotadas das 164 imagens, após o recorte automático e considerando o redimensionamento proporcional (*letterbox*) aplicado pelo YOLOv8. Fonte: Elaborado pelo autor (2026).

da matriz Hessiana, na formulação de Gruber e Haselmann (2021). O procedimento de seleção e os valores adotados constam da Seção 3.2.2.

A Figura 2 apresenta um exemplo das duas representações disponíveis no conjunto de dados. A imagem RGB convencional será utilizada como representação de referência, enquanto a imagem de realce de micro-relevo será avaliada em uma das configurações do estudo de ablação, permitindo investigar se esse tipo de realce contribui para o desempenho do detector.

Figura 2 – Exemplo de carta do conjunto de dados nas duas representações disponíveis: imagem RGB convencional e imagem de realce de micro-relevo.



(a) Imagem RGB convencional

(b) Imagem de realce de micro-relevo

Fonte: Imagem RGB fornecida por empresa parceira; imagem de realce elaborada pelo autor a partir da imagem original (2026).

Como parte da preparação do conjunto de dados, foi realizada uma análise descritiva do conjunto anotado, cujas caixas delimitadoras derivam dos registros de defeitos fornecidos pela empresa parceira. Das 82 cartas disponíveis, 77 apresentam pelo menos um defeito anotado em ao menos uma das faces (93,9%) e 5 não apresentam anotação em nenhuma das faces (6,1%); outras 19 cartas apresentam uma face limpa e outra com defeito. O conjunto totaliza 164 imagens e 1.038 instâncias anotadas, com média de 6,3 anotações por imagem (mediana 3, máximo 43), e 29 imagens (17,7%) possuem arquivo de anotação vazio, correspondendo a faces sem defeito registrado. Essa distribuição indica forte predominância de exemplos positivos no conjunto, o que favorece o treinamento do detector em termos de representatividade da classe de interesse, mas reforça a necessidade de estratificação cuidadosa nos folds da validação cruzada para preservar essa proporção em cada rodada de treinamento e avaliação (KOHAVI, 1995).

O particionamento será realizado por carta, de modo que a frente e o verso de um mesmo exemplar pertençam sempre ao mesmo subconjunto. Cada configuração experimental utiliza 164 imagens, correspondentes à frente e ao verso das 82 cartas disponíveis. As configurações baseadas em imagens RGB utilizam as representações convencionais, enquanto as configurações de realce utilizam as representações correspondentes. Dado o baixo volume disponível, será adotada validação cruzada estratificada em cinco dobras (*5-fold stratified cross-validation*), mantendo frente e verso da mesma carta sempre no

mesmo fold (KOHAVI, 1995). Em cada rodada, quatro folds (cerca de 66 cartas, 131 imagens) são utilizados para treinamento e um fold (cerca de 16 cartas, 33 imagens) para avaliação, resultando em uma proporção aproximada de 80% para treinamento e 20% para avaliação por rodada. Do bloco de treinamento de cada rodada, aproximadamente 20% das cartas (cerca de 13 cartas, 26 imagens) são separadas aleatoriamente como *validation set* interno, utilizado exclusivamente para monitoramento do *early stopping*, de modo que o treino efetivo ocorre sobre as cerca de 53 cartas restantes (105 imagens). Wang, Li e Wang (2022) adotam princípio equivalente em detecção de defeitos com dados escassos, conduzindo experimentos independentes sobre múltiplos grupos e tomando a média dos resultados para medir o desempenho dos modelos, de modo a reduzir a influência de fatores aleatórios. Neste trabalho, o desempenho de cada configuração será igualmente reportado como média e desvio padrão sobre as cinco rodadas. A comparação estatística entre configurações, contudo, será conduzida sobre o score por carta, conforme a Seção 2.2.13, e não sobre a média das rodadas. O mesmo esquema de folds será mantido fixo em todas as configurações experimentais, garantindo comparabilidade (CHEN et al., 2021).

Figura 3 – Esquema da validação cruzada estratificada em cinco dobras aplicada ao conjunto de 82 cartas. Em cada rodada, quatro folds são utilizados para treinamento e um fold é reservado para avaliação, mantendo frente e verso da mesma carta no mesmo fold. Do bloco de treinamento de cada rodada, aproximadamente 20% das cartas (cerca de 13) são separadas aleatoriamente como *validation set* para monitoramento do *early stopping*, permanecendo o fold de avaliação completamente isolado durante o treinamento.

Validação cruzada em 5 dobras — 88 cartas					
Rodada	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
1	Avaliação	Treino	Treino	Treino	Treino
2	Treino	Avaliação	Treino	Treino	Treino
3	Treino	Treino	Avaliação	Treino	Treino
4	Treino	Treino	Treino	Avaliação	Treino
5	Treino	Treino	Treino	Treino	Avaliação

Treino será feito com aproximadamente 56 cartas
Validação será feita com aproximadamente 14 cartas
Avaliação será feita com aproximadamente 18 cartas

As métricas finais serão reportadas como média e desvio padrão das 5 rodadas.

Fonte: Elaborado pelo autor (2026).

Considerando o baixo volume de dados disponível e a dificuldade associada à anotação

de defeitos pequenos e visualmente sutis em cartas TCG, a modelagem inicial do problema será realizada com uma única classe de interesse, denominada *defeito*. Em inspeção visual, a detecção de defeitos pode envolver informações como categoria, localização, contorno e tamanho da imperfeição (CHEN et al., 2021); no entanto, neste trabalho, opta-se por concentrar a avaliação na localização das regiões defeituosas, sem distinguir inicialmente os tipos específicos de dano.

As anotações do conjunto de dados serão produzidas pelo autor na forma de caixas delimitadoras (*bounding boxes*) compatíveis com o formato YOLOv8, derivadas dos registros de defeitos identificados por avaliadores especializados em graduação de cartas TCG durante o processo de inspeção profissional. Esse tipo de anotação, fundamentada na avaliação de especialistas do domínio com critérios técnicos estabelecidos, é considerado o padrão de referência em tarefas de detecção de defeitos visuais (NAHAR et al., 2025a). A conversão dos registros de defeitos para o formato de detecção de objetos preserva a localização espacial das imperfeições identificadas pelos avaliadores, associando cada região defeituosa à classe única *defeito*.

Essa decisão metodológica reduz a granularidade do problema, evita a fragmentação do conjunto de treinamento em múltiplas classes com poucos exemplos e favorece maior consistência nas anotações. Em inspeção visual automatizada com dados limitados, a redução do número de classes de detecção é uma estratégia reconhecida para preservar a representatividade dos exemplos disponíveis e melhorar a capacidade de generalização do modelo (CHEN et al., 2021). Assim, no presente trabalho, o modelo não terá como objetivo diferenciar categorias como risco, dobra ou desgaste, mas sim identificar regiões da carta que apresentem indícios visuais de defeito.

3.1.3 Critérios de validação

A validação do desempenho do modelo será feita por meio de métricas quantitativas utilizadas em tarefas de detecção de objetos. A métrica principal será o *mean Average Precision* com limiar de IoU de 0,5 (mAP@0.5), por permitir uma visão sintética do desempenho do detector em termos de classificação e localização.

Como métricas complementares, também serão utilizados precisão, *recall* e F1-score, com o objetivo de fornecer uma análise mais detalhada do comportamento do modelo em cada configuração experimental. Em razão do baixo volume de dados, o desempenho de cada configuração será reportado como média e desvio padrão sobre as cinco rodadas da validação cruzada (KOHAVI, 1995; WANG; LI; WANG, 2022), e a comparação entre as estratégias será conduzida por teste de Wilcoxon pareado sobre o escore por carta, conforme a Seção 2.2.13. A comparação entre os experimentos buscará identificar quais estratégias produzem ganhos mais consistentes no cenário de dados limitados considerado neste trabalho.

3.2 Detalhes da implementação

3.2.1 Modelo base

Como modelo de detecção será utilizada a versão YOLOv8, selecionada por seu equilíbrio entre eficiência computacional e desempenho em tarefas de detecção de objetos. Considerando que o conjunto de dados disponível é reduzido e que a classe de interesse, denominada *defeito*, não faz parte das classes originais do dataset COCO, todas as configurações experimentais partirão de pesos pré-treinados e serão ajustadas ao domínio das cartas por meio de *fine-tuning*.

Neste trabalho, a configuração base (*baseline*) corresponderá ao YOLOv8 com *transfer learning* treinado sobre as imagens RGB convencionais, sem aumento de dados adicional e sem uso das imagens de realce de micro-relevô. Essa configuração servirá como referência para avaliar a contribuição individual e combinada do aumento de dados.

Entre as variantes disponíveis do YOLOv8, todas pré-treinadas no dataset COCO (LIN et al., 2014), este trabalho adotará a versão *small* (YOLOv8s), com aproximadamente 11 milhões de parâmetros. Essa escolha é motivada pela relação entre capacidade de representação e volume de dados disponível por fold: variantes maiores possuem dezenas de milhões de parâmetros adicionais que, com cerca de 53 cartas de treinamento por rodada, aumentariam o risco de *overfitting* mesmo com *transfer learning*. Wang, Li e Wang (2022) demonstram, em contexto análogo de detecção de defeitos industriais com dados escassos, que modelos com maior número de parâmetros apresentam desempenho inferior a arquiteturas mais simples justamente por esse motivo. Dobrzycki, Bernardos e Casar (2025) corroboram essa decisão ao verificar que, em cenários com dados limitados, variantes menores do YOLOv8 oferecem melhor equilíbrio entre desempenho e custo computacional do que variantes maiores. A adequação final da variante será confirmada nos testes preliminares previstos na Seção 3.2.2, nos quais YOLOv8n será avaliado como alternativa caso YOLOv8s apresente sinais de *overfitting*.

Os demais experimentos partirão dessa configuração de referência e incorporarão novas estratégias de forma controlada. Para garantir comparabilidade entre os resultados, serão mantidos fixos, entre as configurações, parâmetros como resolução de entrada, taxa de aprendizado, tamanho do lote, número máximo de épocas e critério de parada antecipada. Assim, embora o número efetivo de épocas possa variar entre os experimentos em função do *early stopping*, todas as configurações serão submetidas ao mesmo limite máximo de treinamento e à mesma regra de interrupção. Esses valores serão definidos em testes preliminares antes da execução do estudo de ablação.

3.2.2 Hiperparâmetros de treinamento

Os hiperparâmetros de treinamento compreendem as configurações do processo de otimização que não são aprendidas automaticamente pelo modelo, sendo definidas pelo pesquisador antes do início do treinamento (DOBRZYCKI; BERNARDOS; CASAR, 2025). No presente trabalho, os principais hiperparâmetros considerados são: taxa de aprendizado (*learning rate*), número de épocas, tamanho do lote (*batch size*), resolução de entrada das imagens e critério de parada antecipada (*early stopping*).

Os valores finais desses hiperparâmetros serão estabelecidos por meio de testes preliminares realizados sobre a configuração base antes da execução do estudo de ablação. Uma vez definidos, os mesmos valores serão mantidos fixos em todas as quatro configurações experimentais. Essa decisão é essencial para garantir que as diferenças de desempenho observadas entre as configurações sejam atribuíveis exclusivamente às estratégias avaliadas, como o tipo de imagem e o uso de aumento de dados, e não a variações no processo de otimização (DOBRZYCKI; BERNARDOS; CASAR, 2025).

O critério de parada antecipada será configurado para monitorar o mAP@0.5 em um subconjunto de validação interno (*validation set*), constituído por aproximadamente 20% das cartas do bloco de treinamento de cada rodada, correspondendo a cerca de 13 cartas (26 imagens). Esse subconjunto é distinto do fold de avaliação, que permanece completamente isolado durante o treinamento e é utilizado exclusivamente para reportar o desempenho final de cada configuração experimental. A paciência foi estabelecida nos testes preliminares. Prechelt (1998), ao avaliar critérios de parada sobre 1296 execuções de treinamento, observa que curvas reais de erro de validação quase sempre apresentam mais de um mínimo local e que critérios mais lentos elevam de aproximadamente 60% para aproximadamente 80% a probabilidade de a execução terminar com o melhor resultado que ela própria alcançou, ao custo de cerca de quatro vezes mais tempo de treinamento. O autor recomenda critérios rápidos, salvo quando o ganho reduzido compensa o aumento expressivo de tempo.

Neste trabalho a compensação se justifica por duas razões. A primeira é de custo: mesmo quadruplicado, o tempo total das execuções permanece viável no cronograma. A segunda decorre do desenho experimental adotado. Prechelt (1998) analisa o treinamento de um modelo isolado, situação em que a escolha subótima do ponto de parada afeta apenas aquele resultado. Aqui, quatro configurações são comparadas entre si por teste pareado, de modo que a incerteza na seleção do ponto de parada se converte em variância dentro da própria comparação, reduzindo a capacidade do teste de identificar diferenças reais entre as configurações. Adota-se, portanto, paciência de 100 épocas, com teto de 300, mantida fixa em todas as quatro configurações experimentais para garantir comparabilidade entre os resultados.

Registra-se como limitação que o subconjunto de validação interno é reduzido e que a estimativa de mAP obtida sobre ele apresenta variabilidade elevada entre épocas conse-

cutivas. Prechelt (1998) observa que o sobreajuste pode passar despercebido justamente porque o conjunto de validação é finito e, portanto, não perfeitamente representativo do problema. Essa variabilidade não introduz viés no desempenho reportado, uma vez que o *fold* de avaliação permanece isolado do treinamento e da seleção do ponto de parada, mas contribui para a variância das comparações.

Como ponto de partida para os testes preliminares, serão adotados os valores padrão recomendados pela biblioteca Ultralytics para o YOLOv8 no que se refere aos hiperparâmetros de otimização, ajustando-os conforme necessário para o tamanho reduzido do conjunto de dados disponível. Os hiperparâmetros de aumento de dados constituem exceção e não partem dos valores padrão: por definirem uma das variáveis independentes do estudo de ablação, são especificados explicitamente para cada configuração na Seção 3.3. Adicionalmente, os testes preliminares contemplarão a validação da variante do modelo, avaliando YOLOv8n como alternativa a YOLOv8s caso sejam observados sinais de *overfitting*, bem como a definição dos parâmetros do pipeline de realce de micro-relevo. Esses parâmetros incluem o *clipLimit* (valor de referência: 3,0) e o *tileGridSize* (8×8 pixels) do CLAHE, o tamanho do núcleo do operador de gradiente e as escalas do operador de segunda ordem. A escolha entre as três variantes de realce descritas na Seção 3.1.2 também foi resolvida nessa etapa, adotando-se como critério o desempenho no *fold* de avaliação de uma mesma dobra, sob protocolo idêntico ao das demais configurações. Todos os valores definidos nessa etapa serão mantidos fixos entre as quatro configurações experimentais, garantindo que as diferenças de desempenho observadas sejam atribuíveis exclusivamente às estratégias avaliadas.

3.2.3 Tecnologias e ferramentas

A implementação será realizada em Python. Para o treinamento do modelo, será utilizada a biblioteca oficial da família YOLOv8. O processamento das imagens e as etapas de preparação do conjunto de dados poderão ser apoiados por bibliotecas de manipulação de imagens e visão computacional, como OpenCV. Para a aplicação de transformações de aumento de dados, poderão ser utilizadas bibliotecas específicas de *augmentation*, desde que compatíveis com o pipeline definido.

Os experimentos serão executados em ambiente computacional com suporte a GPU, de modo a reduzir o tempo de treinamento e viabilizar a execução das diferentes configurações previstas no estudo de ablação.

3.3 Experimentos e cenário de testes

3.3.1 Estratégias de treinamento avaliadas

O trabalho comparará quatro configurações experimentais baseadas em YOLOv8 com *transfer learning*, variando de forma controlada duas estratégias: o uso de aumento de dados (*data augmentation*) e o tipo de representação visual da entrada, que pode ser a imagem RGB convencional ou a imagem de realce de micro-relevo gerada. Esse desenho permite avaliar a contribuição individual e combinada de cada estratégia no desempenho do detector em um cenário com baixo volume de dados.

O *transfer learning* será empregado em todas as configurações por meio do ajuste fino (*fine-tuning*) de pesos pré-treinados, buscando aproveitar representações visuais previamente aprendidas em bases de larga escala. Essa decisão é justificada pelo baixo volume de dados disponível e pela necessidade de adaptar o detector à classe de interesse *defeito*, inexistente nas classes originais do COCO. Dessa forma, o *transfer learning* não será tratado como uma variável comparativa isolada no estudo de ablação, mas como a base comum de treinamento sobre a qual serão avaliados o aumento de dados e o uso de imagens de realce de micro-relevo.

O aumento de dados será utilizado para ampliar artificialmente a variabilidade do conjunto de treinamento. Para a representação RGB, serão aplicadas transformações geométricas (flip horizontal, rotação de até $\pm 10^\circ$) e fotométricas (variação de brilho e saturação). Para a representação de realce, serão utilizadas apenas transformações geométricas, uma vez que o realce já incorpora normalização de contraste local por CLAHE, tornando inconsistente a aplicação de variações artificiais de brilho ou contraste.

A biblioteca Ultralytics aplica, por padrão, sete transformações de aumento de dados no treinamento de detectores: o mosaico (**mosaic**), a variação de escala (**scale**), a translação (**translate**), o espelhamento horizontal (**fliplr**) e as três variações no espaço HSV (**hsv_h**, **hsv_s** e **hsv_v**) (JOCHER; CHAURASIA; QIU, 2023). Em decorrência disso, a ausência de aumento de dados nas Configurações 1 e 3 não decorre da omissão desses parâmetros, mas exige o seu desligamento explícito. Executadas a partir dos valores padrão, tais configurações receberiam transformações em maior número e de maior intensidade do que as descritas para as Configurações 2 e 4, invertendo o sentido do fator investigado no estudo de ablação. Os parâmetros de aumento de dados são, por conseguinte, especificados individualmente para cada configuração, conforme a Tabela 4.

Dois parâmetros afastam-se do valor padrão em todas as configurações, inclusive naquelas com aumento de dados. O mosaico combina quatro imagens em uma única imagem de treinamento (RAMOS; SAPPA, 2025), de modo que cada uma passa a ocupar aproximadamente metade de sua dimensão linear original; a variação de escala, no valor padrão de 0,5, admite reduções da mesma ordem. Conforme a Tabela 3, a mediana da dimensão menor das instâncias anotadas é de 17,29 px em 1280×1280 e o percentil 25

Tabela 4 – Parâmetros de aumento de dados por configuração experimental

Parâmetro	Padrão	Cfg. 1 e 3	Cfg. 2	Cfg. 4	Motivo do desvio
hsv_h	0,015	0,0	0,015	0,0	Cfg. 4: realce já normalizado por CLAHE
hsv_s	0,7	0,0	0,7	0,0	idem
hsv_v	0,4	0,0	0,4	0,0	idem
degrees	0,0	0,0	10,0	10,0	rotação prevista na estratégia
translate	0,1	0,0	0,1	0,1	padrão mantido
fliplr	0,5	0,0	0,5	0,5	padrão mantido
mosaic	1,0	0,0	0,0	0,0	reduz cada imagem à metade da dimensão linear
scale	0,5	0,0	0,0	0,0	admite redução de até a metade
shear, perspective, flipud, bgr, mixup, cutmix e copy_paste permanecem em 0,0 em todas as configurações, valor que já corresponde ao padrão da biblioteca.					

As transformações mantidas conservam o valor padrão da biblioteca; os desvios estão justificados na última coluna. Fonte: Elaborado pelo autor (2026).

é de 11,38 px; uma redução à metade levaria esses valores a 8,6 px e 5,7 px, isto é, ao limiar do passo da camada P3 ou abaixo dele. Ambas as transformações deslocariam parte substancial do conjunto anotado para a faixa em que o detector não dispõe de suporte espacial para separar o objeto do fundo, contrariando a decisão de elevar a resolução de entrada justamente para retirá-lo dessa faixa. A exclusão é consistente com a observação de [Chen et al. \(2024\)](#) de que o conjunto de transformações de aumento de dados do YOLOv8 não contempla as particularidades de objetos pequenos.

Os demais parâmetros conservam o valor padrão da biblioteca nas configurações com aumento de dados, de modo que as magnitudes adotadas não constituem escolha arbitrária deste trabalho. Todos os valores da Tabela 4 permanecem fixos ao longo dos cinco folds de cada configuração. O aumento de dados é aplicado exclusivamente ao subconjunto de treinamento de cada rodada, no momento do carregamento das imagens, e nunca antes do particionamento dos folds, de modo que versões transformadas de uma mesma carta não possam aparecer simultaneamente no conjunto de treinamento e no de avaliação.

Já o uso das imagens de realce de micro-relevo será avaliado como uma representação alternativa de entrada, com o objetivo de verificar se o realce de textura, relevo e irregularidades superficiais contribui para a detecção de defeitos visuais. Essas imagens são geradas a partir do canal de luminância das imagens originais, utilizando a biblioteca OpenCV. O operador de realce foi definido entre três variantes comparadas em teste preliminar, conforme a Seção 3.1.2. O CLAHE, comum às três variantes, é configurado com *clipLimit* de 3,0 e *tileGridSize* de 8×8 pixels, valores de referência adotados como ponto de partida nos testes preliminares previstos na Seção 3.2.2, nos quais serão avaliados empiricamente e mantidos fixos entre todas as configurações experimentais após definição.

3.3.2 Estudo de ablação

A comparação entre as estratégias será realizada por meio de um estudo de ablação com desenho fatorial. Nesse tipo de desenho, duas variáveis independentes, o uso de aumento de dados e o tipo de representação visual da entrada são combinadas de forma controlada, permitindo avaliar a contribuição individual e conjunta de cada estratégia no desempenho do detector.

Serão consideradas quatro configurações experimentais:

1. YOLOv8 com *transfer learning* em imagens RGB;
2. YOLOv8 com *transfer learning* e aumento de dados em imagens RGB;
3. YOLOv8 com *transfer learning* em imagens de realce de micro-relevo;
4. YOLOv8 com *transfer learning* e aumento de dados em imagens de realce de micro-relevo.

A configuração 1 serve como referência do estudo de ablação, correspondendo ao cenário mais simples: fine-tuning com imagens RGB sem aumento de dados. As demais configurações introduzem variações controladas sobre essa referência, mantendo fixos os hiperparâmetros de treinamento em todas as configurações para garantir que as diferenças de desempenho observadas sejam atribuíveis exclusivamente às estratégias avaliadas.

Os folds serão definidos uma única vez sobre as 82 cartas e mantidos fixos entre todas as configurações, de modo que cada configuração seja avaliada exatamente sobre as mesmas partições. Essa propriedade viabiliza a comparação pareada: cada carta é avaliada uma única vez em cada configuração, o que produz 82 pares por comparação. A comparação entre as quatro estratégias será feita por teste de Wilcoxon pareado sobre o score por carta (DEMŠAR, 2006), permanecendo o mAP@0.5 médio e o desvio padrão sobre as cinco rodadas como caracterização descritiva dos resultados (KOHAVI, 1995).

Esse desenho foi escolhido por ser compatível com o escopo do TCC1 e por permitir uma análise clara da influência de cada estratégia em um contexto de baixo volume de dados. Em vez de comparar múltiplas arquiteturas, a proposta fixa o modelo YOLOv8 e concentra a investigação naquilo que constitui a contribuição principal do trabalho: a comparação entre estratégias de treinamento.

3.4 Resultados e análises

4 Conclusão

4.1 Retomada do problema e dos objetivos

4.2 Contribuições para a Computação

4.3 Limitações e trabalhos futuros

Referências

- Business Research Insights. *Collectible Card Game Market Size, Share, Growth, Trends, Global Industry Analysis*. 2026. Acesso em: 15 mar. 2026. Disponível em: <<https://www.businessresearchinsights.com/market-reports/collectible-card-game-market-101837>>. 11, 21
- CHEN, F. et al. NHD-YOLO: Improved YOLOv8 using optimized neck and head for product surface defect detection with data augmentation. *IET Image Processing*, v. 18, n. 7, p. 1915–1926, 2024. 29, 31, 35, 47
- CHEN, Y. et al. Surface defect detection methods for industrial products: A review. *Applied Sciences*, v. 11, n. 16, p. 7657, 2021. 17, 18, 24, 28, 29, 38, 41, 42
- CHENG, G. et al. Towards large-scale small object detection: Survey and benchmarks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 45, n. 11, p. 13467–13488, 2023. 30, 38
- DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, v. 7, p. 1–30, 2006. Disponível em: <<https://www.jmlr.org/papers/v7/demsar06a.html>>. 20, 32, 33, 48
- DOBRZYCKI, A. D.; BERNARDOS, A. M.; CASAR, J. R. An analysis of layer-freezing strategies for enhanced transfer learning in YOLO architectures. *Mathematics*, v. 13, n. 15, p. 2539, 2025. 26, 27, 28, 31, 38, 43, 44
- GRUBER, D. P.; HASELMANN, M. Inspection of transparent objects with varying light scattering using a Frangi filter. *Journal of Imaging*, v. 7, n. 2, p. 27, 2021. 30, 39
- HUSSAIN, M. YOLO-v1 to YOLO-v8, the rise of YOLO and its complementary nature toward digital manufacturing and industrial defect detection. *Machines*, v. 11, n. 7, p. 677, 2023. 13, 21, 22, 24, 25, 26
- JIANG, S. et al. Automatic detection of surface defects on underwater pile-pier of bridges based on image fusion and deep learning. *Structural Control and Health Monitoring*, v. 2023, p. 8429099, 2023. 13, 29
- JOCHER, G.; CHAURASIA, A.; QIU, J. *Ultralytics YOLO*. 2023. <<https://github.com/ultralytics/ultralytics>>. Versão 8. Documentação e código-fonte. Acesso em: 2 set. 2026. 46
- KIM, M.-G.; OKWUOSA, C. N.; HUR, J.-W. Scan path optimization and YOLO-based detection for defect inspection of curved and glossy surfaces. *Sensors*, v. 26, n. 10, p. 3026, 2026. 13
- KOHAVI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: *Proceedings of the Fourteenth International Joint Conference on Artificial Intelligence (IJCAI-95)*. Montreal, Quebec, Canada: Morgan Kaufmann, 1995. v. 2, p. 1137–1143. Disponível em: <<https://www.ijcai.org/Proceedings/95-2/Papers/016.pdf>>. 20, 31, 32, 40, 41, 42, 48

- LIN, T.-Y. et al. Microsoft COCO: Common objects in context. In: FLEET, D. et al. (Ed.). *Computer Vision – ECCV 2014*. Cham: Springer, 2014. (Lecture Notes in Computer Science, v. 8693), p. 740–755. [20](#), [26](#), [30](#), [43](#)
- LIU, C.-M.; JUANG, J.-C. Systematic evaluation of YOLOv8 variants for UAV-based object detection. *Applied Sciences*, v. 16, n. 7, p. 3559, 2026. [38](#)
- LIU, W.; QUIJANO, K.; CRAWFORD, M. M. YOLOv5-Tassel: Detecting tassels in RGB UAV imagery with improved YOLOv5 based on transfer learning. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, v. 15, p. 8085–8094, 2022. [31](#)
- NAHAR, L. et al. Automated corner grading of trading cards: Defect identification and confidence calibration through deep learning. *Computers in Industry*, v. 164, p. 104187, 2025. [11](#), [12](#), [13](#), [14](#), [17](#), [18](#), [23](#), [24](#), [28](#), [34](#), [42](#)
- NAHAR, L. et al. An integrated deep learning framework for trading card grading: Design, deployment, and evaluation. In: *2025 IEEE International Conference on Big Data (BigData)*. [S.l.]: IEEE, 2025. p. 2609–2615. [11](#), [12](#), [14](#), [17](#)
- PRECHELT, L. Early stopping - but when? In: ORR, G. B.; MÜLLER, K.-R. (Ed.). *Neural Networks: Tricks of the Trade*. Berlin, Heidelberg: Springer, 1998, (Lecture Notes in Computer Science, v. 1524). p. 55–69. [21](#), [44](#), [45](#)
- RAMOS, L. T.; SAPPA, A. D. A decade of you only look once (YOLO) for object detection: A review. *IEEE Access*, v. 13, p. 192747–192794, 2025. [13](#), [25](#), [26](#), [28](#), [33](#), [34](#), [38](#), [46](#)
- SAWADA, M.; FUJI, Y.; AIKAWA, N. Improving classification accuracy in paint surface inspection using image processing and deep learning. In: *2024 IEEE 67th International Midwest Symposium on Circuits and Systems (MWSCAS)*. Springfield, MA, USA: IEEE, 2024. p. 707–711. [13](#), [29](#), [38](#)
- SHEIKHOLESAMI, S. et al. AutoAblation: Automated parallel ablation studies for deep learning. In: *Proceedings of the 1st Workshop on Machine Learning and Systems (EuroMLSys '21)*. New York, NY, USA: ACM, 2021. p. 55–61. [31](#)
- SHEN, Q.; WEI, C. Business model innovation in the trading card grading industry: Cross-national insights from Pokémon trading card game and non-fungible tokens. *American Journal of Business Science Philosophy*, v. 2, n. 2, p. 217–234, 2025. [11](#)
- SITU, Z. et al. A transfer learning-based YOLO network for sewer defect detection in comparison to classic object detection methods. *Developments in the Built Environment*, v. 15, p. 100191, 2023. [12](#), [18](#), [25](#), [26](#), [27](#), [28](#), [29](#), [35](#)
- WANG, H.; LI, Z.; WANG, H. Few-shot steel surface defect detection. *IEEE Transactions on Instrumentation and Measurement*, v. 71, p. 1–12, 2022. Art. no. 5003912. [17](#), [28](#), [32](#), [41](#), [42](#), [43](#)
- XU, C. et al. Detecting tiny objects in aerial images: A normalized Wasserstein distance and a new benchmark. *ISPRS Journal of Photogrammetry and Remote Sensing*, v. 190, p. 79–93, 2022. [30](#)

ZHANG, Y. et al. Research on oriented surface defect detection in the aircraft skin-coating process based on an attention detector. *IET Image Processing*, v. 18, n. 5, p. 1213–1228, 2024. [24](#)


ZHENG, X. et al. Recent advances in surface defect inspection of industrial products using deep learning techniques. *The International Journal of Advanced Manufacturing Technology*, v. 113, n. 1-2, p. 35–58, 2021. [11](#), [13](#), [21](#), [22](#), [24](#), [29](#)

Apêndices

APÊNDICE A – Cronograma previsto no TCC1

O cronograma de trabalho organiza as principais atividades previstas para o desenvolvimento do TCC2, contemplando desde a preparação final do conjunto de dados até a execução dos experimentos, análise dos resultados e redação da versão final do trabalho. As etapas foram distribuídas de forma sequencial, considerando a dependência entre a organização dos dados, o treinamento dos modelos, a comparação das configurações experimentais e a consolidação dos resultados obtidos.

Figura 4 – Cronograma de atividades do TCC2 para o segundo semestre de 2026 – Diagrama de Gantt



Fonte: Elaborado pelo autor (2026)