Matheus da Silva Marini

Avaliação de estratégias de treinamento com YOLOv8 para detecção de defeitos pequenos em cartas Pokémon TCG com baixo volume de dados

São Paulo
2026

Matheus da Silva Marini

Avaliação de estratégias de treinamento com YOLOv8 para detecção de defeitos pequenos em cartas Pokémon TCG com baixo volume de dados

Trabalho de Conclusão de Curso II apresentado ao SENAC Santo Amaro como requisito parcial para conclusão do curso de Ciência da Computação.

SENAC – Serviço Nacional de Aprendizagem Comercial
Unidade Santo Amaro
Curso de Ciência da Computação

Orientador: Prof. Afonso César Lelis Brandão

São Paulo
2026

Resumo

Este trabalho avaliou o impacto de diferentes estratégias de treinamento aplicadas ao YOLOv8 na detecção de defeitos superficiais em cartas Pokémon TCG (*Trading Card Game*). O objetivo foi identificar quais combinações apresentam melhor desempenho com um conjunto limitado de imagens. A escolha do tema baseou-se na escassez de estudos que avaliam sistematicamente essas estratégias no domínio de cartas colecionáveis. Nesse domínio, a graduação avalia a condição física de cada exemplar, mas a inspeção manual é lenta e sujeita à subjetividade do avaliador. Essas limitações motivam a sua automação por visão computacional. A anotação de defeitos, porém, é cara, e a busca bibliográfica realizada não identificou conjuntos de dados públicos de cartas Pokémon TCG com defeitos localizados. Nos experimentos, o modelo partiu de um YOLOv8s com *transfer learning* a partir de pesos pré-treinados no conjunto público de imagens COCO. Quatro configurações cruzaram o uso ou não de aumento de dados com duas representações de entrada: imagens RGB convencionais e imagens de realce de micro-relevo. Sobre a configuração de melhor desempenho, avaliou-se o efeito de uma cabeça de detecção adicional para objetos pequenos (P2) e da resolução de entrada. O conjunto de dados reuniu 206 cartas, 412 imagens e 4.808 anotações, parte delas sugerida por modelos de uma etapa preliminar e validada pelo autor. O desempenho foi medido pelo mAP@0,5, pela precisão, pela revocação e pelo F1, em validação cruzada com cinco dobras. O F1 dá uma única nota por carta, o que permitiu comparar as configurações carta a carta pelo teste de Wilcoxon pareado, com correção de Holm. O aumento de dados melhorou o detector: a Configuração 2, com imagens RGB e aumento de dados, obteve o melhor desempenho, com F1 por carta de 0,376, contra 0,332 da mesma configuração sem aumento de dados. O realce de micro-relevo foi inferior ao RGB quando não havia aumento de dados. Com aumento de dados, essa diferença desapareceu quando a avaliação desconsiderou as anotações sugeridas por esses modelos. A cabeça P2 apresentou desempenho inferior à configuração vencedora, com a mesma revocação e menor precisão. Essa variante não partiu de pesos pré-treinados na cabeça de detecção nem em parte das camadas intermediárias, e por isso o efeito isolado da cabeça P2 não pôde ser separado da ausência de pré-treino. Em uma dobra avaliada (45 cartas), aumentar a resolução de entrada de 640 para 1280 pixels elevou o mAP@0,5 de 0,156 para 0,309 e o F1 por carta de 0,266 para 0,399; esta última diferença foi confirmada pelo teste de Wilcoxon pareado. Uma curva de aprendizado com intervalo de confiança por *bootstrap*, em duas dobras, mostrou que o desempenho ainda não havia estabilizado com o volume de dados disponível. A evidência do aumento de dados vem de cinco dobras, e a da resolução de entrada, de uma só. Por isso, com poucos dados, o aumento de dados melhorou o detector nas duas representações de entrada, e a maior resolução de entrada também o melhorou, mas com evidência mais limitada. O realce de micro-relevo não trouxe ganho.

Palavras-chave: Visão Computacional. Detecção de Defeitos. Pokémon TCG. Conjuntos de Dados Reduzidos. YOLOv8. Realce de Micro-Relevo.

Abstract

This work evaluated the impact of different training strategies applied to YOLOv8 on the detection of surface defects in Pokémon TCG (*Trading Card Game*) cards. The objective was to identify which combinations perform best with a limited set of images. The choice of topic was based on the scarcity of studies that systematically evaluate these strategies in the domain of collectible cards. In this domain, grading assesses the physical condition of each item, but manual inspection is slow and subject to the evaluator's subjectivity. These limitations motivate its automation through computer vision. Defect annotation, however, is expensive, and the bibliographic search carried out did not identify public datasets of Pokémon TCG cards with localized defects. In the experiments, the model started from a YOLOv8s with *transfer learning* from weights pre-trained on the public COCO image dataset. Four configurations crossed the use or not of data augmentation with two input representations: conventional RGB images and micro-relief enhancement images. On top of the best-performing configuration, the effect of an additional detection head for small objects (P2) and of the input resolution was also evaluated. The dataset comprised 206 cards, 412 images, and 4,808 annotations, part of them suggested by models from a preliminary stage and validated by the author. Performance was measured by mAP@0.5, precision, recall and F1, in five-fold cross-validation. F1 gives a single score per card, which allowed the configurations to be compared card by card using a paired Wilcoxon test with Holm correction. Data augmentation improved the detector: Configuration 2, with RGB images and data augmentation, achieved the best performance, with a per-card F1 of 0.376, against 0.332 for the same configuration without data augmentation. Micro-relief enhancement was inferior to RGB when there was no data augmentation. With data augmentation, this difference disappeared when the evaluation disregarded the annotations suggested by these models. The P2 head presented lower performance than the winning configuration, with the same recall and lower precision. This variant did not start from pre-trained weights in the detection head or in part of the intermediate layers, so the isolated effect of the P2 head could not be separated from the lack of pre-training. In one evaluated fold (45 cards), increasing the input resolution from 640 to 1280 pixels raised mAP@0.5 from 0.156 to 0.309 and the per-card F1 from 0.266 to 0.399; the latter difference was confirmed by the paired Wilcoxon test. A learning curve with a bootstrap confidence interval, over two folds, showed that performance had not yet stabilized with the available data volume. The evidence for data augmentation comes from five folds, and that for input resolution from only one. Therefore, with limited data, data augmentation improved the detector in both input representations, and higher input resolution also improved it, but with more limited evidence. Micro-relief enhancement brought no gain.

Keywords: Computer Vision. Defect Detection. Pokémon TCG. Small Datasets. YOLOv8. Micro-Relief Enhancement.

Lista de ilustrações

Figura 1 – Critérios de avaliação no processo de graduação de cartas TCG: cantos, bordas, superfície e centralização, ilustrados sobre carta do conjunto de dados. 24
Figura 2 – Blocos resumidos por um ponto nos níveis P2 a P5, sobre um defeito do conjunto de dados, na imagem de entrada de 640 pixels. 29
Figura 3 – O mesmo defeito na imagem de entrada de 640 e de 1280 pixels, com a grade de 8 pixels do nível P3 sobre a mesma região da carta. 36
Figura 4 – Esquema da validação cruzada estratificada em cinco dobras aplicada às 206 cartas. Em cada rodada, uma dobra é reservada para avaliação, e as outras quatro formam o bloco de treinamento, do qual cerca de 20% das cartas são separadas como validação interna; a frente e o verso de cada carta, assim como as cartas de mesma ilustração, ficam sempre na mesma dobra. 51
Figura 5 – Carta do conjunto de dados em RGB e na variante de realce de micro-relevo adotada nas Configurações 3 e 4 63
Figura 6 – Cronograma de atividades do TCC2 para o segundo semestre de 2026 – Diagrama de Gantt 72

Lista de tabelas

Tabela 1 – Strings de busca utilizadas na pesquisa bibliográfica 19
Tabela 2 – Comparação entre os trabalhos relacionados e este trabalho 43
Tabela 3 – Distribuição do tamanho dos defeitos anotados em função da resolução de entrada 50
Tabela 4 – Plano de experimentação 55
Tabela 5 – Parâmetros de aumento de dados por configuração 59

Lista de Abreviaturas e Siglas

A lista a seguir reúne, em ordem alfabética, as abreviaturas e siglas utilizadas neste trabalho, acompanhadas de seus respectivos significados.

Abreviatura/Sigla	Significado
ACE	*Automatic Color Equalization* (Equalização Automática de Cor)
AMD	*Advanced Micro Devices* (fabricante da placa de vídeo usada nos experimentos)
AP	*Average Precision* (Precisão Média)
AVI	*Automated Visual Inspection* (Inspeção Visual Automatizada)
C2f	*Cross Stage Partial Bottleneck with two Convolutions* (módulo convolucional do YOLOv8)
CIELAB	Espaço de cor definido pela *Commission Internationale de l'Éclairage*, com um canal de luminosidade (L^*) e dois de cor (a^*, b^*)
CLAHE	*Contrast Limited Adaptive Histogram Equalization*
CNN	*Convolutional Neural Network* (Rede Neural Convolucional)
COCO	*Common Objects in Context*
FN	*False Negative* (Falso Negativo)
FP	*False Positive* (Falso Positivo)
FPN	*Feature Pyramid Network* (Rede de Pirâmide de Características)
GPU	*Graphics Processing Unit* (Unidade de Processamento Gráfico)
HSV	*Hue, Saturation, Value* (Matiz, Saturação, Valor)
IoU	*Intersection over Union*
mAP	*mean Average Precision* (Média das Precisões Médias)
P1–P5	Níveis da pirâmide de características do YOLOv8, numerados pela etapa de redução da imagem; no nível Pk, o passo é de 2^k pixels (P1 = passo 2 a P5 = passo 32)
PANet	*Path Aggregation Network*
PSA	*Professional Sports Authenticator*
R-CNN	*Region-based Convolutional Neural Network* (Rede Neural Convolucional Baseada em Regiões)
RGB	*Red, Green, Blue*
ROCm	*Radeon Open Compute* (plataforma da AMD para executar computação em placas de vídeo)
SENAC	Serviço Nacional de Aprendizagem Comercial
TCC	Trabalho de Conclusão de Curso
TCG	*Trading Card Game* (Jogo de Cartas Colecionáveis)
TL	*Transfer Learning*
TP	*True Positive* (Verdadeiro Positivo)

Sumário

1 INTRODUÇÃO . . . 11
1.1 Contextualização do problema . . . 12
1.2 Formulação do problema . . . 14
1.3 Objetivos e hipótese . . . 15
1.3.1 Objetivo geral . . . 15
1.3.2 Objetivos específicos . . . 15
1.3.3 Hipótese ou critério de validação . . . 16
1.4 Justificativa . . . 17

2 REVISÃO BIBLIOGRÁFICA / TRABALHOS RELACIONADOS . . 19
2.1 Metodologia da pesquisa bibliográfica . . . 19
2.2 Fundamentos teóricos . . . 21
2.2.1 Deep Learning e Redes Neurais Convolucionais . . . 22
2.2.2 Visão Computacional e Inspeção Visual Automatizada . . . 22
2.2.3 Defeitos visuais em cartas colecionáveis . . . 23
2.2.4 Detecção de Objetos . . . 25
2.2.5 Métricas de Avaliação . . . 26
2.2.6 Arquitetura YOLO . . . 27
2.2.7 Transfer Learning . . . 30
2.2.8 Detecção de Objetos em Cenários com Dados Limitados . . . 31
2.2.9 Aumento de Dados . . . 32
2.2.10 Pré-processamento e realce de micro-relevo . . . 33
2.2.11 Detecção de objetos pequenos . . . 35
2.2.12 Estudo fatorial e estudo de ablação . . . 37
2.2.13 Validação Cruzada . . . 38
2.2.14 Comparação estatística entre configurações . . . 39
2.3 Trabalhos correlatos . . . 41
2.3.1 Trabalho 1: *Automated corner grading of trading cards: Defect identification and confidence calibration through deep learning* . . . 41
2.3.2 Trabalho 2: *NHD-YOLO: Improved YOLOv8 using optimized neck and head for product surface defect detection with data augmentation* . . . 42
2.3.3 Trabalho 3: *Systematic Evaluation of YOLOv8 Variants for UAV-Based Object Detection* . . . 42

3 DESENVOLVIMENTO / IMPLEMENTAÇÃO / EXPERIMENTOS 44
3.1 Metodologia da pesquisa . . . 44

3.1.1 Visão geral do trabalho 44
3.1.2 Organização e preparação do conjunto de dados 46
3.1.3 Critérios de validação 51
3.2 Detalhes da implementação 55
3.2.1 Modelo base 55
3.2.2 Hiperparâmetros de treinamento 57
3.2.3 Tecnologias e ferramentas 59
3.3 Experimentos e cenário de testes 60
3.3.1 Estratégias de treinamento avaliadas 60
3.3.2 Estudo fatorial, ablação e análises complementares 63
3.4 Resultados e análises 64

4 CONCLUSÃO 65
4.1 Retomada do problema e dos objetivos 65
4.2 Contribuições para a Computação 65
4.3 Limitações e trabalhos futuros 65

REFERÊNCIAS 66

APÊNDICES 70

APÊNDICE A – CRONOGRAMA PREVISTO NO TCC1 71

1 Introdução

Trading Card Games (TCG) são jogos de cartas colecionáveis nos quais cada carta possui atributos únicos, como raridade, ilustração, edição, condição física e valor comercial. Além de sua função no contexto do jogo, essas cartas são negociadas entre jogadores e colecionadores, o que contribui para a formação de um mercado voltado à compra, venda, troca e avaliação de exemplares. Representado por franquias como Pokémon e Magic: The Gathering, esse mercado deve movimentar aproximadamente 20 bilhões de dólares globalmente em 2026, com projeção de ultrapassar 76 bilhões até 2035 (Business Research Insights, 2026). Nesse contexto, o valor comercial de uma carta está diretamente ligado ao seu estado de conservação física. Para certificar essa condição e conferir segurança às transações, consolidou-se o serviço especializado de graduação de cartas (*card grading*), no qual profissionais avaliam cada exemplar segundo critérios padronizados e atribuem uma nota que sintetiza sua qualidade (NAHAR et al., 2025a). A PSA (*Professional Sports Authenticator*), pioneira nessa padronização, estabeleceu uma escala de 10 pontos que se tornaria norma do setor (NAHAR et al., 2025a), enquanto a Beckett Grading Services atribui, além da nota geral, subnotas para quatro atributos da carta, centralização, cantos, bordas e superfície, ampliando o detalhamento do processo de avaliação (Beckett Grading Services, 2026).

O processo de graduação, no entanto, ainda é realizado de forma predominantemente manual. Os avaliadores inspecionam cada carta com auxílio de instrumentos ópticos, como microscópios, o que torna a análise demorada, sujeita à subjetividade de cada profissional e difícil de escalar para acompanhar a demanda. Além disso, o manuseio durante a inspeção pode causar desgaste à própria carta. Em um mercado no qual uma carta pode valer de poucos dólares a centenas de milhares, conforme a raridade e o estado de conservação, a precisão dessa avaliação tem papel crítico no preço (NAHAR et al., 2025a; NAHAR et al., 2025b).

Como resposta a esses desafios, a automação baseada em visão computacional tem sido investigada como alternativa à inspeção manual. Na indústria de manufatura, sistemas de inspeção visual automatizada (*Automated Visual Inspection* – AVI) já empregam arquiteturas de *Deep Learning* e Redes Neurais Convolucionais (CNNs) para detectar defeitos em superfícies com alta velocidade e reprodutibilidade (ZHENG et al., 2021). A adaptação dessas abordagens ao contexto de cartas colecionáveis, contudo, não é direta: as características visuais particulares das cartas e as condições reais de captura introduzem desafios técnicos específicos que limitam a transferência imediata das soluções desenvolvidas para domínios industriais convencionais (NAHAR et al., 2025a).

Um obstáculo adicional diz respeito à disponibilidade de dados. Em tarefas de detecção de objetos em domínios especializados, a construção de conjuntos de dados anotados

em larga escala é custosa e trabalhosa, pois cada imagem exige rotulagem especializada com caixas delimitadoras precisas para cada instância de defeito (SITU et al., 2023). No contexto de cartas TCG, essa restrição é ainda mais pronunciada: a anotação requer avaliação especializada de defeitos segundo critérios técnicos de graduação, e o principal estudo identificado no domínio, conduzido sobre cartas esportivas, contou com o apoio de um parceiro da indústria para viabilizar seu conjunto de dados (NAHAR et al., 2025a).

Pesquisadores já investigaram o uso de técnicas de visão computacional para classificar defeitos em cartas colecionáveis (NAHAR et al., 2025a), porém ainda há uma carência de estudos que avaliem sistematicamente o impacto de diferentes estratégias de treinamento em cenários com baixo volume de dados nesse domínio específico. Durante a busca bibliográfica deste trabalho não foi identificado um conjunto de dados público de imagens de cartas Pokémon TCG com os defeitos localizados por caixas delimitadoras. O único conjunto público encontrado difere do necessário neste trabalho em dois pontos: reúne cartas esportivas, e não cartas Pokémon TCG, e traz recortes rotulados para classificação, sem a posição de cada defeito (NAHAR et al., 2025b). Isso reforça a necessidade de construção de um conjunto próprio. Diante disso, este trabalho realizou uma análise comparativa de estratégias de treinamento para detecção de defeitos em cartas Pokémon TCG, conduzida sobre um conjunto de dados composto por 206 cartas fornecido por uma empresa brasileira especializada em graduação. Sobre um YOLOv8s com *transfer learning* a partir de pesos pré-treinados no conjunto COCO, foram avaliados o aumento de dados (*data augmentation*) e o realce de micro-relevo (uma transformação da imagem que destaca variações locais de intensidade associadas ao relevo da superfície, como vincos e amassados) como representação de entrada. Essas duas estratégias foram cruzadas em um estudo fatorial, que resultou em quatro configurações comparadas entre si. Em seguida, sobre a configuração de melhor desempenho nessa comparação, foram avaliadas uma cabeça de detecção adicional para objetos pequenos (P2) e a resolução de entrada de 1280 pixels, em comparação com a resolução padrão de 640 pixels. A avaliação foi realizada por meio de métricas quantitativas consolidadas na literatura, com o objetivo de identificar as combinações mais eficazes em cenários com dados limitados.

1.1 Contextualização do problema

Na graduação de cartas colecionáveis, a avaliação segue critérios físicos padronizados que consideram superfície, bordas, cantos e centralização como atributos independentes, cada um passível de apresentar tipos específicos de defeito (NAHAR et al., 2025a). Do ponto de vista visual, esses defeitos tendem a ser localizados em regiões específicas da carta e podem ocupar áreas reduzidas da imagem, o que os torna difíceis de identificar tanto manualmente quanto por meio de modelos computacionais (NAHAR et al., 2025a).

Do ponto de vista computacional, a detecção desses defeitos apresenta desafios se-

melhantes aos encontrados em inspeção industrial automatizada, mas agravados pelas características específicas das cartas TCG. O primeiro deles é a iluminação durante a captura das imagens: quando a iluminação não produz bom contraste entre o defeito e o fundo, ou quando introduz ruído na imagem, o reconhecimento de defeitos por métodos supervisionados se torna mais difícil (ZHENG et al., 2021). No contexto de cartas colecionáveis, esse efeito pode ser intensificado pela presença de artes visualmente complexas, superfícies holográficas e defeitos de baixa visibilidade. Para mitigar seu impacto sobre a detecção de defeitos sutis, operadores de filtragem têm sido aplicados como etapa de pré-processamento em sistemas de inspeção visual (SAWADA; FUJI; AIKAWA, 2024; JIANG et al., 2023).

O segundo desafio são os reflexos em superfícies holográficas (*foil*). Em superfícies altamente refletoras, artefatos de reflexo podem mascarar as características visuais necessárias para identificar defeitos (KIM; OKWUOSA; HUR, 2026). De modo análogo, o brilho da superfície holográfica pode reduzir o contraste entre o defeito e a região ao redor, e reflexos e sombras já são reconhecidos como fonte de problema na captura de imagens de cartas (NAHAR et al., 2025a). Entre as estratégias avaliadas neste trabalho, o realce de micro-relevo aumenta o contraste local da imagem e pode atenuar em parte essa perda de contraste; nenhuma delas, porém, atua sobre a captura da imagem, etapa em que o reflexo se forma.

Um terceiro desafio diz respeito à natureza da tarefa de inspeção em si. Abordagens de classificação atribuem um rótulo à imagem, ou a um recorte dela, como um canto da carta, sem fornecer informação sobre a localização do defeito (HUSSAIN, 2023). Um canto pode apresentar *whitening* restrito à sua extremidade, mas o classificador produz apenas uma nota global para aquela região, sem indicar a posição ou a extensão do dano. Quando essa informação é necessária, a detecção de objetos, que localiza cada instância por caixa delimitadora e lhe atribui uma classe (RAMOS; SAPPA, 2025), é apontada como preferível à classificação de imagens em inspeção de defeitos (HUSSAIN, 2023). Neste trabalho, a detecção foi conduzida com uma única classe, denominada *defeito*: o modelo localiza cada instância, mas não distingue o tipo de defeito nem sua gravidade. Mesmo sem essas informações, a localização tem valor próprio, pois indica ao avaliador em que pontos da carta concentrar a inspeção.

Um quarto desafio diz respeito ao tamanho dos defeitos. Antes de entrar na rede, a imagem é redimensionada para a resolução de entrada: na resolução de 640 pixels, por exemplo, ela é redimensionada, mantendo a proporção, até que seu lado maior meça 640 pixels. A rede, por sua vez, reduz essa imagem em etapas, e cada nível de detecção trabalha sobre um mapa de características em que um único ponto resume um bloco de pixels da imagem de entrada; o lado desse bloco é chamado de passo. No nível de passo 8, por exemplo, cada ponto resume um bloco de 8×8 pixels, e o sinal de um defeito cujo menor lado é menor que 8 pixels ocupa só uma parte de cada bloco em que aparece e fica

diluído no ponto que resume esse bloco. Na resolução de entrada de 640 pixels, que é a resolução padrão do YOLOv8, 57,6% dos defeitos deste conjunto de dados têm o menor lado da caixa delimitadora abaixo de 8 pixels, o passo do nível de detecção mais fino do YOLOv8 original (P3); essa proporção cai para 10,8% quando a resolução de entrada sobe para 1280 pixels. Essa restrição motivou a avaliação de uma cabeça de detecção adicional voltada a objetos pequenos (P2, de passo 4) e da resolução de entrada como estratégias deste trabalho.

Por fim, a construção de conjuntos de dados anotados nesse domínio impõe restrições práticas que delimitam diretamente o escopo de investigação possível. Mesmo o principal estudo identificado no domínio trabalhou com um conjunto que os próprios autores caracterizam como pequeno (NAHAR et al., 2025a), o que evidencia por que cenários com poucos exemplos rotulados constituem uma restrição real que demanda estratégias de treinamento específicas. Um sistema integrado de graduação automática, apresentado por seus autores como pronto para uso em produção, avalia cantos, bordas e superfície de forma unificada, com algumas centenas de cartas (593 para cantos, 134 para bordas e 150 para superfície) (NAHAR et al., 2025b). Esse sistema, porém, classifica recortes da carta, sem localizar os defeitos na imagem. A diferença para este trabalho é, portanto, sobretudo de tarefa: aqui, o modelo detecta cada defeito e o localiza por caixa delimitadora.

1.2 Formulação do problema

Diante desses desafios, o problema investigado neste trabalho pode ser formulado pela seguinte pergunta: com um conjunto reduzido de imagens anotadas, quais estratégias de treinamento aplicadas ao YOLOv8, entre aumento de dados, realce de micro-relevo como representação de entrada, cabeça de detecção adicional para objetos pequenos e resolução de entrada, melhoram a detecção de defeitos superficiais em cartas Pokémon TCG? O trabalho restringe-se à detecção de defeitos com uma classe única, sem atribuir a nota de graduação da carta, e à comparação dessas estratégias sobre um mesmo conjunto de dados e um mesmo protocolo de avaliação.

As anotações de defeito usadas neste trabalho foram feitas por um único anotador, o próprio autor, com apoio nos laudos de graduação emitidos pela empresa que forneceu o conjunto de dados e no próprio julgamento sobre a imagem, inclusive para defeitos não registrados nesses laudos. A referência contra a qual o detector é medido é, portanto, o julgamento desse anotador apoiado nos laudos, e não o laudo em si; sem um segundo anotador, não foi possível medir a concordância entre avaliadores, e o desempenho que é possível medir fica limitado pela consistência dessa anotação. Parte das caixas delimitadoras, 892 de 4.808 (18,6%), foi sugerida por modelos de detecção treinados em uma etapa preliminar do trabalho e validada individualmente pelo autor, em uma revisão da anotação descrita na Seção 3.1.2. Esses modelos usavam imagens coloridas convencionais (RGB), com aumento

de dados, e nenhum deles havia sido treinado com a carta para a qual sugeriu caixas. Como esses modelos viam as imagens da mesma forma que as configurações que usam imagens RGB, as caixas sugeridas podem favorecer essas configurações na comparação com o realce de micro-relevo; por esse motivo, os resultados apresentados no Capítulo 3 foram verificados também desconsiderando essas caixas sugeridas.

1.3 Objetivos e hipótese

Os objetivos a seguir decorrem da lacuna e da restrição apresentadas nas seções anteriores: há carência de estudos que avaliem sistematicamente estratégias de treinamento para detectar defeitos em cartas colecionáveis, e o conjunto de dados disponível reúne apenas 206 cartas. Por isso, o objetivo é comparativo: em vez de propor um modelo novo, o trabalho avalia quais estratégias melhoram um detector já estabelecido, o YOLOv8, nesse cenário.

1.3.1 Objetivo geral

Avaliar o desempenho de estratégias de treinamento aplicadas ao modelo YOLOv8 para detecção de defeitos pequenos em cartas Pokémon TCG com baixo volume de dados.

1.3.2 Objetivos específicos

Para alcançar o objetivo geral, foram definidos os seguintes objetivos específicos:

1. Organizar e preparar um conjunto de dados de imagens de cartas Pokémon TCG, adotando uma classe única de detecção denominada *defeito*.

2. Implementar quatro configurações experimentais baseadas em YOLOv8 com *transfer learning*, cruzando o uso de aumento de dados (*data augmentation*) com duas representações de entrada, imagens RGB convencionais e imagens de realce de micro-relevo, e comparar as quatro combinações resultantes.

3. Avaliar, sobre a configuração de melhor desempenho nessa comparação, o efeito de uma cabeça de detecção adicional voltada a objetos menores (P2), pela revocação (a proporção dos defeitos anotados que o modelo encontra) dos defeitos cujo menor lado da caixa delimitadora é menor que 8 pixels, e o efeito da resolução de entrada, comparando 1280 e 640 pixels pelo F1 por carta, com teste de Wilcoxon pareado.

4. Comparar o desempenho das diferentes configurações por meio de métricas quantitativas consolidadas em detecção de objetos, incluindo precisão (*Precision*), revocação (*Recall*), F1-*score* e *mean Average Precision* (mAP@0,5).

5. Avaliar, por meio de uma curva de aprendizado, se o desempenho do detector aumenta com o número de cartas disponíveis para treino.

6. Analisar os resultados obtidos, identificando quais estratégias de treinamento apresentam melhor desempenho em cenários com conjuntos de dados reais e limitados no domínio de inspeção de cartas TCG.

1.3.3 Hipótese ou critério de validação

A partir da revisão da literatura, foram formuladas as hipóteses H1 a H3; a hipótese H4 foi formulada depois, a partir da análise do tamanho das anotações apresentada na Seção 1.1. As quatro hipóteses foram formuladas antes do treinamento dos modelos usados para testá-las:

H1 O aumento de dados (*data augmentation*) melhora o desempenho do detector em relação à configuração sem aumento de dados.

H2 O uso de imagens de realce de micro-relevo como representação de entrada melhora o desempenho do detector em relação às imagens RGB.

H3 A combinação de aumento de dados e realce de micro-relevo (Configuração 4) produz o melhor desempenho entre as quatro configurações avaliadas.

H4 A cabeça de detecção adicional P2 aumenta a revocação (*recall*) dos defeitos cujo menor lado da caixa delimitadora é menor que 8 pixels, na resolução de entrada de 1280 pixels.

A métrica usada para testar H1 a H3 foi o F1 por carta, que resume em um único valor a precisão e a revocação das detecções de cada carta; seu cálculo é descrito no Capítulo 3. H1 foi testada pela comparação pareada por carta entre a Configuração 2 (RGB com aumento de dados) e a Configuração 1 (RGB sem aumento de dados), e entre a Configuração 4 (realce com aumento de dados) e a Configuração 3 (realce sem aumento de dados). H2 foi testada pela comparação entre a Configuração 3 e a Configuração 1, e entre a Configuração 4 e a Configuração 2. H3 seria refutada se alguma das outras configurações superasse significativamente a Configuração 4, o que foi verificado pelas mesmas comparações da Configuração 4 com as Configurações 2 e 3, sem teste adicional; a regra completa de decisão das três hipóteses é apresentada no Capítulo 3. Todas essas comparações usaram o teste de Wilcoxon pareado bilateral, com nível de significância $\alpha = 0{,}05$, definido antes do treinamento das quatro configurações; a correção de Holm para o conjunto de comparações foi aplicada na análise dos resultados.

Para H4, o critério, definido antes do treinamento da variante com a cabeça P2, foi a revocação dos defeitos cujo menor lado da caixa é menor que 8 pixels na resolução de

1280 pixels, somados todos os defeitos desse grupo, comparando a configuração de melhor desempenho com e sem a cabeça P2. Mesmo nessa resolução, parte dos defeitos permanece abaixo do passo do nível P3 (Seção 1.1), o que justificou testar a P2 nessa resolução. Já se sabia, antes desse treinamento, que a variante com a cabeça P2 não receberia pesos pré-treinados na cabeça de detecção nem em parte das camadas intermediárias; por isso, o teste de H4 não separa o efeito da cabeça P2 do efeito da falta de pré-treino.

A resolução de entrada e a curva de aprendizado foram análises exploratórias, decididas depois dos resultados do estudo fatorial e sem hipótese formulada previamente; seus resultados indicam direções a confirmar. A confirmação ou a refutação de cada hipótese é apresentada nos resultados e retomada na conclusão.

1.4 Justificativa

No âmbito científico, os estudos existentes sobre automação da graduação de cartas colecionáveis apresentam contribuições relevantes, mas com lacunas que abrem espaço para a investigação realizada neste trabalho. Nahar et al. (2025a) propõem um modelo baseado em *transfer learning* para classificar a severidade de defeitos em cantos, alcançando 83% de acurácia média em um conjunto de 4.744 imagens de cantos obtidas de 593 cartas esportivas, mas o estudo está restrito a um único critério de avaliação e não analisa sistematicamente o impacto de diferentes estratégias de treinamento no desempenho do modelo. Embora o sistema integrado descrito na Seção 1.1 alcance acurácias de 81% a 94% na classificação de recortes (NAHAR et al., 2025b), a investigação sistemática do impacto de estratégias de treinamento na detecção localizada de defeitos, com conjuntos reduzidos de dados reais, permanece uma lacuna no domínio de cartas colecionáveis, que este trabalho investigou sobre um conjunto de 206 cartas e 412 imagens.

A relevância de investigar estratégias como *transfer learning* e aumento de dados em cenários com amostras escassas é sustentada pela literatura de inspeção visual automatizada. Chen et al. (2021) identificam o problema de pequenas amostras (*small sample problem*) como um dos problemas centrais da detecção de defeitos superficiais industriais com aprendizado profundo, associado ao risco de sobreajuste, e apontam quatro linhas de solução: aumento de dados, modelos não supervisionados ou semissupervisionados, *transfer learning* e otimização da estrutura da rede. Um exemplo quantitativo é apresentado por Wang, Li e Wang (2022), na detecção de defeitos superficiais em aço: com apenas cinco imagens rotuladas por categoria, pré-treinar o detector em outras categorias de defeito antes do ajuste fino elevou o mAP de 9,4% para 24,1%, em relação ao mesmo modelo treinado somente com essas imagens. Nesse mesmo experimento, o aumento de dados, uma das estratégias avaliadas neste trabalho, acrescentou até 2,3 pontos percentuais ao mAP.

Na prática, avaliar essas estratégias (aumento de dados, realce de micro-relevo, a

cabeça de detecção adicional P2 e a resolução de entrada) sobre um YOLOv8s com *transfer learning* a partir do conjunto COCO indica quais delas merecem ser priorizadas quando o volume de dados de treinamento é pequeno, um cenário comum em domínios especializados como o de cartas colecionáveis. Um resultado negativo (uma estratégia que não melhora o desempenho nesse cenário) também constitui uma contribuição, pois evita que trabalhos futuros repitam o mesmo investimento sem o ganho esperado. Essa análise é relevante para contextos em que a anotação é cara e o volume de dados é limitado (SITU et al., 2023; CHEN et al., 2021), e busca subsidiar a detecção automática de defeitos como apoio à inspeção visual (NAHAR et al., 2025a).

2 Revisão Bibliográfica / Trabalhos Relacionados

Este capítulo apresenta a pesquisa bibliográfica que fundamenta o trabalho, os conceitos teóricos necessários para compreender os experimentos e os trabalhos relacionados. A Seção 2.1 descreve como a literatura foi buscada e selecionada. A Seção 2.2 apresenta os fundamentos, do geral para o específico. Começa pela base: aprendizado profundo e redes neurais convolucionais, inspeção visual automatizada, defeitos visuais em cartas colecionáveis, detecção de objetos, métricas de avaliação de detectores e a arquitetura YOLO. Em seguida, trata do *transfer learning* usado em todos os experimentos, do cenário com poucos dados e das estratégias avaliadas neste trabalho: aumento de dados, realce de micro-relevo, cabeça de detecção adicional para objetos pequenos e resolução de entrada. Por fim, apresenta os conceitos usados para comparar essas estratégias: estudo fatorial e estudo de ablação, validação cruzada e comparação estatística. A Seção 2.3 analisa os trabalhos mais próximos do problema investigado e indica como este trabalho se diferencia deles.

2.1 Metodologia da pesquisa bibliográfica

A pesquisa bibliográfica foi realizada por meio das bases Google Scholar, IEEE Xplore, ScienceDirect e MDPI, utilizando combinações de termos em inglês diretamente relacionados aos temas centrais do trabalho. As strings de busca utilizadas, bem como os quantitativos de artigos triados e selecionados em cada etapa, estão apresentados na Tabela 1. A triagem considerou título e resumo como critérios iniciais de relevância, com leitura completa reservada aos trabalhos selecionados para inclusão. A busca ocorreu em duas fases: uma exploratória, com strings temáticas, e outra dirigida, para localizar a fundamentação de decisões de método específicas, como o operador de realce, a comparação estatística e os critérios de treinamento; por isso, parte das strings da Tabela 1 é mais específica que as demais.

Tabela 1 – Strings de busca utilizadas na pesquisa bibliográfica

String de busca	**Bases**	**Triados**	**Selecionados**
"trading card" OR "collectible card" AND "computer vision"	GS, IEEE, SD, MDPI	14	4
"surface defect detection" AND "computer vision" AND "scratch" OR "wear"	GS, IEEE, SD, MDPI	9	2

String de busca	**Bases**	**Triados**	**Selecionados**
"PCB" AND "surface defect detection" AND "global contextual attention" AND "YOLO"	GS, IEEE, SD, MDPI	8	1
"ablation study" AND "object detection" AND "transfer learning"	GS, IEEE, SD, MDPI	5	2
"dataset COCO" AND "object detection" AND "YOLO pretraining"	GS, IEEE, SD, MDPI	3	1
"ImageNet pre-training" AND "from scratch" AND "object detection"	GS, IEEE, SD, MDPI	13	2
"filter" AND "surface defect detection" AND "deep learning"	GS, IEEE, SD, MDPI	18	3
"vessel enhancement" AND "Hessian" AND "multiscale"	GS, IEEE, SD, MDPI	5	1
"three-channel" AND "SAR" AND "YOLO" AND "ship detection"	GS, IEEE, SD, MDPI	4	1
"CLAHE" AND "transfer learning" AND "from scratch" AND "domain shift"	GS	3	1
"YOLOv8" AND "defect detection" AND "transfer learning"	GS, IEEE, SD, MDPI	11	4
"cross-validation" AND "YOLO" AND "defect detection"	GS, IEEE, SD, MDPI	6	1
"cross-validation" AND "model selection" AND "survey"	GS, IEEE, SD, MDPI	11	2
"statistical comparison" AND "classifiers" AND "cross-validation"	GS, IEEE, SD, MDPI	10	3
"bootstrap confidence intervals" AND "BCa"	GS, IEEE, SD, MDPI	14	2
"metric-related pitfalls" AND "image analysis" AND "validation"	GS, IEEE, SD, MDPI	2	1
"Neural Networks" AND "Early Stopping"	GS, IEEE, SD, MDPI	2	1
"learning curves" AND "deep networks" AND "analysis"	GS, IEEE, SD, MDPI	20	3
"small object detection" AND "input resolution" OR "image size"	GS, IEEE, SD, MDPI	9	3
"highly reflective" surface defect detection YOLO	MDPI	9	1
Fontes não acadêmicas (contextualização de mercado e documentação técnica)	Diversas	n/a	3
Total		**176**	**42**

GS = Google Scholar; IEEE = IEEE Xplore; SD = ScienceDirect; MDPI = Multidisciplinary Digital Publishing Institute. Fonte: Elaborado pelo autor (2026).

Foram priorizados trabalhos acadêmicos publicados entre 2021 e 2026, em língua inglesa, disponíveis em periódicos ou anais de conferências. A seleção considerou principalmente estudos revisados por pares e *surveys* recentes quando diretamente relacionados ao problema investigado ou necessários para fundamentar conceitos técnicos específicos. Trabalhos anteriores a 2021 foram admitidos apenas quando são a origem ou a referência clássica de um método, de um conjunto de dados ou de um resultado empírico usado como fundamento neste trabalho, com alto impacto medido pelo número de citações no OpenAlex, acima de mil em todos os casos na consulta de outubro de 2026; toda a literatura sobre detecção de defeitos e sobre o domínio de cartas colecionáveis permaneceu restrita a 2021 em diante. Por esse critério, foram incluídos nove trabalhos anteriores a 2021, agrupados a seguir por tema; os conceitos mencionados são apresentados na Seção 2.2 e no Capítulo 3. Como base de pré-treinamento, o conjunto COCO (LIN et al., 2014), no qual foram obtidos os pesos iniciais do YOLOv8. Em validação cruzada e seleção de modelos, Kohavi (1995), para a estratificação das dobras; Arlot e Celisse (2010), para a escolha do número de dobras; e Cawley e Talbot (2010), para o viés de fazer escolhas no mesmo conjunto usado para medir o desempenho. Em comparação estatística, Demšar (2006), para o teste de Wilcoxon pareado e a correção de Holm (Seção 2.2.14), e DiCiccio e Efron (1996), para o intervalo de confiança por *bootstrap*. No treinamento, Prechelt (1998), para o critério de parada antecipada adotado na Seção 3.2.2, e He, Girshick e Dollár (2019), para o efeito do pré-treino quando há poucos dados. Em processamento de imagem, Frangi et al. (1998), cuja medida foi usada no realce de micro-relevo.

De forma complementar, também foram consultadas fontes não acadêmicas: páginas institucionais e relatórios setoriais, utilizados para contextualização do mercado e caracterização do domínio de aplicação (Business Research Insights, 2026; Beckett Grading Services, 2026), e a documentação técnica da biblioteca Ultralytics, utilizada para os detalhes de implementação do YOLOv8 (JOCHER; CHAURASIA; QIU, 2023). A relevância de cada trabalho foi avaliada com base em sua aderência ao problema de pesquisa, isto é, a detecção automatizada de defeitos visuais em cenários com baixo volume de dados, com ênfase em aplicações de visão computacional em domínios especializados.

2.2 Fundamentos teóricos

Esta seção apresenta os conceitos teóricos que sustentam os experimentos, organizados do geral para o específico. As Seções 2.2.1 a 2.2.6 tratam da base: aprendizado profundo, inspeção visual automatizada, defeitos em cartas colecionáveis, detecção de objetos, métricas de avaliação e a arquitetura YOLO. As Seções 2.2.7 a 2.2.11 tratam do cenário com poucos dados e das estratégias avaliadas. As Seções 2.2.12 a 2.2.14 tratam de como essas

estratégias foram comparadas.

2.2.1 Deep Learning e Redes Neurais Convolucionais

Deep Learning é uma subárea do aprendizado de máquina que utiliza redes neurais artificiais com múltiplas camadas para aprender representações diretamente a partir dos dados. Em visão computacional, essa abordagem reduziu a dependência de características projetadas manualmente, permitindo que os modelos extraíssem padrões visuais complexos a partir das próprias imagens (ZHENG et al., 2021). Nesse contexto, as Redes Neurais Convolucionais (CNNs, do inglês *Convolutional Neural Networks*) tornaram-se a arquitetura central para tarefas como classificação de imagens, detecção de objetos e inspeção de defeitos, pois utilizam camadas convolucionais para aprender características visuais em diferentes níveis de abstração (HUSSAIN, 2023).

A relevância das CNNs em visão computacional foi consolidada por arquiteturas como AlexNet, VGGNet, GoogLeNet, ResNet e DenseNet, que demonstraram a eficácia de redes profundas na extração automática de características visuais (ZHENG et al., 2021; HUSSAIN, 2023). Embora apresentem diferenças estruturais, essas arquiteturas compartilham a ideia de aprender representações hierárquicas da imagem, nas quais camadas iniciais capturam padrões simples, como bordas e texturas, enquanto camadas mais profundas representam formas e estruturas mais complexas.

Na inspeção visual automatizada, essa capacidade é especialmente importante porque defeitos de superfície podem variar em forma, escala, textura e contraste. Segundo Zheng et al. (2021), métodos tradicionais dependiam de atributos manualmente projetados, o que os tornava sensíveis a variações nas condições de captura e no tipo de defeito. Já métodos baseados em *deep learning* integram a extração e a aprendizagem de características em um mesmo processo, favorecendo maior adaptação a diferentes cenários de inspeção.

Essa base também sustenta arquiteturas modernas de detecção, como a família YOLO, nas quais redes convolucionais são utilizadas para extrair características visuais que posteriormente são empregadas na localização e classificação dos objetos de interesse (HUSSAIN, 2023). Assim, a compreensão das CNNs é necessária para fundamentar o uso de detectores baseados em *deep learning* na identificação de defeitos visuais em cartas TCG.

2.2.2 Visão Computacional e Inspeção Visual Automatizada

A visão computacional é a área da ciência da computação que desenvolve métodos para que sistemas digitais interpretem e analisem imagens e vídeos automaticamente. Uma de suas aplicações mais relevantes na prática industrial está nos sistemas de inspeção visual automatizada (*Automated Visual Inspection* – AVI), cuja função é substituir ou apoiar a inspeção manual de qualidade em linhas de produção (ZHENG et al., 2021).

Um sistema AVI é composto, em geral, por três etapas principais: aquisição de imagem, detecção de defeitos e controle de qualidade. A etapa de aquisição utiliza câmeras digitais combinadas com sistemas de iluminação controlada para garantir contraste adequado entre as características do produto e possíveis defeitos. Em seguida, a etapa de detecção aplica algoritmos de processamento de imagem para identificar e classificar anomalias. Por fim, os resultados são enviados ao sistema de controle de qualidade, que determina a aceitação ou rejeição do produto (ZHENG et al., 2021).

Antes da consolidação do *Deep Learning*, muitos sistemas AVI dependiam de características projetadas manualmente por especialistas, o que os tornava sensíveis a variações nas condições de aplicação (ZHENG et al., 2021). Com o avanço das CNNs, passaram a ser desenvolvidos métodos capazes de aprender padrões diretamente a partir dos dados de treinamento, superando parte das limitações dos métodos tradicionais. Sistemas baseados em CNNs têm sido avaliados na inspeção de defeitos em semicondutores, aço e tecidos, e alguns estudos relatam acurácias de classificação acima de 99% em defeitos de aço e de placas de circuito impresso (ZHENG et al., 2021).

2.2.3 Defeitos visuais em cartas colecionáveis

A inspeção visual de cartas colecionáveis envolve a identificação de defeitos físicos distribuídos ao longo de regiões específicas da carta. O processo de graduação avalia quatro critérios independentes: cantos, bordas, superfície e centralização, cada um passível de apresentar tipos específicos de defeito (NAHAR et al., 2025a). A Figura 1 ilustra essas regiões e os principais tipos de imperfeição associados a cada critério. A centralização, que mede a posição da arte em relação às bordas, é uma propriedade geométrica da carta inteira e não se localiza por caixa delimitadora; por isso, fica fora do escopo da detecção neste trabalho.

Figura 1 – Critérios de avaliação no processo de graduação de cartas TCG: cantos, bordas, superfície e centralização, ilustrados sobre carta do conjunto de dados.



Fonte: Elaborado pelo autor a partir de imagem fornecida por empresa parceira (2026).

Do ponto de vista computacional, compreender a aparência desses defeitos é necessário para formular a tarefa de detecção. Os tipos de defeito observados nas cartas do conjunto de dados deste trabalho incluem:

- **Riscos (*scratches*):** marcas finas e alongadas na superfície, na frente ou no verso da carta, de comprimento e visibilidade variáveis.
- **Vincos e dobras (*creases*):** deformações do papel resultantes de dobramento parcial, que na fotografia aparecem como linhas mais claras ou mais escuras que a superfície ao redor.
- ***Whitening*:** perda de pigmento nas bordas ou nos cantos, que ficam mais claros que o restante da carta.
- **Desgaste de cantos (*corner wear*):** arredondamento ou amassamento das pontas da carta pelo manuseio.

- **Desgaste de bordas (*edge wear*):** irregularidades ao longo das bordas, frequentemente acompanhadas de *whitening*.
- **Manchas e pontos:** marcas de sujeira sobre a superfície, de poucos pixels a regiões extensas.

Ocorre também um desgaste difuso, formado por muitos micro-riscos ou micro-pontos sem início nem fim definidos, que não pode ser delimitado por caixas; seu tratamento é descrito no Capítulo 3.

Esses defeitos apresentam características que dificultam sua detecção automática. Muitos ocupam regiões pequenas em relação à área da carta, como é comum em defeitos superficiais (CHEN et al., 2021); a análise de tamanho apresentada na Seção 1.1 quantifica isso para este conjunto de dados. Defeitos sutis sobre superfícies com texturas e padrões visuais complexos representam um desafio reconhecido na literatura de inspeção visual, o que tem motivado o desenvolvimento de detectores específicos para esse tipo de cenário (XIA et al., 2023); nas cartas, esse papel é desempenhado pela arte impressa e pelas superfícies holográficas (*foil*), cujo reflexo foi discutido na mesma seção. Além disso, a qualidade da iluminação na captura condiciona o contraste com que o defeito aparece na imagem (ZHENG et al., 2021).

A relevância de um sistema automatizado decorre dessas dificuldades e do caráter manual da graduação, descrito no Capítulo 1: a inspeção é demorada e sujeita à subjetividade de cada avaliador (NAHAR et al., 2025a). Neste trabalho, o detector não atribui nota à carta; ao localizar cada defeito por caixa delimitadora, ele indica ao avaliador em que pontos concentrar a inspeção.

2.2.4 Detecção de Objetos

A detecção de objetos é uma tarefa de visão computacional que combina dois problemas distintos: a classificação de objetos presentes em uma imagem e a localização precisa de cada instância por meio de caixas delimitadoras (*bounding boxes*) (HUSSAIN, 2023). Diferentemente da classificação de imagens, que atribui um único rótulo à imagem inteira, a detecção de objetos é capaz de identificar múltiplos objetos em posições diferentes, retornando para cada um deles suas coordenadas espaciais, a classe correspondente e um escore de confiança (RAMOS; SAPPA, 2025).

A qualidade de uma detecção é medida pela métrica *Intersection over Union* (IoU), que quantifica a sobreposição entre a caixa delimitadora predita e a caixa de referência (*ground truth*). O IoU é calculado como a razão entre a área de interseção e a área de união das duas caixas (XU et al., 2022), assumindo valores entre 0 e 1, em que valores mais próximos de 1 indicam maior precisão de localização. A partir de um limiar de IoU, como o de 0,5, usado na métrica apresentada na Seção 2.2.5 (RAMOS; SAPPA, 2025), uma predição é considerada verdadeiro positivo (TP) quando corresponde a uma caixa de

referência e sua sobreposição atinge ou supera esse limiar. A correspondência é de um para um: cada caixa de referência pode ser associada a uma única predição, e predições que não correspondem a nenhuma caixa de referência, inclusive uma segunda predição sobre o mesmo defeito, são contabilizadas como falsos positivos (FP), e caixas de referência que não são associadas a nenhuma predição válida são contabilizadas como falsos negativos (FN).

As arquiteturas de detecção de objetos são geralmente classificadas em dois grupos: detectores de dois estágios (*two-stage*) e detectores de um estágio (*one-stage*) (HUSSAIN, 2023). Os detectores de dois estágios, como a família R-CNN, dividem o processo em uma etapa de geração de propostas de regiões candidatas e uma etapa posterior de classificação e refinamento. Embora apresentem alta acurácia, esse design resulta em maior custo computacional e menor velocidade de inferência (SITU et al., 2023). Os detectores de um estágio, por sua vez, realizam a classificação e a localização em uma única passagem pela rede, obtendo melhor desempenho em tempo real com menor demanda computacional (HUSSAIN, 2023).

Como discutido na Seção 1.1, a detecção de objetos é preferida à classificação quando a localização do defeito é necessária (HUSSAIN, 2023). Nas cartas, riscos, desgastes e pequenas dobras ocupam regiões específicas e reduzidas da superfície, de modo que a localização de cada defeito é parte central da análise.

2.2.5 Métricas de Avaliação

A avaliação de modelos de detecção de objetos requer métricas que considerem simultaneamente a acurácia de classificação e a qualidade de localização espacial (RAMOS; SAPPA, 2025). As métricas fundamentais são a precisão (*precision*) e a revocação (*recall*), definidas respectivamente como:

$$\text{Precisão} = \frac{TP}{TP + FP} \tag{2.1}$$

$$\text{Revocação} = \frac{TP}{TP + FN} \tag{2.2}$$

em que TP são os verdadeiros positivos, FP os falsos positivos e FN os falsos negativos. A precisão mede a proporção de detecções corretas entre todas as detecções realizadas, enquanto a revocação mede a proporção de objetos reais que foram corretamente detectados. O F1-*score* combina ambas as métricas em um único valor por meio da média harmônica:

$$F1 = 2 \cdot \frac{\text{Precisão} \times \text{Revocação}}{\text{Precisão} + \text{Revocação}} \tag{2.3}$$

Cada caixa predita pelo detector vem acompanhada de um escore de confiança, como apresentado na Seção 2.2.4. A precisão, a revocação e o F1 dependem, portanto, de um limiar de confiança: só as predições com confiança igual ou superior a ele são contadas.

Um limiar baixo aceita mais predições, o que tende a aumentar a revocação e a reduzir a precisão; um limiar alto produz o efeito inverso. O F1 pode ser calculado sobre todas as caixas de um conjunto de avaliação, o F1 agregado, ou separadamente para cada carta, com as predições e as anotações das suas duas faces, o F1 por carta. Como todas as cartas do conjunto de dados têm ao menos uma anotação, o F1 por carta está definido para todas elas, exceto nas verificações feitas sem as caixas sugeridas, em que cinco cartas ficam sem nenhuma anotação e saem das comparações por carta (Seção 3.1.2). A forma como o limiar foi escolhido neste trabalho é descrita na Seção 2.2.13, e o uso do F1 por carta como nota das comparações pareadas, na Seção 2.2.14.

A métrica de referência na avaliação de detectores de objetos é o *mean Average Precision* (mAP), que resume o desempenho do modelo ao calcular a média das precisões médias (*Average Precision* – AP) para cada classe (RAMOS; SAPPA, 2025). A AP de uma classe é calculada como a área sob a curva precisão-revocação, que varia conforme o limiar de confiança das predições. O mAP é então a média das APs sobre todas as classes:

$$\text{mAP} = \frac{1}{N} \sum_{i=1}^{N} AP_i \tag{2.4}$$

em que N é o número de classes. Neste trabalho, com a classe única *defeito*, o mAP coincide com a AP dessa classe. Duas variantes são frequentemente reportadas na literatura: o mAP@0,5, que utiliza um limiar de IoU de 0,5 para classificar predições como TP, e o mAP@0,5:0,95, que calcula a média sobre os limiares de IoU de 0,5 a 0,95, em passos de 0,05 (RAMOS; SAPPA, 2025).

2.2.6 Arquitetura YOLO

A família YOLO (*You Only Look Once*) representa uma das abordagens de detecção de objetos do tipo *one-stage* mais difundidas na literatura recente, destacando-se pelo equilíbrio entre velocidade de inferência e acurácia (RAMOS; SAPPA, 2025). Desde sua formulação inicial, a arquitetura trata a detecção como um problema unificado, prevendo caixas delimitadoras e probabilidades de classe diretamente a partir da imagem em uma única passagem pela rede (HUSSAIN, 2023). Essa característica diferencia os modelos YOLO de detectores em duas etapas, nos quais a geração de regiões candidatas e a classificação são realizadas em fases separadas.

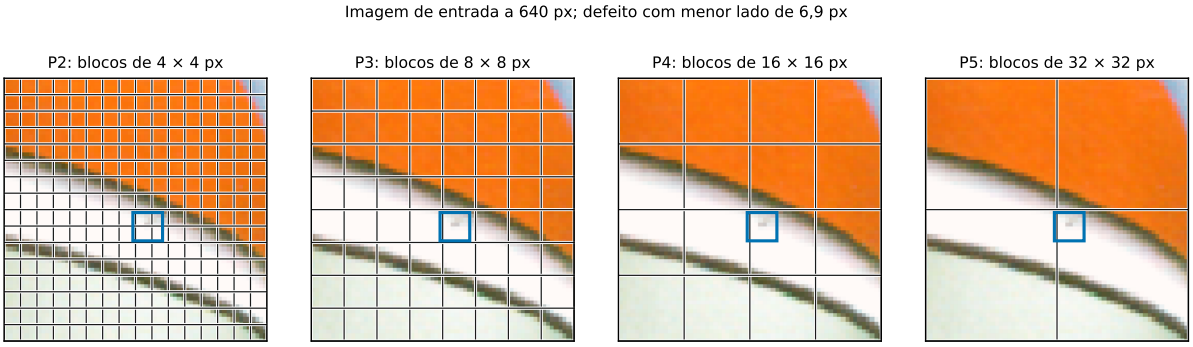
Ao longo do tempo, diferentes versões da família YOLO incorporaram melhorias voltadas ao tratamento de objetos em múltiplas escalas, à otimização do treinamento e à eficiência computacional (HUSSAIN, 2023; RAMOS; SAPPA, 2025). O YOLOv8, lançado em 2023, mantém a estrutura modular do YOLOv5, composta por *backbone*, a parte que extrai as características da imagem, *neck*, que combina essas características em várias escalas, e *head*, a cabeça que produz as caixas e as classes. De versões anteriores da família, ele conserva no *neck* a PANet (*Path Aggregation Network*), estrutura que

combina características de diferentes resoluções, e a cabeça com ramos desacoplados para classificação e regressão, introduzida em uma versão posterior ao YOLOv5; em relação ao YOLOv5, entre as novidades estão a detecção *anchor-free* e um novo bloco de extração de características no *backbone*, o C2f (RAMOS; SAPPA, 2025).

Nas versões anteriores, a rede previa deslocamentos em relação a caixas de formatos predefinidos, chamadas caixas âncora, distribuídas sobre o mapa de características. O paradigma *anchor-free* dispensa essas caixas: o modelo prevê diretamente os centros dos objetos. Essa característica simplifica o treinamento e pode favorecer a adaptação a conjuntos de dados específicos, nos quais as proporções e distribuições dos objetos não seguem necessariamente os padrões de bases genéricas (RAMOS; SAPPA, 2025). Já o módulo C2f busca melhorar o reaproveitamento de características intermediárias, aumentando a capacidade de representação do *backbone* sem comprometer a eficiência computacional. A PANet, por sua vez, contribui para a fusão de informações em diferentes resoluções (RAMOS; SAPPA, 2025), como detalhado a seguir.

Como apresentado na Seção 1.1, a rede reduz a imagem de entrada em etapas, e cada ponto de um mapa de características resume um bloco de pixels da imagem cujo lado é o passo. No YOLOv8, o *backbone* realiza cinco dessas etapas, cada uma dividindo pela metade a largura e a altura do mapa. Os mapas obtidos formam níveis, identificados pela letra P seguida do número da etapa: no nível Pk, cada ponto resume um bloco de $2^k \times 2^k$ pixels, de modo que o passo vale 2 pixels no nível P1, 4 no P2, 8 no P3, 16 no P4 e 32 no P5 (JOCHER; CHAURASIA; QIU, 2023). Quanto mais alto o nível, maior a região da imagem resumida por cada ponto e menor o detalhe espacial que o mapa preserva. A Figura 2 mostra os blocos dos níveis P2 a P5 sobre um defeito do conjunto de dados deste trabalho, na resolução de entrada de 640 pixels: com menor lado de 6,9 pixels, o defeito é menor que um único bloco do nível P3. O *neck* mistura a informação desses níveis nos dois sentidos. No caminho de cima para baixo, de desenho inspirado na rede de pirâmide de características (FPN, do inglês *Feature Pyramid Network*), os mapas mais reduzidos são ampliados e combinados aos mais detalhados; a PANet, citada acima, acrescenta um caminho de baixo para cima, que complementa o primeiro e leva o detalhe espacial dos mapas mais detalhados até os mais reduzidos (RAMOS; SAPPA, 2025). Na configuração padrão do YOLOv8, a cabeça de detecção decide sobre três níveis: P3, destinado aos objetos pequenos, P4, aos médios, e P5, aos grandes (JOCHER; CHAURASIA; QIU, 2023). Os níveis P1 e P2 existem no *backbone*, mas não recebem cabeça de detecção; por isso, o menor passo sobre o qual o modelo padrão decide é de 8 pixels. A biblioteca oferece também uma variante, chamada P2, que acrescenta uma cabeça de detecção sobre o nível P2, de passo 4; ela é descrita na Seção 2.2.11.

Figura 2 – Blocos resumidos por um ponto nos níveis P2 a P5, sobre um defeito do conjunto de dados, na imagem de entrada de 640 pixels.



Fonte: Elaborado pelo autor (2026).

Os pesos pré-treinados do YOLOv8 disponibilizados pela Ultralytics foram obtidos no conjunto COCO (*Common Objects in Context*), uma base de imagens de objetos comuns em cenas do cotidiano (LIN et al., 2014), em sua versão de 2017, cujo conjunto de treino reúne cerca de 118 mil imagens anotadas em 80 classes (JOCHER; CHAURASIA; QIU, 2023). Esses pesos constituem o ponto de partida usual para adaptar o YOLOv8 a novos domínios, seja por inferência direta, seja por ajuste fino (*fine-tuning*), descrito na Seção 2.2.7 (DOBRZYCKI; BERNARDOS; CASAR, 2025; SITU et al., 2023).

No presente trabalho, a escolha do YOLOv8 está relacionada à sua adequação ao problema investigado. Como os defeitos em cartas podem ser pequenos, localizados e visualmente sutis, a tarefa exige um detector capaz de preservar informações espaciais e operar de forma eficiente. Em comparação com detectores de dois estágios, como a família R-CNN, detectores de um estágio como o YOLO oferecem menor custo computacional e maior velocidade de inferência (SITU et al., 2023; HUSSAIN, 2023), embora com acurácia em geral inferior (HUSSAIN, 2023); o menor custo viabilizou treinar as várias configurações comparadas no equipamento disponível. Além disso, o YOLOv8 possui variantes com diferentes relações entre custo computacional e desempenho (RAMOS; SAPPA, 2025). Em cenários de adaptação de modelos pré-treinados, Dobrzycki, Bernardos e Casar (2025) investigam estratégias de *transfer learning* em arquiteturas YOLOv8 e YOLOv10, demonstrando que a escolha da configuração de treinamento depende das características do conjunto de dados e dos recursos computacionais disponíveis.

O modelo de partida (*baseline*) adotado neste trabalho foi o YOLOv8s inicializado com pesos pré-treinados no COCO e submetido a ajuste fino sobre as imagens de cartas Pokémon TCG, com a classe única *defeito*. Treinado com imagens RGB e sem aumento de dados, esse modelo corresponde à Configuração 1 e serviu de referência para o estudo fatorial, que mediu o efeito do aumento de dados e do realce de micro-relevo. A cabeça de detecção adicional P2 e a resolução de entrada foram avaliadas depois, alterando-se um componente por vez sobre a configuração de melhor desempenho, procedimento apresentado

na Seção 2.2.12 e detalhado no Capítulo 3.

2.2.7 Transfer Learning

Transfer learning é uma estratégia de aprendizado de máquina que consiste em aproveitar o conhecimento adquirido por um modelo treinado em um domínio fonte para melhorar o desempenho em um domínio alvo distinto (SITU et al., 2023). A motivação para essa abordagem reside na observação de que modelos profundos aprendem representações hierárquicas de características visuais que tendem a ser transferíveis entre domínios, especialmente nas camadas mais rasas da rede, que capturam padrões genéricos como bordas, texturas e gradientes (SITU et al., 2023).

Na prática, o *transfer learning* em visão computacional é implementado por meio do ajuste fino: um modelo pré-treinado em um conjunto de dados de larga escala, como ImageNet ou COCO, tem seus pesos utilizados como ponto de partida, sendo então re-treinado total ou parcialmente sobre o conjunto de dados alvo (DOBRZYCKI; BERNARDOS; CASAR, 2025). Essa abordagem permite que o modelo se adapte às características específicas do novo domínio sem partir de uma inicialização aleatória, reduzindo significativamente a quantidade de dados rotulados necessária para alcançar bom desempenho (SITU et al., 2023).

Em cenários com baixo volume de dados, o *transfer learning* é especialmente relevante. Um modelo treinado do zero com poucas imagens tende ao sobreajuste (*overfitting*): ele se ajusta aos exemplos de treino, inclusive aos detalhes particulares de cada um, e passa a errar em imagens novas. He, Girshick e Dollár (2019) mediram esse efeito em detecção de objetos. Com apenas mil imagens de treino do COCO, um detector de dois estágios que partiu de pesos pré-treinados no ImageNet atingiu 9,9 pontos de AP, em uma escala de 0 a 100. O mesmo detector treinado do zero atingiu 3,5, e os autores atribuem essa diferença ao sobreajuste causado pela falta de dados. Quando o número de imagens de treino aumentou, a vantagem do pré-treino diminuiu. Isso indica que o pré-treino ajuda mais justamente quando há poucos dados.

Esse benefício, porém, vale apenas para as camadas que já existiam no modelo pré-treinado. Quando uma parte nova é acrescentada à arquitetura, como um nível de detecção a mais, essa parte e as camadas que mudam de posição ou de formato para recebê-la, como a própria cabeça de detecção, não têm pesos pré-treinados correspondentes e começam com valores aleatórios, situação verificada na variante usada neste trabalho e quantificada no Capítulo 3. Li et al. (2023) mediram o efeito de manter partes de um detector com valores aleatórios. Quando o *neck* e a cabeça de detecção também receberam pré-treino, o desempenho foi maior do que quando começaram aleatórios, inclusive quando o ajuste fino usou apenas 1% das imagens de treino do COCO. Para os autores, começar com partes aleatórias é uma das diferenças entre o pré-treino e o ajuste fino que podem limitar o resultado e tornar a convergência mais lenta. Esses detectores não eram da família YOLO,

e o estudo não tratou de camadas acrescentadas a um modelo existente; por isso, neste trabalho, essa relação é tratada como hipótese para explicar o desempenho da variante com a cabeça P2, descrita na Seção 2.2.11, e é examinada com os resultados no Capítulo 3.

2.2.8 Detecção de Objetos em Cenários com Dados Limitados

A detecção de objetos em cenários com dados limitados constitui um problema relevante em visão computacional, especialmente em domínios nos quais a coleta e a anotação de imagens são custosas. Neste trabalho, o termo *baixo volume de dados* refere-se a conjuntos nos quais o número de exemplos anotados é insuficiente para treinar modelos de detecção profundos com capacidade de generalização adequada, tornando necessário o uso de estratégias complementares como *transfer learning* e aumento de dados (CHEN et al., 2021). Não há um limiar absoluto para esse conceito, pois o volume que se mostra limitado depende da tarefa e do modelo. No presente trabalho, esse cenário é caracterizado pelo conjunto de 206 cartas disponível, volume inferior ao das 593 cartas esportivas usadas por Nahar et al. (2025a) na classificação de cantos, conjunto que os próprios autores caracterizam como pequeno.

Em tarefas de detecção, além de reconhecer a classe de interesse, o modelo também deve localizar espacialmente cada instância na imagem por meio de caixas delimitadoras (RAMOS; SAPPA, 2025). Essa exigência torna o processo mais sensível à escassez de exemplos rotulados, uma vez que, além da imagem, é necessário dispor de anotações consistentes indicando a localização de cada objeto ou defeito de interesse (SITU et al., 2023). Em conjuntos reduzidos, modelos baseados em *deep learning* tendem a apresentar maior risco de sobreajuste e menor capacidade de generalização, pois há poucos exemplos disponíveis para representar adequadamente a variabilidade visual dos objetos ou defeitos (WANG; LI; WANG, 2022). Esse problema torna-se ainda mais crítico em aplicações de inspeção visual, nas quais os defeitos podem ser pequenos, sutis, desbalanceados e difíceis de distinguir do fundo da imagem (CHEN et al., 2021; WANG; LI; WANG, 2022). A pesquisa não adota um protocolo formal de *Few-Shot Object Detection*, em que o modelo aprende classes novas a partir de poucos exemplos em divisões padronizadas dos dados, porque aqui não há classes novas: o detector aprende uma única classe, *defeito*, com todas as anotações disponíveis. Ela se insere no contexto da detecção de objetos com baixo volume de dados (SITU et al., 2023), avaliando estratégias como *transfer learning*, aumento de dados e uso de imagens de realce de micro-relevo para melhorar o desempenho do detector. A cabeça de detecção adicional P2 e a resolução de entrada, também avaliadas, respondem a outra limitação, o tamanho reduzido dos defeitos na imagem, tratada na Seção 2.2.11.

Uma forma de verificar se o volume de dados limita o desempenho é a curva de aprendizado, que descreve o desempenho de um modelo em função do tamanho do conjunto de treino (VIERING; LOOG, 2023). Ela é obtida treinando o mesmo modelo com

frações crescentes dos dados de treino e avaliando todas as versões no mesmo conjunto de avaliação. A curva de aprendizado não se confunde com a curva de treino, que acompanha o desempenho ao longo de um único treinamento, a cada passagem completa pelos dados de treino, chamada época. Se o desempenho continua a subir nas últimas frações, mais dados tendem a melhorar o modelo; se a inclinação da curva se torna pequena, ela se aproxima de um patamar, e coletar mais dados rende pouco (VIERING; LOOG, 2023). A mesma ferramenta foi proposta para avaliar decisões de projeto, como o pré-treino e o aumento de dados, no regime de poucos dados (HOIEM et al., 2021). Estimar quantos exemplos a mais seriam necessários para atingir um desempenho-alvo, por outro lado, é mais difícil: extrapolar a curva a partir de poucos dados produz estimativas pouco confiáveis (MAHMOOD et al., 2022). Por isso, neste trabalho, a curva de aprendizado foi usada para verificar se o desempenho já havia se estabilizado, e não para prever o número de cartas necessário.

2.2.9 Aumento de Dados

O aumento de dados (*data augmentation*) é um conjunto de técnicas que amplia a diversidade do conjunto de treinamento por meio de transformações aplicadas às imagens existentes, sem a necessidade de coletar novos exemplos. O princípio é expor o modelo, durante o treinamento, a variações plausíveis das imagens, de modo que ele não dependa de detalhes particulares dos poucos exemplos disponíveis. Na detecção de defeitos superficiais com pequenas amostras, o aumento de dados é apontado como uma das quatro linhas de solução para o problema (CHEN et al., 2021).

As transformações usadas no aumento de dados costumam ser de dois tipos. As geométricas, como espelhamento, rotação, translação e mudança de escala, alteram a posição, a orientação e o tamanho dos objetos na imagem. As fotométricas alteram a cor e o brilho, por exemplo por variações de matiz, saturação e valor no espaço de cor HSV (*Hue, Saturation, Value*). Na biblioteca Ultralytics, usada neste trabalho, essas transformações são aplicadas durante o treinamento, a cada vez que uma imagem é carregada, com intensidade sorteada dentro de limites definidos nos parâmetros de configuração do treino, chamados hiperparâmetros (JOCHER; CHAURASIA; QIU, 2023). A biblioteca oferece também o mosaico, que combina quatro imagens de treino em uma única imagem e recorta dela uma janela do tamanho da entrada da rede. A mudança de escala, por sua vez, amplia ou reduz a imagem por um fator sorteado; quando reduz, os objetos ficam menores, o que importa quando eles já estão próximos do passo do nível de detecção mais fino, apresentado na Seção 2.2.6.

Em cenários com conjuntos de dados reduzidos, o aumento de dados atua contra o sobreajuste: ao aumentar a diversidade efetiva do conjunto de treinamento, reduz a dependência do modelo em relação a padrões específicos dos exemplos disponíveis (CHEN et al., 2021). Uma medição do tamanho desse efeito vem da classificação de imagens: com

ajuste fino, o erro obtido com aumento de dados foi aproximadamente igual ao obtido sem ele usando 1,8 vez mais exemplos, o que levou os autores a interpretar o aumento de dados como um multiplicador do valor de cada exemplo (HOIEM et al., 2021). Neste trabalho, o aumento de dados foi um dos dois fatores do estudo fatorial, o que permitiu medir seu efeito isolado e combinado com o realce de micro-relevo.

2.2.10 Pré-processamento e realce de micro-relevo

Em uma fotografia, o relevo da superfície não é registrado diretamente: ele aparece apenas de forma indireta, como variações locais de brilho, porque a inclinação do papel em um vinco ou em um amassado altera a quantidade de luz refletida em direção à câmera. A intensidade dessas variações depende da iluminação da captura, que condiciona o contraste com que o defeito aparece na imagem (ZHENG et al., 2021). O realce de micro-relevo não reconstrói a forma tridimensional da superfície; ele amplifica essas variações locais de brilho, para que se destaquem do restante da imagem. Métodos baseados em filtragem, como transformada de Fourier, filtros de Gabor e transformada *wavelet*, integram o repertório clássico de detecção de defeitos em superfícies (CHEN et al., 2021), e operadores de filtragem também têm sido aplicados como etapa de pré-processamento em sistemas de inspeção visual (SAWADA; FUJI; AIKAWA, 2024; JIANG et al., 2023).

No contexto da inspeção visual automatizada, filtros de gradiente direcional têm sido aplicados como etapa de pré-processamento para realce de defeitos em superfícies industriais. Sawada, Fuji e Aikawa (2024) empregam o filtro *emboss*, que realça a variação de intensidade em uma direção e dá à imagem aparência de relevo, aplicado em oito direções, na etapa de extração de defeitos em superfícies pintadas, dentro de um pipeline clássico de morfologia matemática que antecede a classificação por rede convolucional. Os autores não avaliam isoladamente a contribuição do realce por gradiente, de modo que o trabalho evidencia a aplicabilidade da técnica ao problema, e não sua superioridade sobre a ausência de pré-processamento. De forma complementar, Jiang et al. (2023) combinam a equalização adaptativa de histograma com limitação de contraste (CLAHE, do inglês *Contrast Limited Adaptive Histogram Equalization*) a um método de equalização automática de cor (ACE), fundindo as duas imagens realçadas, como pré-processamento anterior à detecção com o YOLOv3. Como o CLAHE não foi avaliado separadamente, o trabalho mostra que o operador já foi empregado antes de um detector da família YOLO, e não o seu efeito isolado; na representação adotada neste trabalho, ele foi aplicado apenas ao brilho da imagem, como um dos canais da representação de entrada descrita adiante. Os operadores de gradiente direcional respondem à taxa de variação da intensidade, isto é, a bordas. Defeitos como riscos e vincos, contudo, não constituem bordas, e sim estruturas alongadas de espessura reduzida com intensidade semelhante nos dois lados, que correspondem a estruturas de segunda ordem. Gruber e Haselmann (2021) sustentam que a filtragem baseada nos autovalores da matriz Hessiana, que descreve a curvatura

local da intensidade da imagem, é adequada à inspeção de superfícies precisamente porque os defeitos observados são acompanhados de estruturas dessa natureza, e registram que as derivadas que compõem a Hessiana são obtidas pela convolução da imagem com as derivadas de uma função gaussiana, chamada núcleo, cujo desvio padrão determina a escala das estruturas amplificadas. Essa seletividade de escala é relevante no presente caso, uma vez que a carta apresenta arte impressa cujos contornos possuem escala e contraste superiores aos dos defeitos investigados, e que operadores de primeira ordem amplificam de forma indistinta.

A representação de realce adotada neste trabalho ocupa os três canais de entrada com a luminosidade original da imagem, com essa luminosidade realçada por um primeiro operador e com a resposta de um segundo operador, calculada sobre a imagem já realçada. O primeiro é o CLAHE. Nele, a imagem é dividida em uma grade de regiões retangulares, chamadas ladrilhos; o histograma de intensidades de cada ladrilho é equalizado, o que estica o contraste dentro dele; um limite de corte restringe esse estiramento, para não amplificar o ruído; e os resultados de ladrilhos vizinhos são combinados por interpolação bilinear (JIANG et al., 2023). Neste trabalho, o CLAHE foi aplicado ao canal de luminosidade (L^*) do espaço de cor CIELAB, que separa o brilho da cor, e não aos três canais RGB; assim, ele atua sobre o brilho, em que o relevo se manifesta, sem alterar a cor. O segundo operador é a medida de Frangi et al. (1998), calculada a partir dos autovalores da matriz Hessiana em várias escalas: ela responde a estruturas alongadas, como cristas e vales, e atenua regiões uniformes e manchas arredondadas. Os autores fixaram em 0,5 o parâmetro que controla a sensibilidade ao alongamento da estrutura e indicaram, para o parâmetro que controla a supressão das regiões de baixo contraste, metade do maior valor da norma da Hessiana na imagem, valor que funcionou na maioria dos casos que avaliaram. Esses mesmos valores foram usados neste trabalho. Por construção, a medida favorece os defeitos alongados, como riscos e vincos, e tende a atenuar manchas, pontos e o *whitening* em área, que também estão entre os defeitos do conjunto de dados; a luminosidade original e a luminosidade com CLAHE, nos outros dois canais, preservam a informação desses defeitos.

O YOLOv8 pré-treinado espera uma imagem de três canais. Jiang et al. (2021) observam que, quando a entrada tem um único canal, a solução mais simples é replicá-lo três vezes, o que desperdiça dois canais. Na detecção de navios em imagens de radar, que têm um único canal, os autores substituíram duas das cópias por versões da mesma imagem que destacam os detalhes finos (sub-bandas de alta frequência), e o AP do YOLO-V4-tiny passou de 88,08% para 89,64%, um ganho de 1,56 ponto percentual. Na mesma linha, a representação de realce de micro-relevo avaliada neste trabalho ocupa os três canais com informações diferentes da mesma imagem; sua composição e o procedimento que a escolheu entre as alternativas testadas são descritos na Seção 3.3.1. Essa substituição tem um custo possível: as primeiras camadas da rede pré-treinada aprenderam padrões de imagens RGB comuns, e uma entrada formada por canais realçados se afasta dessa

distribuição, o que pode reduzir parte do benefício do pré-treino descrito na Seção 2.2.7. Ahmad et al. (2025) observaram uma tendência compatível com essa hipótese ao aplicar o CLAHE a radiografias de coluna, na segmentação de vértebras com um Mask R-CNN: o modelo pré-treinado teve uma pequena queda na sobreposição entre a segmentação prevista e a real, e o mesmo modelo treinado do zero, um ganho marginal. Nenhuma das duas diferenças foi estatisticamente significativa. Os autores sugerem que o realce introduz uma mudança de domínio que pode reduzir a utilidade das características pré-treinadas. No trabalho de Jiang et al. (2021), a entrada original já tinha um único canal, situação diferente da substituição de uma imagem RGB. Até onde a busca bibliográfica identificou, o uso de uma representação de realce de micro-relevo como entrada de um detector YOLOv8 não havia sido investigado na inspeção de cartas colecionáveis.

2.2.11 Detecção de objetos pequenos

A detecção de objetos pequenos constitui um subcampo com dificuldades próprias, distintas das que caracterizam a detecção em cenários com dados limitados. Cheng et al. (2023) identificam a perda de informação como um de seus desafios centrais: detectores convencionais reduzem progressivamente a resolução espacial ao longo do *backbone*, e a decisão da cabeça de detecção é tomada sobre a representação resultante. Essa perda praticamente não afeta objetos grandes e médios, cujas características sobrevivem à subamostragem, mas é determinante para objetos pequenos, dos quais resta pouca informação nas camadas finais.

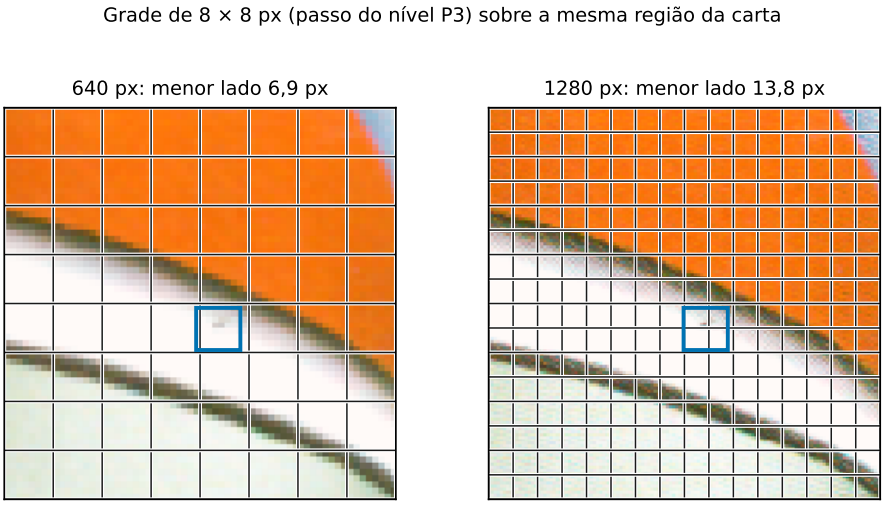
Essa perda está ligada ao passo dos níveis de detecção, apresentado na Seção 2.2.6. Na resolução de entrada de 640 pixels, o nível P3, de passo 8, é um mapa de até 80×80 pontos, cada qual resumindo um bloco de 8×8 pixels da imagem de entrada. Um defeito cujo menor lado é menor que 8 pixels ocupa apenas parte de cada bloco em que aparece; o restante do bloco é fundo, isto é, a superfície da carta ao redor do defeito. O ponto que resume o bloco combina os dois sinais, e o do defeito fica diluído no do fundo: enfraquecido, mas não necessariamente ausente. Por isso, a detecção desses defeitos é mais difícil, sem ser impossível. Em defeitos de placas de circuito impresso, Xia et al. (2023) afirmam que as características de alvos menores que 10×10 pixels se tornam muito fracas, ou desaparecem por completo, no mapa de passo 8.

Há duas formas diretas de reduzir essa limitação. A primeira é acrescentar um nível de detecção mais fino. Na variante P2 do YOLOv8, a cabeça de detecção passa a decidir também sobre o nível P2, de passo 4, além de P3, P4 e P5, e o *neck* ganha as camadas necessárias para levar as características até esse nível (JOCHER; CHAURASIA; QIU, 2023). Como o mapa de passo 4 tem quatro vezes mais pontos que o de passo 8, o custo de memória e de processamento aumenta; em um YOLOv8l, o acréscimo do nível P2 elevou o custo computacional em cerca de 20% (LIU; JUANG, 2026). Há também um efeito colateral apontado na literatura. Em defeitos de placas de circuito impresso, com um

YOLOv5s, o acréscimo do nível P2 manteve o mAP@0,5 em 97,7%, elevou o mAP@0,5:0,95 de 68,4% para 73,3% e a revocação de 95,5% para 96,5%, enquanto a precisão passou de 98,8% para 98,1%; os autores apontam que o mapa P2 traz ruído de fundo e o tratam com um módulo de atenção ao contexto global (XIA et al., 2023).

A segunda forma é aumentar a resolução de entrada. Como a imagem é redimensionada até que seu lado maior meça a resolução de entrada, conforme descrito na Seção 1.1, dobrar essa resolução dobra o tamanho, em pixels, de cada defeito, e o detalhe ganho é real quando a fotografia original tem mais pixels do que a resolução de entrada, como ocorre neste conjunto de dados. A Figura 3 mostra o mesmo defeito da Figura 2 nas duas resoluções: o menor lado passa de 6,9 para 13,8 pixels, e o defeito, antes menor que um bloco do nível P3, passa a ser maior que ele. Liu e Juang (2026) compararam as duas formas na detecção de objetos pequenos em imagens de drone, com o YOLOv8l: passar a resolução de entrada de 640 para 1280 pixels elevou o mAP@0,5 de 12,7% para 15,9%, um ganho relativo de 25%, ao custo de cerca de quatro vezes mais processamento, enquanto o acréscimo do nível P2, medido a 640 pixels, elevou-o de 12,7% para 13,5%, um ganho relativo de 6%. Os lotes de treinamento, isto é, o número de imagens processadas a cada atualização dos pesos, foram diferentes nas duas resoluções (8 imagens a 640 pixels e 4 a 1280), o que limita a comparação direta. Neste trabalho, a cabeça P2 foi avaliada na resolução de 1280 pixels, condição que os autores não mediram.

Figura 3 – O mesmo defeito na imagem de entrada de 640 e de 1280 pixels, com a grade de 8 pixels do nível P3 sobre a mesma região da carta.



Fonte: Elaborado pelo autor (2026).

A dificuldade não se restringe à arquitetura: alcança também a métrica de avaliação. Xu et al. (2022) demonstram que a *Intersection over Union* é altamente sensível ao desvio de localização quando o objeto é diminuto. Para um objeto de 5×8 pixels, aumentar o desvio da caixa predita de 1 para 3 pixels, na diagonal, reduz o IoU de 0,54 para 0,14; para

um objeto de 200 × 320 pixels, o mesmo aumento o reduz apenas de 0,97 para 0,91. Em termos práticos, quanto menor o objeto, menor a tolerância a erro de localização admitida pela métrica. Como a própria caixa de referência é traçada à mão e sua borda pode variar em alguns pixels, parte dos defeitos pequenos pode não atingir o limiar de IoU mesmo com uma predição bem localizada, o que limita o desempenho mensurável nesses defeitos independentemente da capacidade do detector de percebê-los.

2.2.12 Estudo fatorial e estudo de ablação

O estudo de ablação é uma estratégia experimental utilizada para avaliar a contribuição de componentes específicos de um modelo ou *pipeline*. Em redes neurais profundas, esse tipo de estudo consiste em medir o desempenho do modelo após a remoção ou alteração de determinados componentes, permitindo compreender a contribuição relativa desses elementos para o desempenho geral (SHEIKHOLESLAMI et al., 2021). Em vez de analisar apenas o desempenho de uma configuração final completa, a ablação compara diferentes versões do experimento, adicionando, removendo ou modificando elementos de forma controlada. Dessa forma, torna-se possível identificar quais componentes efetivamente contribuem para a melhoria do desempenho e quais apresentam impacto reduzido ou dependente do contexto.

Em modelos de detecção de objetos baseados em YOLO, esse tipo de análise é especialmente relevante para avaliar estratégias de treinamento e adaptação de modelos pré-treinados. Liu, Quijano e Crawford (2022) conduziram um estudo de ablação explícito em uma arquitetura YOLOv5 modificada para detecção de objetos pequenos em imagens de drone com dados limitados, avaliando a contribuição individual de cada componente proposto. Dobrzycki, Bernardos e Casar (2025) investigaram sistematicamente diferentes configurações de *transfer learning* em arquiteturas YOLOv8 e YOLOv10, comparando treinamento do zero, ajuste fino completo e congelamento parcial de camadas, em que parte dos pesos é mantida fixa durante o treino, e concluíram que não há estratégia universalmente superior e que o desempenho depende das características do conjunto de dados. Chen et al. (2024) também conduziram um estudo de ablação sobre os componentes propostos para o detector, acrescentando-os um a um.

O estudo fatorial, por sua vez, cruza todas as opções de dois ou mais fatores: cada opção de um fator é combinada com cada opção dos demais, e cada combinação forma uma configuração. Neste trabalho, os fatores foram o aumento de dados (sem ou com) e a representação de entrada (RGB ou realce de micro-relevo), o que resultou em um estudo fatorial 2 × 2, com quatro configurações. Esse desenho contém as comparações de uma ablação, pois cada estratégia aparece desligada e ligada enquanto a outra é mantida fixa (com uma ressalva sobre o aumento de dados, descrita na Seção 3.3.1), e por isso também pode ser descrito como uma ablação. Além dessas comparações, ele permite verificar se o efeito de um fator depende da opção adotada no outro, o que alterar um componente

por vez não mostra. Essa dependência é chamada de interação; neste trabalho, ela foi testada carta a carta, comparando o efeito do aumento de dados com imagens RGB e com imagens de realce. Ao longo do texto, a expressão estudo fatorial designa esse cruzamento 2×2, e a expressão ablação designa as avaliações feitas depois dele sobre a configuração de melhor desempenho, em que um único componente foi alterado por vez: o acréscimo da cabeça de detecção P2 e a resolução de entrada. Em todas as configurações, o ajuste fino foi aplicado sem congelamento de camadas.

2.2.13 Validação Cruzada

A validação cruzada é um método de estimação de desempenho que busca reduzir a dependência dos resultados em relação a um particionamento específico dos dados. Na variante em k dobras (*k-fold cross-validation*), o conjunto de dados é dividido em k subconjuntos de tamanho aproximadamente igual, chamados dobras. Em cada uma das k rodadas, uma dobra distinta é reservada para avaliação, e as demais são usadas para treinamento, de modo que cada exemplo é avaliado exatamente uma vez, por um modelo que não o viu no treinamento. Na variante estratificada, a divisão preserva em cada dobra a proporção das classes (KOHAVI, 1995); neste trabalho, com classe única, a estratificação usou outra característica das cartas, descrita no Capítulo 3. Quando o objetivo não é apenas estimar o desempenho de um modelo, mas comparar configurações entre si, a média das métricas sobre as rodadas descarta uma informação útil: todas as configurações foram avaliadas sobre exatamente as mesmas dobras, o que permite compará-las em pares, como descrito na Seção 2.2.14.

Em cenários com baixo volume de dados, essa abordagem é especialmente relevante: com poucos exemplos, um único particionamento pode produzir resultados otimistas ou pessimistas, dependendo de quais amostras caem no conjunto de avaliação (KOHAVI, 1995). O valor de k adotado, as dobras mantidas fixas entre todas as configurações e a forma como as cartas foram distribuídas entre elas são descritos no Capítulo 3.

Em cada rodada, o bloco de treinamento foi subdividido em um conjunto de treino efetivo e um conjunto de validação interna, com cerca de 20% das cartas do bloco. A validação interna não participou da atualização dos pesos, mas foi usada para todas as escolhas feitas dentro de cada rodada: a parada antecipada (*early stopping*), que interrompe o treino quando o desempenho na validação interna deixa de melhorar e mantém os pesos da melhor época, porque a piora nessa validação sinaliza o início do sobreajuste (PRECHELT, 1998); e o limiar de confiança usado no cálculo do F1, apresentado na Seção 2.2.5, escolhido como o que maximizou o F1 nela. Fazer essas escolhas na dobra de avaliação tornaria a estimativa otimista, porque o erro medido no conjunto usado para escolher foi diretamente minimizado por essa escolha e não deve ser usado para estimar o desempenho (CAWLEY; TALBOT, 2010). Por isso, nessas escolhas, a dobra de avaliação permaneceu isolada durante o treinamento de cada rodada e foi usada apenas para medir o desempenho final

dessa rodada. O operador de realce de micro-relevo, por sua vez, foi escolhido uma única vez, na validação interna da rodada da primeira dobra, e mantido nas demais; como essa validação interna contém cartas que são avaliadas nas outras rodadas, essa escolha não ficou isolada delas, limitação discutida no Capítulo 3.

2.2.14 Comparação estatística entre configurações

Reportar a média e o desvio padrão de uma métrica sobre as rodadas da validação cruzada descreve o desempenho de uma configuração, mas não é suficiente para afirmar que uma configuração supera outra. A variação decorrente da amostra de avaliação e do próprio treinamento pode ser da mesma ordem de grandeza que as diferenças entre as configurações comparadas; por isso, decidir se uma supera a outra exige levar essa variação em conta, e não apenas comparar médias (BOUTHILLIER et al., 2021).

A alternativa é o teste pareado. Quando as mesmas partições são utilizadas em todas as configurações, cada unidade de avaliação é observada uma vez em cada configuração, e a comparação pode ser feita sobre a diferença dentro de cada par. Com isso, a variação entre as unidades, que é comum às configurações comparadas, deixa de pesar na incerteza da diferença; Demšar (2006) descreve esse efeito na comparação de dois classificadores sobre vários conjuntos de dados. Neste trabalho, a unidade de avaliação foi a carta: com as dobras fixas entre as configurações, cada uma das 206 cartas foi avaliada uma vez por configuração, por um modelo que não a viu no treinamento, e recebeu uma nota própria, o F1 por carta, definido na Seção 2.2.5, o que forma 206 pares nas comparações do estudo fatorial e menos nas análises feitas sobre parte das cartas, descritas no Capítulo 3.

O teste de Wilcoxon pareado (*Wilcoxon signed-ranks test*) é a alternativa não paramétrica ao teste t pareado, que pressupõe diferenças com distribuição normal. As diferenças observadas em cada par são ordenadas pelo valor absoluto e recebem postos; somam-se separadamente os postos das diferenças positivas (R^+) e das negativas (R^-), e a estatística do teste é $T = \min(R^+, R^-)$, comparada a um valor crítico, obtido de tabela quando há poucos pares ou de uma aproximação pela distribuição normal quando há muitos. O resultado é expresso pelo valor-p: a probabilidade de observar diferenças ao menos tão desequilibradas quanto as obtidas se não houvesse diferença real entre as configurações, situação chamada de hipótese nula; quando o valor-p fica abaixo do nível de significância escolhido, a diferença é considerada estatisticamente significativa. Demšar (2006) recomenda esse teste para comparar algoritmos de aprendizado sobre vários conjuntos de dados independentes, cada um fornecendo um par, por não pressupor normalidade das diferenças e por ser menos sensível a valores extremos observados em poucas unidades. Sobre um único conjunto de teste, a comparação também pode ser feita caso a caso: na análise de resultados de desafios de imagens biomédicas, Wiesenfarth et al. (2021) comparam os algoritmos participantes, a partir dos resultados já obtidos no desafio, pela métrica de cada caso de teste, com o teste de Wilcoxon pareado e a correção de Holm. Neste trabalho,

os casos são as cartas, avaliadas por modelos treinados com partes sobrepostas do mesmo conjunto de dados. O teste trata esses modelos como fixos e mede se a diferença entre eles se sustenta ao variar as cartas avaliadas, mas não inclui a variação que surgiria ao repetir o treinamento, por exemplo com outra semente aleatória.

O número de pares condiciona o menor valor-p que o teste pode alcançar. Com n pares existem 2^n arranjos de sinais igualmente prováveis sob a hipótese nula, de modo que o menor valor-p bilateral possível é $2/2^n$. Para $n = 5$ esse limite vale 0,0625, superior ao nível de significância usual de 0,05: com cinco pares o teste não rejeita a hipótese nula ainda que todas as diferenças apontem no mesmo sentido. Se a unidade de análise fosse a dobra, a validação cruzada em cinco dobras adotada neste trabalho, descrita no Capítulo 3, forneceria exatamente cinco pares, e nenhuma comparação poderia ser conclusiva; com a carta como unidade, o número de pares chega a 206. A escolha da unidade de análise, portanto, condiciona a própria possibilidade de conclusão do experimento.

Quando várias comparações são feitas com o mesmo nível de significância, a chance de ao menos uma delas apontar uma diferença por acaso cresce com o número de comparações. A correção de Holm controla esse risco para o conjunto das comparações: sendo m o número de comparações, os valores-p são ordenados do menor para o maior; o menor é comparado a α/m, o segundo a $\alpha/(m-1)$, e assim por diante; assim que uma comparação não atinge o seu limite, ela e todas as seguintes não são rejeitadas, isto é, não indicam diferença significativa. Demšar (2006) apresenta o procedimento como etapa posterior ao teste de Friedman, usado para comparar vários classificadores ao mesmo tempo, mas registra que ele pode ser usado, de forma geral, para controlar o erro do conjunto de testes quando várias hipóteses são testadas.

O teste pareado responde se uma configuração supera a outra, mas não informa a incerteza de uma métrica isolada, como o mAP@0,5 de um modelo. Para isso, pode-se usar um intervalo de confiança por *bootstrap*. No *bootstrap* não paramétrico, sorteiam-se, com reposição, tantas unidades quanto as do conjunto original, recalcula-se a métrica sobre a amostra sorteada e repete-se o procedimento muitas vezes; no método percentil, os percentis 2,5 e 97,5 das métricas obtidas delimitam o intervalo de confiança de 95% (DICICCIO; EFRON, 1996). Os mesmos autores consideram duas mil repetições adequadas para construir intervalos de confiança e descrevem também um intervalo que parte dos mesmos percentis e acrescenta correções para melhorar a precisão da cobertura, isto é, a frequência com que o intervalo contém o valor verdadeiro; o método percentil corresponde a esse intervalo sem as correções. Neste trabalho, foi usado o método percentil, com duas mil repetições. A unidade sorteada precisa ser independente: quando há várias observações do mesmo sujeito, sortear as observações isoladamente ignora a correlação entre elas e produz intervalos com cobertura abaixo do nível nominal, e o correto é sortear o sujeito inteiro, com todas as suas observações (PANG et al., 2023). Ignorar essa estrutura hierárquica dos dados é um erro frequente ao agregar métricas (REINKE et al., 2024). Neste trabalho,

os defeitos de uma mesma carta não são independentes entre si, e por isso a unidade sorteada foi a carta. Um intervalo assim reflete apenas a incerteza decorrente da amostra de avaliação, e não a variação que surgiria ao repetir o treinamento.

2.3 Trabalhos correlatos

Os trabalhos relacionados selecionados nesta seção foram escolhidos com base no critério de proximidade com o problema investigado, isto é, a detecção de defeitos visuais com apoio de visão computacional em cenários de dados limitados, com aplicação à graduação de cartas colecionáveis. Embora nem todos estejam inseridos no mesmo domínio, todos enfrentam desafios práticos ou metodológicos próximos aos deste trabalho, seja no contexto direto de cartas colecionáveis, seja na comparação de estratégias de treinamento para detectores baseados em YOLO. Para cada trabalho, são apresentados o problema tratado, o método, os resultados, as limitações e a diferença em relação a este trabalho.

2.3.1 Trabalho 1: *Automated corner grading of trading cards: Defect identification and confidence calibration through deep learning*

Nahar et al. (2025a) abordaram a automação da inspeção de defeitos em cartas colecionáveis, com foco na graduação de cantos. O problema é próximo do investigado neste trabalho, pois ambos usam visão computacional para apoiar a identificação de defeitos visuais em cartas, mas o domínio difere: os autores trabalharam com cartas esportivas, digitalizadas em *scanner* justamente para reduzir reflexos e sombras da captura, enquanto este trabalho usa fotografias de cartas Pokémon TCG, todas com a frente holográfica. Os autores propuseram um modelo baseado em *transfer learning* com a arquitetura DenseNet201 para classificar os defeitos de cantos em quatro níveis de severidade, além de incorporar técnicas de calibração de confiança e um mecanismo de revisão humana (*human-in-the-loop*). Os resultados reportaram acurácia média de 83% na classificação da severidade dos cantos. Os mesmos autores apresentaram também um sistema integrado, que reúne a avaliação de cantos, bordas e superfície e igualmente se baseia na classificação de recortes (NAHAR et al., 2025b). O estudo está restrito ao critério de cantos, utiliza um conjunto de 593 cartas (4.744 imagens de cantos), que os próprios autores caracterizam como pequeno, e não compara sistematicamente diferentes estratégias de treinamento; por classificar recortes, o modelo também não localiza o defeito dentro do canto. O presente trabalho diferencia-se por detectar e localizar cada defeito em toda a carta e por comparar, em um estudo fatorial com validação cruzada e teste pareado, o efeito de diferentes estratégias de treinamento com poucos dados.

2.3.2 Trabalho 2: *NHD-YOLO: Improved YOLOv8 using optimized neck and head for product surface defect detection with data augmentation*

Chen et al. (2024) investigam o problema da detecção de defeitos em superfícies de produtos industriais, propondo melhorias arquiteturais sobre o YOLOv8 combinadas com estratégias específicas de aumento de dados. Assim como no presente trabalho, os autores buscam aprimorar o desempenho de detectores baseados em YOLOv8 para identificação de defeitos em superfícies visualmente complexas. A metodologia proposta introduz modificações nos módulos de *neck* e *head* da arquitetura e emprega uma técnica de aumento de dados baseada em cópia-e-cola seletiva para pequenos objetos. Os experimentos foram conduzidos em três conjuntos de dados: defeitos em aço da Northeastern University (NEU-DET), placas de circuito impresso da Peking University (PKU-Market-PCB) e o conjunto COCO. Os resultados mostram ganhos de 1,1 a 1,8 ponto de AP no NEU-DET, de 1,4 ponto no PKU-Market-PCB e de 1,5 ponto no COCO sobre o YOLOv8 de mesmo tamanho, com velocidade de inferência ligeiramente menor. Apesar da proximidade metodológica com o presente trabalho em termos de arquitetura e uso de aumento de dados, o estudo apresenta limitações para o contexto deste trabalho: utiliza conjuntos de dados de defeitos industriais já estabelecidos e públicos, avaliados em uma única divisão entre treino e teste, sem repetições nem teste estatístico, de modo que os ganhos de 1 a 2 pontos não vêm acompanhados de medida de incerteza. O presente trabalho diferencia-se por comparar as estratégias com validação cruzada e teste pareado por carta, no domínio de cartas colecionáveis, no qual a anotação especializada limita o volume de dados disponível.

2.3.3 Trabalho 3: *Systematic Evaluation of YOLOv8 Variants for UAV-Based Object Detection*

Liu e Juang (2026) investigaram a detecção de objetos pequenos em imagens aéreas capturadas por drones, com o YOLOv8. O problema se aproxima deste trabalho pelo tamanho reduzido dos objetos e pela pergunta sobre quais estratégias melhoram o detector nessa condição. O método comparou, sob as mesmas condições experimentais, a capacidade do modelo, a resolução de entrada de 640 e de 1280 pixels e o acréscimo do nível de detecção P2. Os resultados, apresentados na Seção 2.2.11, favoreceram a resolução de entrada sobre o nível P2, e os autores concluíram que, nesse cenário, a resolução de entrada e a capacidade do modelo devem ser priorizadas antes de mudanças na arquitetura. Como limitações para o presente contexto, o domínio é outro, com cenas abertas e várias categorias de objetos, e o nível P2 foi avaliado apenas na resolução de 640 pixels. O presente trabalho diferencia-se por avaliar a cabeça P2 na resolução de 1280 pixels, em defeitos de cartas colecionáveis, e por comparar as configurações carta a carta, com teste pareado.

A Tabela 2 sintetiza as diferenças entre os trabalhos analisados e este trabalho.

Tabela 2 – Comparação entre os trabalhos relacionados e este trabalho

Trabalho	**Objetivo**	**Tecnologia**	**Avaliação**	**Limitação**
Nahar et al. (2025a)	Graduação automática de cantos de cartas esportivas	DenseNet201, TL e calibração de confiança	Acurácia e calibração de confiança	Só cantos; classifica recortes sem localizar o defeito
Chen et al. (2024)	Detecção de defeitos em superfícies de produtos	YOLOv8 modificado e aumento de dados	mAP em NEU-DET, PKU-Market-PCB e COCO	Conjuntos industriais consolidados, sem foco em poucos dados
Liu e Juang (2026)	Estratégias para objetos pequenos em imagens aéreas	YOLOv8: capacidade, resolução de entrada e nível P2	mAP@0,5 e custo computacional	Outro domínio; nível P2 avaliado só a 640 pixels
Este trabalho	Comparação de estratégias de treinamento com poucos dados em cartas Pokémon TCG	YOLOv8s com TL, aumento de dados, realce de micro-relevo, cabeça P2 e resolução de entrada	Precisão, revocação, F1 e mAP@0,5; Wilcoxon pareado por carta	206 cartas; anotador único; um único detector (YOLOv8)

TL = *transfer learning*. Fonte: Elaborado pelo autor (2026).

3 Desenvolvimento / Implementação / Experimentos

Neste capítulo, apresentam-se a metodologia da pesquisa (Seção 3.1), os detalhes da implementação (Seção 3.2), os experimentos realizados (Seção 3.3) e os resultados obtidos, com sua análise (Seção 3.4).

3.1 Metodologia da pesquisa

Esta pesquisa é empírica, de natureza experimental e abordagem quantitativa: cada estratégia de treinamento foi variada de forma controlada, com os demais elementos do treinamento e da avaliação mantidos fixos, e seus efeitos foram medidos por métricas numéricas e comparados por testes estatísticos. As hipóteses testadas, H1 a H4, e o critério usado para confirmar ou refutar cada uma foram apresentados na Seção 1.3.3. Esta seção apresenta a visão geral do trabalho, com as etapas na ordem em que foram executadas (Seção 3.1.1), a organização e a preparação do conjunto de dados (Seção 3.1.2) e os critérios de validação, isto é, as métricas e os testes estatísticos usados na comparação (Seção 3.1.3).

3.1.1 Visão geral do trabalho

O trabalho consistiu no desenvolvimento de um *pipeline* experimental para detecção de defeitos visuais em cartas Pokémon TCG utilizando o modelo YOLOv8. O objetivo não foi construir um sistema completo de graduação automática, mas avaliar, em um cenário com baixo volume de dados, como diferentes estratégias de treinamento influenciam o desempenho do detector.

O recorte metodológico adotado concentrou-se nos defeitos visíveis na imagem que podem ser delimitados por caixa, na superfície, nas bordas e nos cantos da carta, como riscos, vincos, *whitening* e manchas (Seção 2.2.3), por serem compatíveis com a formulação do problema como tarefa de detecção de objetos. A centralização, que exige tratamento geométrico próprio, e o desgaste difuso, que não pode ser delimitado por caixas, ficaram fora da detecção; o tratamento do desgaste difuso é descrito na Seção 3.1.2.

A investigação foi conduzida sobre um conjunto de 206 cartas Pokémon TCG, cujas imagens, uma da frente e uma do verso de cada carta, foram fornecidas por uma empresa brasileira especializada em graduação, o que totalizou 412 imagens. Essas imagens receberam 4.808 anotações de defeito, todas na classe única *defeito*, cuja origem é detalhada na Seção 3.1.2. A partir desse conjunto, foi construída uma base de experimentação

compatível com o formato exigido pelo YOLOv8, que permitiu comparar, de forma controlada, diferentes estratégias de treinamento em contexto de dados limitados.

O trabalho seguiu as etapas abaixo, na ordem em que foram executadas:

1. Testes preliminares: o protocolo foi executado primeiro sobre as 82 cartas recebidas inicialmente, para verificar sua viabilidade no equipamento disponível. Quando as 124 cartas restantes foram recebidas, as etapas seguintes foram realizadas sobre o conjunto completo de 206 cartas, e apenas esses resultados foram usados para testar as hipóteses.

2. Preparação do conjunto de dados: anotação dos defeitos nas fotografias recebidas, recorte automático da região da carta em cada imagem, divisão das cartas em cinco dobras para a validação cruzada, com a frente e o verso de cada carta sempre na mesma dobra, e revisão da anotação com o apoio dos modelos dos testes preliminares (Seção 3.1.2).

3. Escolha da variante de realce de micro-relevo: quatro variantes foram comparadas em uma das dobras, e a escolha foi feita na validação interna (Seção 3.3.1).

4. Estudo fatorial 2×2: as quatro configurações, que cruzam o aumento de dados (sem ou com) e a representação de entrada (RGB ou realce de micro-relevo), foram treinadas e avaliadas nas cinco dobras, com resolução de entrada de 1280 pixels, em 20 treinamentos.

5. Ablação sobre a configuração de melhor desempenho no estudo fatorial, escolhida pelo critério da Seção 3.1.3: o acréscimo da cabeça de detecção P2, avaliado nas cinco dobras, e a comparação da resolução de entrada de 1280 pixels com a de 640 pixels, avaliada em uma dobra.

6. Análises complementares sobre a mesma configuração: a curva de aprendizado, com 25%, 50% e 75% das cartas de treino, em duas dobras, e um teste de capacidade do modelo com uma variante maior do YOLOv8, o YOLOv8m, em uma dobra.

7. Avaliação: cálculo das métricas na dobra de avaliação de cada rodada e teste das hipóteses H1 a H4 pelos critérios definidos na Seção 1.3.3, com os procedimentos descritos na Seção 3.1.3.

Os testes preliminares usaram as 82 cartas recebidas inicialmente, com 164 imagens, anotadas pelo autor antes da revisão descrita na Seção 3.1.2 e recortadas pelo mesmo procedimento automático. As cartas foram divididas em cinco dobras, com a frente e o verso de cada carta na mesma dobra, e, em cada rodada, cerca de 20% das cartas do treinamento formaram a validação interna. As quatro configurações do estudo fatorial foram treinadas nas cinco dobras com o mesmo modelo, a mesma resolução de entrada de

1280 pixels, o mesmo tamanho de lote, a mesma paciência, isto é, o número de épocas sem melhora tolerado antes da parada antecipada, e os mesmos parâmetros de aumento de dados usados depois no conjunto completo (Seção 3.2); rodadas isoladas serviram para ajustar o protocolo. Esses testes fixaram o tamanho do lote e a paciência (Seção 3.2.2), e os modelos treinados neles apoiaram a revisão da anotação do conjunto completo (Seção 3.1.2). Nas dobras desses testes, ao contrário das do conjunto completo, as cartas de mesma ilustração não foram mantidas juntas; a consequência disso para a revisão da anotação é apresentada na Seção 3.1.2.

3.1.2 Organização e preparação do conjunto de dados

A preparação do conjunto de dados compreendeu, nesta ordem, a aquisição das imagens, a anotação inicial dos defeitos, o recorte automático da carta em cada imagem, a divisão das cartas em cinco dobras para a validação cruzada e a revisão da anotação. A descrição a seguir agrupa as etapas por assunto: primeiro as imagens e a anotação, inclusive a revisão, e depois o recorte e a divisão em dobras.

As imagens foram fornecidas pela empresa de graduação: uma fotografia colorida (RGB) da frente e uma do verso de cada carta, capturadas pela própria empresa, sem controle deste trabalho sobre a iluminação ou o equipamento. As fotografias de 16 cartas têm fundo vermelho, e as das demais, fundo branco; oito imagens já chegaram recortadas na carta, sem fundo. A frente de todas as 206 cartas tem superfície holográfica, cujos reflexos foram discutidos na Seção 1.1. As resoluções são heterogêneas: 1280×1771 pixels em 317 imagens, 2560×3540 em 25, 1654×2352 em 23, 1320×1811 em 21, 1243×1719 em 15, 902×1248 em 2 e nove resoluções pontuais nas nove imagens restantes. Após o recorte automático descrito adiante, a dimensão média das imagens é de cerca de 1326×1827 pixels, e o lado maior supera a resolução de entrada de 1280 pixels usada nos experimentos em 407 das 412 imagens.

Os defeitos foram anotados pelo autor com caixas delimitadoras, com apoio nos laudos de graduação da empresa e no próprio julgamento sobre a imagem, como descrito na Seção 1.2, e gravados no formato de anotação do YOLOv8, um arquivo de texto por imagem, com uma linha por caixa. Todas as caixas pertencem à classe única *defeito*: o modelo localiza cada defeito sem distinguir seu tipo, o que evita dividir um conjunto de dados já pequeno em várias classes com poucos exemplos cada. O autor escreveu um critério de anotação, que foi aplicado a todas as caixas na revisão descrita adiante, inclusive às da primeira etapa:

1. cada marca contínua recebe uma caixa ajustada a ela, qualquer que seja o seu tamanho;

2. marcas separadas por superfície intacta recebem caixas separadas;

3. o desgaste de borda recebe uma caixa em forma de faixa para cada trecho contínuo, e um canto desgastado contido nessa faixa não recebe caixa própria;

4. o desgaste difuso não recebe caixa, pelo motivo exposto adiante;

5. padrões de impressão, como os brilhos e a textura das superfícies holográficas, não são defeito, e um risco sobre superfície holográfica é anotado quando atravessa ou interrompe a ilustração.

A anotação foi feita em duas etapas. Na primeira, o autor anotou as fotografias recebidas, antes do recorte descrito adiante, e obteve 3.109 caixas. Na segunda, feita depois do recorte e da divisão em dobras, essa anotação foi revisada com o apoio dos cinco modelos treinados nos testes preliminares (Seção 3.1.1) com imagens RGB e aumento de dados, um para cada dobra das 82 cartas iniciais. Seguiu-se a ideia, usada por Xu et al. (2022) na reanotação de um conjunto de imagens aéreas com objetos minúsculos, de que predições sem anotação correspondente podem indicar objetos que deixaram de ser anotados. Por isso, os modelos indicaram possíveis defeitos apenas onde ainda não havia caixa.

Nenhuma carta recebeu indicação de um modelo treinado com ela. Cada uma das 82 cartas iniciais recebeu as indicações do modelo em cuja dobra de avaliação ela estava. Cada modelo fez predições com confiança mínima de 0,05, com a opção da biblioteca que aplica aumento de dados também no momento da predição. Nessas 82 cartas, foram mantidas as predições com confiança de pelo menos 0,10. Cada uma das 124 cartas restantes, que nenhum dos cinco modelos havia visto, recebeu indicações formadas a partir das predições dos cinco modelos. As predições com IoU de pelo menos 0,4 com a de maior confiança foram reunidas em um grupo, e cada grupo com pelo menos duas predições gerou uma indicação, na posição média dessas predições ponderada pela confiança, mantida quando a soma das confianças dividida por cinco era de pelo menos 0,10. Em todas as cartas, foi descartada a indicação que se sobrepunha a uma caixa existente, isto é, com IoU de pelo menos 0,1 com ela ou com o centro de uma dentro da outra. A garantia de que nenhum modelo sugeriu caixas em uma carta usada no seu treinamento vale por carta, e não por ilustração. Oito cartas receberam indicações de modelos que tinham visto, no treinamento ou na validação interna, outra carta de mesma ilustração. Duas delas estão entre as 82 iniciais: nos testes preliminares, ficaram em dobras diferentes, e o modelo que fez as indicações para cada uma tinha visto a outra. As outras seis estão entre as 124 restantes e têm a mesma ilustração de uma carta inicial, vista por quatro dos cinco modelos. O efeito disso sobre as indicações dessas oito cartas, de 206, não foi medido.

O autor examinou cada caixa sugerida, aceitou 892 e rejeitou 414. Na mesma revisão, aplicou o critério acima também às caixas da primeira etapa, das quais removeu 156 e ajustou 3, e traçou 963 caixas novas. A anotação final reúne, assim, 4.808 caixas: 892

(18,6%) sugeridas pelos modelos e aceitas pelo autor e 3.916 traçadas pelo próprio autor (Seção 1.2).

Os modelos que sugeriram as caixas trabalhavam com imagens RGB. Por isso, as caixas sugeridas tendem a marcar defeitos que um detector com imagens RGB já encontra com facilidade. Isso pode favorecer as configurações que usam imagens RGB na comparação com as que usam realce de micro-relevo.

Para controlar esse risco, as métricas e as comparações pareadas do estudo fatorial e da cabeça P2 foram calculadas duas vezes: com a anotação completa, de 4.808 caixas, e com a anotação sem as caixas sugeridas, de 3.916 caixas. Na segunda referência, foram ignoradas as predições que tinham IoU de pelo menos 0,5 com uma caixa sugerida e nenhuma correspondência com caixa traçada pelo autor. Essas predições não contaram como acerto nem como erro, porque decidir se estavam certas exigiria justamente a caixa sugerida que foi retirada. Cinco cartas têm apenas caixas sugeridas. Na anotação sem as caixas sugeridas, elas ficaram sem nenhuma caixa e saíram das comparações por carta feitas com essa referência, que reuniram 201 cartas.

A leitura dos resultados seguiu um critério simples: uma conclusão que se mantém com as duas referências não depende da presença das caixas sugeridas na referência de avaliação. Esse controle, porém, alcança apenas a avaliação. Os modelos foram treinados com a anotação completa, que inclui as 892 caixas sugeridas, e toda a revisão, em que o autor também traçou 963 caixas novas, removeu 156 caixas da primeira etapa e rejeitou 414 sugestões, foi feita com as sugestões à vista. Uma eventual influência das sugestões sobre o treinamento ou sobre as decisões da revisão está presente nas duas referências e não foi medida.

O desgaste difuso, formado por muitos micro-riscos ou micro-pontos sem início nem fim definidos (Seção 2.2.3), não recebeu caixa, porque não há como delimitar nele uma marca individual. Ele foi registrado à parte, por imagem: 15 imagens, de 9 cartas, apresentam esse desgaste. Essas imagens permaneceram no conjunto, com caixas apenas para os defeitos delimitáveis nelas. Em consequência, nas regiões com desgaste difuso, o detector foi treinado e avaliado como se não houvesse defeito, e uma predição sobre elas foi contada como erro; essa é uma limitação da anotação por caixa.

O conjunto anotado reúne 4.808 anotações nas 412 imagens, com média de 11,67 por imagem (mediana de 6 e máximo de 174); 1.697 estão na frente das cartas e 3.111 no verso. Todas as 206 cartas têm ao menos uma anotação; em 29 delas, uma das faces não tem nenhuma, o que corresponde a 29 imagens (7,0%) sem caixa. A distribuição é concentrada: a mediana de 6 anotações por imagem contrasta com o máximo de 174, atingido nas cartas com desgaste mais extenso. Quanto à forma, apenas 367 anotações (7,6%) têm o lado maior mais de cinco vezes maior que o menor, de modo que a maior parte das caixas não tem forma de faixa.

Como a imagem é reduzida até que seu lado maior meça a resolução de entrada

(Seção 1.1), o fundo da fotografia ocupa pixels que poderiam representar a carta. Por isso, antes do treinamento, cada imagem foi recortada na região da carta por um procedimento automático, sem aprendizado, desenvolvido neste trabalho. O procedimento estima a cor do fundo a partir das bordas da fotografia e marca como carta os pixels que diferem desse fundo em cor ou em textura. Em seguida, determina os limites da carta pela contagem dessas marcações ao longo das linhas e das colunas da imagem e confere o resultado pela proporção física da carta, de 63 por 88 milímetros.

O recorte mantém uma margem de 25 pixels em torno da carta, porque parte do *whitening* de canto foi anotada ultrapassando ligeiramente a borda detectada. As caixas delimitadoras foram convertidas para o novo enquadramento, e duas regras impediram a perda de anotações. Quando a carta não era detectada, ou quando o recorte excluiria uma anotação, a imagem era mantida inteira. Quando o recorte cortaria parte de uma anotação, ele era ampliado até contê-la, com 5 pixels de folga. As 412 imagens foram processadas sem que nenhuma das 3.109 anotações da primeira etapa fosse descartada ou cortada, e as oito que já chegaram recortadas foram mantidas inteiras. As caixas da revisão foram traçadas já sobre as imagens recortadas, e, no conjunto final, todas as 4.808 anotações estão contidas nelas.

A Tabela 3 descreve o tamanho dos defeitos anotados pelo menor lado da caixa delimitadora, medido depois do recorte, com a imagem reduzida, mantendo a proporção, até que seu lado maior meça a resolução de entrada. Na resolução de 640 pixels, a mediana do menor lado é de 7,25 pixels, e 57,6% das anotações ficam abaixo de 8 pixels, o passo do nível de detecção P3; na resolução de 1280 pixels, essa fração cai para 10,8%. A tabela traz também a fração de anotações para as quais atingir IoU de 0,5 exige que a caixa predita esteja deslocada menos de 2 pixels da anotação; aproximando a caixa por um quadrado deslocado em uma direção, isso ocorre quando o menor lado é inferior a 6 pixels. Essa distribuição sustentou a resolução de entrada de 1280 pixels, já usada nos testes preliminares e adotada em todas as configurações do estudo fatorial (Seção 3.2.2). Nessa resolução, as anotações foram divididas em três faixas pelo menor lado, usadas na análise por tamanho: 517 abaixo de 8 pixels, 2.853 entre 8 e 20 pixels e 1.438 acima de 20 pixels.

A divisão das cartas em dobras foi feita por carta: a frente e o verso de uma carta ficaram sempre na mesma dobra, porque são o mesmo exemplar físico, e separá-los permitiria ao modelo encontrar na avaliação uma carta que já viu no treinamento. Pelo mesmo motivo, cartas diferentes que compartilham a mesma ilustração foram mantidas juntas: o conjunto tem 12 grupos de cartas com a mesma ilustração, que somam 28 cartas, e cada grupo ficou inteiro em uma única dobra. Adotou-se $k = 5$, dentro da faixa de 5 a 10 dobras frequentemente relatada na literatura de seleção de modelos (ARLOT; CELISSE, 2010). Com $k = 5$, cada rodada usa as cartas de quatro dobras, cerca de 80% do total, para o treinamento e a validação interna; como o modelo é treinado com menos cartas do que o conjunto inteiro, a estimativa absoluta tende a ser pessimista (KOHAVI, 1995). Como

Tabela 3 – Distribuição do tamanho dos defeitos anotados em função da resolução de entrada

	640 pixels	**1280 pixels**
Menor lado da caixa delimitadora (pixels)		
Percentil 5	3,27	6,54
Percentil 25	5,24	10,48
Mediana	7,25	14,51
Percentil 75	11,33	22,65
Percentil 95	25,08	50,16
Frações das anotações		
Abaixo de 8 pixels (passo do nível P3)	57,6%	10,8%
IoU de 0,5 exige erro de localização inferior a 2 pixels	34,6%	3,7%

Medições sobre as 4.808 anotações das 412 imagens, após o recorte automático, com a imagem reduzida, mantendo a proporção, até que seu lado maior meça a resolução de entrada. Fonte: Elaborado pelo autor (2026).

todas as configurações foram avaliadas nas mesmas dobras, supõe-se, como Kohavi (1995), que esse viés as afete de modo semelhante, o que preserva a comparação entre elas; a comparação vale, assim, para o volume de treino efetivamente usado em cada rodada, de 129 a 134 cartas, e não necessariamente para um treino com as 206 cartas. A escolha de 5 em vez de 10 dobras decorreu do custo de treinamento, e o valor absoluto das métricas deve ser lido como estimativa conservadora. A Figura 4 ilustra o esquema.

A divisão foi estratificada pelo número de faces com defeito anotado em cada carta (nenhuma, uma ou duas), para distribuir entre as dobras as cartas com faces sem anotação. A estratificação usou a anotação inicial, anterior à revisão, na qual 5 cartas não tinham anotação em nenhuma face, 39 tinham uma face sem anotação e 162 tinham anotação nas duas; a mesma divisão foi mantida depois da revisão. Cada grupo de mesma ilustração entrou na estratificação como uma unidade, no estrato do menor número de faces com defeito entre as suas cartas, para que um grupo com uma carta sem anotação fosse distribuído com o mesmo cuidado que essa carta teria sozinha. As unidades de cada estrato foram embaralhadas, com semente fixa, e distribuídas em rodízio entre as cinco dobras.

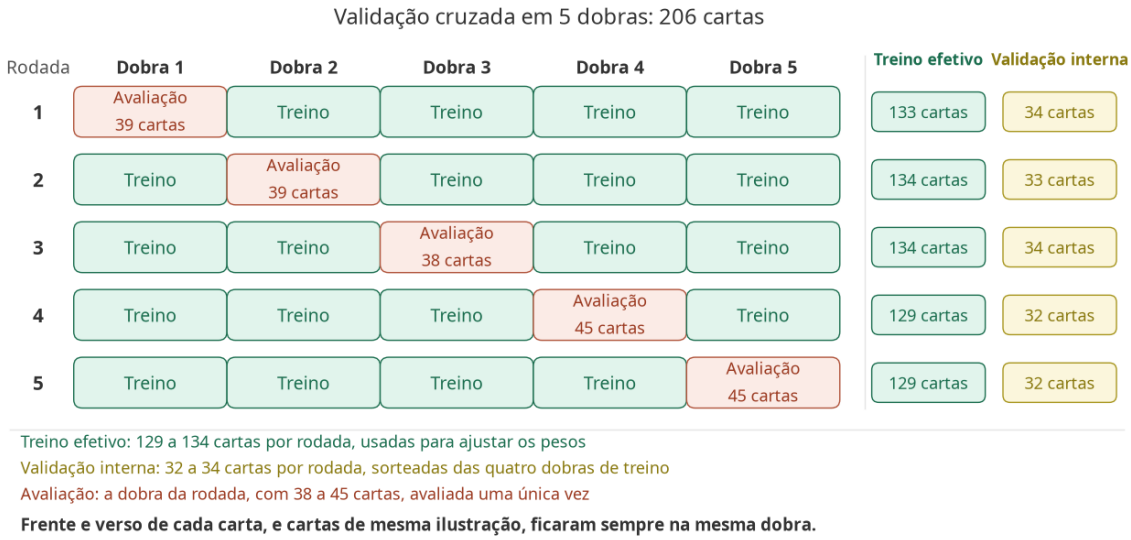
As dobras ficaram com 39, 39, 38, 45 e 45 cartas, diferença causada pelos grupos de mesma ilustração, e com 1.416, 747, 645, 1.217 e 783 anotações. O desequilíbrio no número de anotações decorre das cartas com desgaste mais extenso, que têm até 174 anotações em uma face e ficaram em duas das dobras. A divisão foi feita uma única vez e mantida fixa em todas as configurações e análises, de modo que cada carta foi avaliada exatamente uma vez em cada configuração, o que permite a comparação pareada por carta (Seção 2.2.14).

Em cada rodada, cerca de 20% das cartas do bloco de treinamento, de 32 a 34 cartas, formaram a validação interna, sorteadas mantendo juntas as cartas de mesma ilustração, e o treino efetivo ficou com 129 a 134 cartas. Essas listas, de treino efetivo, de validação interna e de avaliação, foram definidas uma única vez para cada rodada e usadas sem

alteração em todas as configurações; só a curva de aprendizado reduziu o treino efetivo (Seção 3.3.2).

A validação interna foi usada nas escolhas descritas na Seção 2.2.13: a parada antecipada, o limiar de confiança do F1 e a variante de realce de micro-relevo. A dobra de avaliação de cada rodada não participou da parada antecipada nem da escolha do limiar dessa rodada; a ressalva sobre a escolha da variante de realce é apresentada na Seção 3.3.1.

Figura 4 – Esquema da validação cruzada estratificada em cinco dobras aplicada às 206 cartas. Em cada rodada, uma dobra é reservada para avaliação, e as outras quatro formam o bloco de treinamento, do qual cerca de 20% das cartas são separadas como validação interna; a frente e o verso de cada carta, assim como as cartas de mesma ilustração, ficam sempre na mesma dobra.



Fonte: Elaborado pelo autor (2026).

3.1.3 Critérios de validação

O desempenho de cada rodada foi medido na sua dobra de avaliação. A métrica usada para testar as hipóteses H1 a H3 foi o F1 por carta (Seção 2.2.5), porque a comparação entre as configurações foi feita carta a carta (Seção 2.2.14) e exige uma nota para cada carta. No seu cálculo, foram consideradas apenas as predições com confiança igual ou superior ao limiar fixado na validação interna da rodada (Seção 2.2.13), aplicado sem alteração à dobra de avaliação. Esse limiar foi o valor de confiança, entre 1.000 valores igualmente espaçados de 0 a 1, que maximizou o F1 agregado da validação interna, calculado pela própria biblioteca, depois de suavizada a curva do F1 em função do limiar, o mesmo critério que a biblioteca aplica ao conjunto que avalia (JOCHER; CHAURASIA; QIU, 2023). Em cada imagem, as predições foram percorridas da maior para a menor confiança, e cada uma foi associada à anotação ainda não associada com a qual tinha a maior IoU, desde que essa IoU fosse de pelo menos 0,5, o mesmo limiar do mAP@0,5; cada associação contou como verdadeiro positivo, cada predição sem associação como falso positivo e cada anotação

sem predição associada como falso negativo. Os verdadeiros positivos, os falsos positivos e os falsos negativos da frente e do verso foram somados, e o F1 da carta foi calculado sobre essas somas. Assim, as predições feitas em uma face sem anotação contam como falsos positivos da carta, e uma carta com anotações e sem nenhum acerto recebe F1 igual a zero. Uma carta sem nenhuma anotação na referência usada não tem F1 definido e ficou fora das comparações, o que só ocorreu na anotação sem as caixas sugeridas (Seção 3.1.2). A revocação por carta foi calculada da mesma forma.

Além do F1 por carta, foram reportados, para descrever cada configuração, o mAP@0,5 de cada dobra e a média das cinco dobras, e a precisão, a revocação e o F1 agregados, obtidos com o mesmo limiar e a mesma associação, somando os verdadeiros positivos, os falsos positivos e os falsos negativos de todas as cartas das cinco dobras. As predições de cada imagem da dobra de avaliação foram salvas com os valores padrão de avaliação da biblioteca: confiança mínima de 0,001, até 300 predições por imagem e supressão de não máximos, que elimina cada predição cuja IoU com outra de maior confiança supera 0,7. O mAP@0,5 foi recalculado a partir dessas predições, da mesma forma nas duas referências de anotação, com a precisão interpolada em 101 valores de revocação igualmente espaçados, como na biblioteca. Ele não foi usado para testar hipóteses, porque não fornece uma nota por carta. A precisão e a revocação informadas pela biblioteca de treinamento não foram usadas, porque correspondem ao limiar que maximiza o F1 na própria dobra de avaliação. A média e o desvio padrão entre as cinco dobras não foram usados nos testes das hipóteses (Seção 2.2.14).

Cada comparação usou o teste de Wilcoxon pareado bilateral (Seção 2.2.14) sobre o F1 por carta, com as dobras fixas entre as configurações. As comparações que testam H1 a H3 são as quatro definidas na Seção 1.3.3: a Configuração 2 contra a 1 e a Configuração 4 contra a 3, para H1, e a Configuração 3 contra a 1 e a Configuração 4 contra a 2, para H2; as duas que envolvem a Configuração 4 decidem também H3. A elas somou-se uma quinta, entre a configuração de melhor desempenho, definida adiante nesta seção, com e sem a cabeça P2. Ela verifica se o acréscimo da cabeça alterou o desempenho geral do detector, além da revocação dos defeitos pequenos examinada em H4.

A correção de Holm foi aplicada a essas cinco comparações, isto é, com $m = 5$, e uma diferença foi considerada significativa quando o valor-p ajustado ficou abaixo de $\alpha = 0{,}05$. As cinco comparações foram feitas com as duas referências de anotação, com 206 pares na anotação completa e 201 na anotação sem as caixas sugeridas, e a correção foi aplicada separadamente em cada referência. Os pares com diferença nula foram excluídos do cálculo do teste, e seu número é informado com cada resultado. A revocação por carta foi comparada nas mesmas cinco comparações, com a correção aplicada à parte, para indicar a origem das diferenças no F1. Cada configuração foi treinada uma única vez em cada rodada; por isso, o teste trata os modelos como fixos, como discutido na Seção 2.2.14.

A decisão sobre H1, H2 e H3 seguiu uma regra fixa, aplicada em cada referência de

anotação. Como o teste é bilateral, uma diferença significativa pode ocorrer nos dois sentidos, e só uma diferença no sentido previsto pela hipótese contou a seu favor. H1 foi considerada confirmada quando as duas comparações correspondentes, a Configuração 2 contra a 1 e a Configuração 4 contra a 3, foram significativas após a correção de Holm, no sentido previsto, e refutada quando alguma delas foi significativa no sentido contrário. Nos demais casos, o resultado foi lido separadamente para cada representação de entrada, como confirmação parcial quando uma das duas comparações foi significativa no sentido previsto. A mesma regra valeu para H2, com as comparações da Configuração 3 contra a 1 e da Configuração 4 contra a 2, lidas separadamente para cada condição de aumento de dados. H3 foi considerada confirmada apenas quando a Configuração 4 superou significativamente as Configurações 2 e 3, refutada quando alguma delas superou significativamente a Configuração 4, e não confirmada nos demais casos.

Como análise adicional, sem hipótese formulada, verificou-se a interação entre os dois fatores do estudo fatorial (Seção 2.2.12). Para cada carta, calculou-se o efeito do aumento de dados com imagens RGB, isto é, o F1 por carta da Configuração 2 menos o da Configuração 1, e o efeito do aumento de dados com imagens de realce, o da Configuração 4 menos o da Configuração 3. Como as variações no espaço HSV só fizeram parte do aumento de dados das imagens RGB (Seção 3.3.1), a diferença entre esses efeitos inclui também a diferença entre os dois aumentos de dados. Os dois efeitos foram comparados carta a carta pelo teste de Wilcoxon pareado bilateral, com a anotação completa: se o efeito do aumento de dados não depende da representação de entrada, as diferenças entre eles se distribuem em torno de zero. Essa análise ficou fora da correção de Holm, por não testar nenhuma das hipóteses.

A ablação e as análises complementares foram feitas sobre a configuração de melhor desempenho no estudo fatorial. Essa configuração foi escolhida ao fim do estudo fatorial, como a de maior mAP@0,5 médio nas cinco dobras de avaliação, com a anotação completa; ela também obteve o maior F1 agregado. O mAP@0,5 médio foi usado nessa escolha por ser a métrica de referência dos detectores (Seção 2.2.5) e por estar disponível ao fim de cada rodada, sem depender do limiar de confiança. Essa escolha usou as próprias dobras de avaliação, e não a validação interna. Como a configuração escolhida serve de referência nas comparações seguintes, a escolha pode favorecê-la ligeiramente nelas; as comparações do estudo fatorial não são afetadas, porque seus pares foram definidos antes, nas hipóteses.

Para H4, cada defeito foi atribuído a uma das três faixas de tamanho da Seção 3.1.2, pelo menor lado da sua caixa na resolução de 1280 pixels. A associação entre predições e anotações foi a mesma do F1 por carta, feita com todas as anotações da imagem. A revocação de cada faixa foi o número de defeitos da faixa associados a uma predição, somado nas cinco dobras de avaliação, dividido pelo total de defeitos da faixa. A revocação das três faixas foi calculada também para as quatro configurações do estudo fatorial, como descrição.

O critério de H4, definido na Seção 1.3.3, foi a revocação da faixa abaixo de 8 pixels, com 517 defeitos, comparada entre a configuração de melhor desempenho com e sem a cabeça P2. Esse critério não fixou margem mínima de diferença nem teste estatístico. Como a associação usa o limiar de confiança fixado na validação interna de cada rodada, os modelos com e sem a cabeça P2 tiveram a revocação medida em limiares que podem diferir, e um modelo com limiar mais baixo mantém mais predições e ganha revocação à custa de precisão. Por isso, o resultado de H4 é lido junto com a comparação do F1 por carta entre os dois modelos, uma das cinco comparações com correção de Holm, que leva em conta também a precisão.

Como análise adicional, feita depois dos resultados, a revocação da faixa abaixo de 8 pixels foi calculada carta a carta nas 127 cartas que têm ao menos um defeito nela, e os dois modelos foram comparados pelo teste de Wilcoxon pareado bilateral. Essa análise foi usada apenas para indicar se a diferença na revocação somada se distingue de uma variação casual, sem substituir o critério da Seção 1.3.3. Todas essas medidas, inclusive a descrição das quatro configurações, foram calculadas com as duas referências de anotação; na anotação sem as caixas sugeridas, a faixa abaixo de 8 pixels tem 513 defeitos, e a análise por carta reuniu 126 cartas.

A ablação da resolução de entrada e as análises complementares, isto é, o teste de capacidade e a curva de aprendizado, foram feitas sem hipótese formulada. Elas usaram a configuração de melhor desempenho, a anotação completa e dobras isoladas, identificadas de 1 a 5 na ordem em que foram apresentadas na Seção 3.1.2.

A resolução de entrada de 640 pixels e o YOLOv8m foram avaliados na Dobra 5, de 45 cartas. Cada um foi comparado com a rodada da configuração de melhor desempenho nessa dobra, treinada com o YOLOv8s a 1280 pixels, pelo F1 por carta e pelo teste de Wilcoxon pareado bilateral, com 45 pares e sem correção de Holm.

A curva de aprendizado foi avaliada nas Dobras 3 e 5. Em cada dobra, os modelos treinados com 25%, 50% e 75% das cartas do treino efetivo e a rodada com todas elas foram avaliados nas mesmas cartas da dobra de avaliação, pelo mAP@0,5. A curva usou o mAP@0,5, e não o F1 por carta, porque o mAP@0,5 não depende do limiar de confiança. Com o F1, cada ponto da curva teria um limiar próprio, escolhido na validação interna por um modelo treinado com menos cartas, e a variação dessa escolha entre os pontos se somaria à variação causada pelo número de cartas de treino, que é o que a curva mede. A incerteza das diferenças entre os pontos da curva foi estimada pelo intervalo de confiança por *bootstrap* descrito na Seção 2.2.14, com a carta como unidade sorteada. Em cada repetição, a mesma amostra de cartas foi usada para recalcular o mAP@0,5 de todos os pontos. O intervalo foi obtido para a diferença entre pontos consecutivos e entre 50% e 100% das cartas do treino efetivo.

A Tabela 4 resume os experimentos, com o que variou e o que ficou fixo em cada um, as dobras usadas e a métrica e o teste de cada comparação.

Tabela 4 – Plano de experimentação

Experimento	**Objetivo**	**O que varia**	**O que fica fixo**	**Dobras**	**Métrica e teste**
Escolha da variante de realce	Escolher a variante das Configurações 3 e 4; sem hipótese	Variante de realce de micro-relevo (quatro)	Configuração 3, YOLOv8s, 1280 pixels	Dobra 1	F1 agregado na validação interna, calculado pela biblioteca; escolhida a variante de maior valor, sem teste
Estudo fatorial 2×2	H1, H2 e H3	Aumento de dados (sem ou com) e representação de entrada (RGB ou realce)	YOLOv8s com pesos pré-treinados, 1280 pixels, demais hiperparâmetros e dobras	1 a 5	F1 por carta; Wilcoxon pareado bilateral (206 e 201 pares), com correção de Holm; interação como análise adicional
Ablação da cabeça P2	H4	Cabeça P2 (sem ou com)	Configuração de melhor desempenho e demais condições do estudo fatorial	1 a 5	H4: revocação somada dos defeitos menores que 8 pixels, sem teste; F1 por carta com Wilcoxon e Holm; revocação por carta nessa faixa com Wilcoxon, como análise adicional
Ablação da resolução de entrada	Sem hipótese	640 ou 1280 pixels	Configuração de melhor desempenho, YOLOv8s	Dobra 5	F1 por carta; Wilcoxon pareado bilateral (45 pares), sem Holm
Curva de aprendizado	Análise complementar, sem hipótese	Fração das cartas do treino efetivo (25%, 50%, 75% e 100%)	Configuração de melhor desempenho, YOLOv8s, 1280 pixels	Dobras 3 e 5	mAP@0,5, que não depende do limiar de confiança; intervalo de confiança de 95% por *bootstrap* percentil, com a carta como unidade
Teste de capacidade	Análise complementar, sem hipótese	YOLOv8s ou YOLOv8m	Configuração de melhor desempenho, 1280 pixels	Dobra 5	F1 por carta; Wilcoxon pareado bilateral (45 pares), sem Holm

Dobras numeradas de 1 a 5 na ordem da Seção 3.1.2. Em todos os experimentos, o limiar de confiança foi fixado na validação interna de cada rodada, a associação entre predição e anotação exigiu IoU de pelo menos 0,5, e o mAP@0,5, a precisão, a revocação e o F1 agregados foram reportados como descrição. Fonte: Elaborado pelo autor (2026).

3.2 Detalhes da implementação

Esta seção descreve o modelo usado nos experimentos (Seção 3.2.1), os hiperparâmetros de treinamento, inclusive os de aumento de dados de cada configuração (Seção 3.2.2), e o ambiente computacional em que os treinamentos foram executados (Seção 3.2.3).

3.2.1 Modelo base

As rodadas usaram o YOLOv8s, a variante *small* do YOLOv8, inicializado com os pesos pré-treinados no COCO disponibilizados pela biblioteca Ultralytics (Seção 2.2.6) e submetido a ajuste fino sobre as imagens das cartas, com a classe única *defeito*. Nenhuma camada foi congelada: todos os pesos foram ajustados durante o treinamento. Houve duas exceções ao uso do YOLOv8s com todos os pesos pré-treinados, descritas adiante nesta

seção: o teste de capacidade usou o YOLOv8m, e a ablação da cabeça P2 usou uma versão do YOLOv8s que recebeu os pesos pré-treinados em apenas parte das camadas. Os pesos iniciais foram os mesmos em todas as configurações: o *transfer learning* não foi um fator do estudo, mas a base comum sobre a qual o aumento de dados e o realce de micro-relevo foram comparados.

O YOLOv8 foi mantido como detector, em vez de versões mais recentes da família YOLO, por três motivos. Primeiro, foi a arquitetura definida antes dos experimentos e usada nos testes preliminares, que verificaram a viabilidade do protocolo no equipamento disponível (Seção 3.1.1). Segundo, é a versão usada pelos dois trabalhos correlatos que tratam de detecção de objetos (Seção 2.3), o que aproxima as condições deste trabalho das deles. Terceiro, a biblioteca utilizada oferece para o YOLOv8 uma variante oficial com a cabeça de detecção P2, necessária à ablação, o que permitiu fazê-la sem modificar a arquitetura por conta própria (JOCHER; CHAURASIA; QIU, 2023).

Entre os tamanhos do YOLOv8, adotou-se o *small*, com cerca de 11 milhões de parâmetros, pelo custo de memória e de tempo. Com a configuração de treinamento descrita na Seção 3.2.2, o YOLOv8s ocupou cerca de 7,1 GB dos 16 GB de memória da placa de vídeo e levou cerca de 28 segundos por época. O tamanho seguinte, o YOLOv8m, com cerca de 26 milhões de parâmetros (JOCHER; CHAURASIA; QIU, 2023), ocupou 11,6 GB e levou 58 segundos por época na rodada em que foi treinado. O acréscimo da cabeça P2 elevou a memória ocupada pelo YOLOv8s em cerca de 4 a 6 GB, conforme a dobra; somado aos 11,6 GB do YOLOv8m, um acréscimo dessa ordem deixaria a ocupação no limite dos 16 GB da placa ou acima deles, e a combinação do YOLOv8m com a cabeça P2 não foi treinada. A possibilidade de que a capacidade do YOLOv8s limitasse o desempenho foi examinada pelo teste de capacidade (Tabela 4), cujo resultado é apresentado na Seção 3.4.

Na ablação da cabeça P2, usou-se a variante P2 do YOLOv8s oferecida pela biblioteca (Seção 2.2.11), com os mesmos pesos pré-treinados, dobras e hiperparâmetros da configuração sem a cabeça P2. A biblioteca só transfere os pesos de uma camada quando o nome, que inclui a posição da camada na rede, e o formato coincidem nos dois modelos. O *backbone* e o caminho de cima para baixo do *neck* até o nível P3 são iguais nas duas arquiteturas e receberam os pesos pré-treinados. As camadas acrescentadas para levar as características até o nível P2 deslocaram a posição das seguintes; por isso, o caminho de baixo para cima do *neck*, exceto poucos conjuntos de pesos que coincidiram por acaso, e toda a cabeça de detecção, inclusive nos níveis P3 a P5, começaram com valores aleatórios. Ao todo, foram transferidos 219 dos 437 tensores de pesos do modelo, isto é, dos conjuntos de valores aprendidos de suas camadas. Essa perda de pré-treino, prevista na Seção 2.2.7, acompanhou todas as rodadas com a cabeça P2 e é considerada na análise dos resultados. Com essa cabeça, a memória ocupada ficou entre 11,2 e 13,1 GB, e o tempo por época, entre 41 e 43 segundos.

3.2.2 Hiperparâmetros de treinamento

Os hiperparâmetros de treinamento foram os mesmos em todas as rodadas, exceto o elemento que cada experimento variou (Tabela 4); os parâmetros de aumento de dados, que definem um dos fatores do estudo fatorial, são apresentados adiante. A resolução de entrada foi de 1280 pixels, a mesma dos testes preliminares, e a distribuição do tamanho dos defeitos na anotação final (Tabela 3) sustentou a escolha: nela, a fração das anotações com menor lado abaixo do passo do nível P3 cai de 57,6%, a 640 pixels, para 10,8%. Como o lado maior da maior parte das imagens recortadas supera 1280 pixels (Seção 3.1.2), o aumento de tamanho corresponde a detalhe presente na fotografia. O custo também aumenta: na Dobra 5, a rodada da configuração de melhor desempenho a 640 pixels ocupou 2,1 GB da memória da placa de vídeo e levou 7,7 segundos por época, contra 7,1 GB e 27,7 segundos a 1280 pixels.

As imagens foram processadas em lotes de 4. A biblioteca acumula o resultado de 16 lotes antes de cada atualização dos pesos, de modo que cada atualização considerou 64 imagens. Lotes de 8 imagens foram experimentados nos testes preliminares e travaram a placa de vídeo nas duas tentativas, por falha da biblioteca da AMD que executa as convoluções, e não por falta de memória, já que a ocupação estimada, de cerca de 12,5 GB, caberia nos 16 GB da placa.

O otimizador, algoritmo que calcula o ajuste dos pesos a cada atualização, foi escolhido pela própria biblioteca, na opção automática: para treinamentos com até 10 mil atualizações, como os deste trabalho, ela adota o AdamW, com taxa de aprendizado inicial, que regula o tamanho de cada ajuste, de 0,002 quando há uma única classe (JOCHER; CHAURASIA; QIU, 2023). Os demais hiperparâmetros de otimização mantiveram o valor padrão da biblioteca. O treinamento usou semente aleatória fixa e o modo determinístico da biblioteca, e cada configuração foi treinada uma única vez em cada rodada. Duas rodadas interrompidas foram retomadas a partir do estado salvo ao fim da última época concluída, com os mesmos parâmetros.

Cada rodada teve teto de 300 épocas e parada antecipada com paciência de 100 épocas: o treino foi interrompido quando a validação interna passou 100 épocas sem melhora, e foram mantidos os pesos da melhor época (Seção 2.2.13). A melhora foi medida pelo critério da biblioteca, que, na versão usada, é o mAP@0,5:0,95 na validação interna (JOCHER; CHAURASIA; QIU, 2023), e não o mAP@0,5. Nenhuma rodada atingiu o teto de 300 épocas: todas foram encerradas pela paciência.

A paciência de 100 épocas, que coincide com o valor padrão da biblioteca, foi usada também nos testes preliminares. Prechelt (1998) observa que critérios de parada mais lentos trazem pequena melhora na generalização ao custo de cerca de quatro vezes mais tempo de treinamento; neste trabalho, esse custo coube no cronograma, e uma escolha ruim do ponto de parada acrescentaria variação às comparações entre as configurações.

Os hiperparâmetros de aumento de dados foram definidos por configuração, conforme

a Tabela 5. A biblioteca aplica, por padrão, sete transformações de aumento de dados no treinamento de detectores: o mosaico (`mosaic`), a variação de escala (`scale`), a translação (`translate`), o espelhamento horizontal (`fliplr`) e as três variações no espaço HSV (`hsv_h`, `hsv_s` e `hsv_v`) (JOCHER; CHAURASIA; QIU, 2023). Por isso, a ausência de aumento de dados nas Configurações 1 e 3 exigiu o desligamento explícito desses parâmetros: com os valores padrão, essas configurações receberiam mais transformações do que as Configurações 2 e 4, o que inverteria o sentido do fator investigado no estudo fatorial. Nas Configurações 2 e 4, as transformações mantidas conservaram o valor padrão da biblioteca, e acrescentou-se a rotação de até 10 graus, uma das transformações geométricas de aumento de dados apresentadas na Seção 2.2.9, em valor que não foi ajustado por teste. Ao girar a imagem, a biblioteca substitui cada caixa pela menor caixa alinhada aos eixos que contém os seus quatro cantos girados, o que a alarga; o efeito é maior nas 367 caixas em forma de faixa (Seção 3.1.2): no ângulo máximo, uma faixa de 100 por 5 pixels passa a ser representada por uma caixa de cerca de 99 por 22 pixels. Na Configuração 4, as variações no espaço HSV foram desligadas, porque o realce de micro-relevo já ajusta o contraste local pelo CLAHE e seus três canais não representam cores (Seção 2.2.10); variações artificiais de cor e de brilho perturbariam o sinal que ele constrói.

Dois parâmetros foram desligados em todas as configurações, inclusive nas com aumento de dados. O primeiro é a variação de escala. No valor padrão de 0,5, ela multiplica o tamanho da imagem por um fator sorteado entre 0,5 e 1,5, isto é, pode reduzi-la até a metade ou ampliá-la em até 50%. Reduzir à metade uma imagem de 1280 pixels deixa os defeitos com o tamanho que teriam na resolução de 640 pixels, na qual 57,6% das anotações ficam abaixo do passo do nível P3 (Tabela 3); a transformação desfaria, em parte das imagens de treino, o ganho da resolução de entrada adotada. A biblioteca permite restringir o sorteio a fatores de ampliação, mas essa opção, que também levaria parte da carta para fora da imagem, não foi avaliada.

O segundo é o mosaico, que combina quatro imagens e recorta delas uma janela do tamanho da entrada (Seção 2.2.9). Com a variação de escala desligada, ele não reduz os objetos. O recorte, porém, pode cortar defeitos nas bordas de cada imagem, e a imagem resultante reúne partes de quatro cartas, situação que não ocorre na avaliação, feita sobre a carta inteira. A translação, mantida nas Configurações 2 e 4, também pode levar para fora da imagem uma faixa da carta de até 10% da altura, e com ela parte do desgaste da borda superior ou inferior; a biblioteca corta as caixas no limite da imagem e descarta as que perdem mais de 90% da área. A perda é menor que no mosaico, do qual cada imagem participa apenas com a parte que cai na janela recortada. Os demais parâmetros de aumento de dados que a biblioteca aplica ao treinamento de detectores já valem zero por padrão e foram mantidos assim em todas as configurações.

Os valores da Tabela 5 ficaram fixos nas cinco dobras de cada configuração. As transformações foram aplicadas apenas às imagens de treino de cada rodada, no momento

em que cada imagem era carregada, e nunca gravadas em disco antes da divisão em dobras; assim, versões transformadas de uma carta não puderam aparecer no treino e na avaliação ao mesmo tempo. O pacote opcional Albumentations não foi instalado, porque, quando ele está presente, a biblioteca o usa para aplicar desfoque, conversão para tons de cinza e equalização de contraste a uma pequena parte das imagens de todas as configurações, inclusive das que não têm aumento de dados.

Tabela 5 – Parâmetros de aumento de dados por configuração

		Configuração			
Parâmetro	**Padrão**	**1 e 3**	**2**	**4**	**Motivo do valor adotado**
`hsv_h`	0,015	0,0	0,015	0,0	Configuração 4: realce com contraste ajustado pelo CLAHE e canais que não são cores
`hsv_s`	0,7	0,0	0,7	0,0	idem
`hsv_v`	0,4	0,0	0,4	0,0	idem
`degrees`	0,0	0,0	10,0	10,0	transformação geométrica usual, valor não ajustado; alarga as caixas em faixa
`translate`	0,1	0,0	0,1	0,1	padrão mantido
`fliplr`	0,5	0,0	0,5	0,5	padrão mantido
`mosaic`	1,0	0,0	0,0	0,0	corta defeitos nas bordas e reúne partes de quatro cartas
`scale`	0,5	0,0	0,0	0,0	a redução leva defeitos para baixo do passo do nível P3
`shear`, `perspective`, `flipud`, `bgr`, `mixup`, `cutmix` e `copy_paste` ficaram em 0,0 em todas as configurações, valor que já é o padrão da biblioteca.					

Padrão: valor padrão da biblioteca Ultralytics 8.4.138. Nas Configurações 1 e 3, sem aumento de dados, todos os parâmetros foram zerados; nas Configurações 2 e 4, os valores diferentes do padrão estão justificados na última coluna. Fonte: Elaborado pelo autor (2026).

3.2.3 Tecnologias e ferramentas

A implementação foi feita em Python, versão 3.12. O treinamento e a avaliação dos modelos usaram a biblioteca Ultralytics, versão 8.4.138, que mantém a implementação de referência do YOLOv8 e oferece a variante com a cabeça P2 (JOCHER; CHAURASIA; QIU, 2023), sobre o PyTorch 2.14.0 com a plataforma ROCm 7.2, que permite executar o PyTorch em placas de vídeo AMD, como a do equipamento disponível; a versão anterior testada, o PyTorch 2.10.0 com a plataforma ROCm 7.0, falhou durante o treinamento nessa placa. O recorte automático da carta e a geração das imagens de realce de micro-relevo usaram a biblioteca OpenCV, versão 5.0, que oferece a conversão entre espaços de cor, os filtros e o CLAHE empregados, e a biblioteca NumPy, versão 2.5, nas operações sobre matrizes, como o cálculo da medida de Frangi; os testes estatísticos usaram a biblioteca SciPy, versão 1.18, que implementa o teste de Wilcoxon pareado. Os experimentos foram

executados em um computador com o sistema operacional Ubuntu 24.04 e placa de vídeo AMD Radeon RX 9060 XT, com 16 GB de memória. A lista completa de pacotes e versões acompanha o código do trabalho, disponível em repositório público[1].

3.3 Experimentos e cenário de testes

Esta seção define as quatro configurações comparadas no estudo fatorial e descreve como as imagens de realce de micro-relevo foram geradas e como a variante adotada foi escolhida (Seção 3.3.1); em seguida, descreve as rodadas de treinamento do estudo fatorial, da ablação e das análises complementares (Seção 3.3.2).

3.3.1 Estratégias de treinamento avaliadas

O estudo fatorial (Seção 2.2.12) cruzou dois fatores: o aumento de dados, sem ou com, e a representação de entrada, imagens RGB ou imagens de realce de micro-relevo. As quatro combinações formaram as configurações comparadas:

Configuração 1 imagens RGB, sem aumento de dados;

Configuração 2 imagens RGB, com aumento de dados;

Configuração 3 imagens de realce de micro-relevo, sem aumento de dados;

Configuração 4 imagens de realce de micro-relevo, com aumento de dados.

As quatro configurações usaram o mesmo modelo, os mesmos pesos pré-treinados e os mesmos hiperparâmetros de treinamento, exceto os de aumento de dados (Seção 3.2); a Configuração 1 corresponde, assim, ao ajuste fino sem nenhuma das duas estratégias. As hipóteses H1 e H2 (Seção 1.3.3) tratam do efeito de cada fator, e H3, da combinação dos dois na Configuração 4; as comparações que testaram cada uma estão na Seção 3.1.3.

Nas Configurações 2 e 4, o aumento de dados aplicou às imagens de treino a translação, o espelhamento horizontal e a rotação; na Configuração 2, aplicou também as variações de matiz, saturação e valor no espaço HSV, que ficaram desligadas na Configuração 4 pelo motivo exposto na Seção 3.2.2. Os valores de cada parâmetro estão na Tabela 5, e a consequência dessa diferença para a comparação entre as representações de entrada é discutida adiante, nesta seção.

As imagens de realce de micro-relevo das Configurações 3 e 4 foram geradas a partir das imagens recortadas (Seção 3.1.2), sempre a partir do canal de luminosidade (L^*) do espaço CIELAB, com os operadores apresentados na Seção 2.2.10, aplicados na resolução da imagem recortada, antes da redução à resolução de entrada. Quatro variantes foram comparadas:

[1] <https://github.com/Marynxs/tcc-deteccao-defeitos-pokemon-tcg-yolov8>

***Emboss* e CLAHE** o filtro *emboss*, com núcleo de 3×3 pixels cujas linhas são $(-2, -1, 0)$, $(-1, 0, 1)$ e $(0, 1, 2)$, que responde à variação de luminosidade na direção diagonal; a resposta, somada a 128 e limitada à faixa de 0 a 255, foi seguida do CLAHE;

CLAHE e *emboss* em oito direções o CLAHE seguido do filtro *emboss* aplicado em oito direções, como no trabalho sobre superfícies pintadas discutido na Seção 2.2.10, mantendo-se em cada pixel a maior resposta em valor absoluto; as oito direções foram obtidas girando os coeficientes da borda do mesmo núcleo uma posição por vez, em passos de 45 graus, e, como direções opostas dão o mesmo valor absoluto, correspondem a quatro eixos distintos;

Frangi o CLAHE seguido da medida de Frangi, calculada com núcleos gaussianos de desvio padrão de 1,5, 3 e 5 pixels, mantendo-se em cada pixel a maior resposta entre essas escalas;

Composição de três canais a variante descrita na Seção 2.2.10, em que os três canais de entrada recebem a luminosidade original, a luminosidade com CLAHE e a medida de Frangi da variante anterior.

Nas três primeiras variantes, a imagem resultante, de um único canal, foi repetida nos três canais de entrada da rede; na última, cada canal recebeu uma informação diferente. Em todas, o CLAHE usou uma grade de 8×8 ladrilhos, valor padrão da biblioteca OpenCV, e limite de corte de 3,0, mais baixo que o padrão da biblioteca, de 40, o que torna o realce mais suave. Esses valores não foram ajustados por teste, e a medida de Frangi usou os parâmetros indicados por seus autores (Seção 2.2.10).

As respostas do *emboss* em oito direções e da medida de Frangi foram convertidas para a faixa de intensidades de 0 a 255, por uma escala linear que leva o percentil 1 ao valor 0 e o percentil 99,5 ao valor 255, percentis calculados em cada imagem; os valores fora desse intervalo foram fixados nesses limites. A medida de Frangi foi implementada pelo autor. Em cada escala, a imagem foi suavizada pelo núcleo gaussiano, e as derivadas de segunda ordem foram aproximadas por diferenças em uma vizinhança de 3×3 pixels e multiplicadas pelo quadrado do desvio padrão, para tornar comparáveis as respostas das escalas. A medida foi calculada a partir dos autovalores da Hessiana assim obtida, sem distinguir estruturas mais claras ou mais escuras que a vizinhança, já que a carta tem defeitos dos dois tipos.

As escalas da medida de Frangi e o núcleo do *emboss* foram definidos em pixels da imagem recortada, e não em proporção da carta. Como a resolução das fotografias varia, a mesma escala corresponde a estruturas de tamanhos diferentes na carta. A variação é limitada, porque 317 das 412 imagens foram recebidas na mesma resolução, de 1280×1771 pixels (Seção 3.1.2).

A variante foi escolhida uma única vez, antes do estudo fatorial, na rodada da Dobra 1. A Configuração 3 foi treinada com cada uma das quatro variantes, com os demais hiperparâmetros iguais aos das outras rodadas. Foi adotada nas Configurações 3 e 4 a variante de maior F1 agregado na validação interna dessa rodada, calculado com a anotação completa pela própria biblioteca de treinamento. A biblioteca escolhe o limiar no próprio conjunto em que mede o F1, aqui a validação interna, e associa predições e anotações percorrendo os pares em ordem decrescente de IoU, e não as predições em ordem decrescente de confiança. No procedimento da Seção 3.1.3, o limiar escolhido na validação interna foi aplicado à dobra de avaliação, com a associação descrita naquela seção.

A composição de três canais obteve F1 de 0,208; o *emboss* seguido do CLAHE, 0,192; a medida de Frangi, 0,161; e o CLAHE seguido do *emboss* em oito direções, 0,151. A vantagem da variante adotada sobre a segunda foi de 8% do valor desta e, no mAP@0,5 da mesma validação interna, também calculado pela biblioteca, de 2%. Como cada variante foi treinada uma única vez, em uma única dobra, essa diferença não foi testada e não permite afirmar que a composição de três canais seja superior às demais: a escolha foi uma seleção de hiperparâmetro, e não um resultado do trabalho.

A escolha também não ficou isolada das rodadas seguintes. As 34 cartas da validação interna da Dobra 1 pertencem às outras quatro dobras e foram, portanto, avaliadas nas rodadas correspondentes. Como a variante adotada foi a de maior F1 justamente nessas cartas, a escolha pode favorecer ligeiramente as Configurações 3 e 4 nas comparações com as Configurações 1 e 2 (Seção 2.2.13).

A comparação entre as duas representações de entrada não isola apenas o realce de micro-relevo, por dois motivos. Primeiro, o aumento de dados não foi idêntico nas duas: as variações no espaço HSV só foram aplicadas às imagens RGB, de modo que a comparação entre as Configurações 2 e 4 difere também na presença dessas variações, e o efeito do aumento de dados medido com imagens RGB inclui transformações que não foram aplicadas às imagens de realce. Segundo, as quatro variantes partem apenas da luminosidade (L^*) e descartam os dois canais de cor do espaço CIELAB. Assim, as comparações entre as Configurações 3 e 1 e entre as Configurações 4 e 2 opõem também imagens com cor a imagens sem cor. Uma representação de controle, com a luminosidade sem realce repetida nos três canais, não foi treinada; por isso, uma diferença entre as imagens RGB e as de realce pode decorrer tanto do realce quanto da retirada da cor.

A Figura 5 mostra uma carta do conjunto de dados em RGB e na composição de três canais adotada.

Figura 5 – Carta do conjunto de dados em RGB e na variante de realce de micro-relevo adotada nas Configurações 3 e 4



(a) Imagem RGB (b) Composição de três canais

Na imagem (b), exibida como imagem colorida, os canais azul, verde e vermelho contêm, respectivamente, a luminosidade, a luminosidade com CLAHE e a medida de Frangi; as cores não têm significado para a rede. Fonte: Imagem RGB fornecida pela empresa de graduação; imagem de realce elaborada pelo autor a partir dela (2026).

3.3.2 Estudo fatorial, ablação e análises complementares

O estudo fatorial, a ablação e as análises complementares seguiram as etapas da Seção 3.1.1 e o plano da Tabela 4. As 20 rodadas do estudo fatorial, das quatro configurações nas cinco dobras, usaram o YOLOv8s a 1280 pixels e as mesmas dobras. A ablação e as análises complementares partiram da configuração de melhor desempenho e alteraram um único elemento por vez, mantendo os demais iguais aos da rodada do estudo fatorial na mesma dobra. Os elementos alterados foram a cabeça P2, nas cinco dobras, que trouxe junto a perda dos pesos pré-treinados em parte das camadas (Seção 3.2.1); a resolução de entrada de 640 pixels e o YOLOv8m, cada um em uma rodada na Dobra 5; e a fração das cartas do treino efetivo, na curva de aprendizado. Ao todo, contadas as quatro rodadas da escolha da variante de realce, foram 37 rodadas de treinamento.

Na curva de aprendizado, a configuração de melhor desempenho foi treinada com 25%, 50% e 75% das cartas do treino efetivo, nas Dobras 3 e 5, com a validação interna e a dobra de avaliação inalteradas; o ponto de 100% é a rodada do estudo fatorial na mesma dobra. As cartas foram sorteadas uma única vez, com semente fixa, de modo que cada fração contivesse a anterior e que as cartas de mesma ilustração ficassem juntas.

As dobras da ablação da resolução e das análises complementares foram escolhidas

depois do estudo fatorial. A Dobra 5 foi escolhida por ter, na avaliação, o número de anotações mais próximo do típico entre as cinco dobras (783, a mediana) e por não conter as cartas de desgaste mais extenso, que ficaram nas Dobras 1 e 4; nela, a configuração de melhor desempenho teve o maior mAP@0,5 entre as cinco dobras. Se parte desse valor se deve à variação da própria rodada, e não apenas a uma dobra mais fácil, a rodada de referência está acima do seu desempenho típico, e as diferenças medidas contra ela tendem a favorecê-la: a vantagem de 1280 sobre 640 pixels pode estar exagerada, e a comparação com o YOLOv8m pode estar desfavorável a ele. A resolução de 640 pixels e o YOLOv8m foram avaliados na mesma dobra, o que permitiu compará-los com a mesma rodada de referência da curva. A curva de aprendizado foi repetida na Dobra 3, que, como a 5, não contém as cartas de desgaste mais extenso, para verificar se sua forma se mantinha em outra dobra.

3.4 Resultados e análises

4 Conclusão

4.1 Retomada do problema e dos objetivos

4.2 Contribuições para a Computação

4.3 Limitações e trabalhos futuros

Referências

AHMAD, M. S. Z. et al. Impact of image enhancement using contrast-limited adaptive histogram equalization (CLAHE), anisotropic diffusion, and histogram equalization on spine x-ray segmentation with U-Net, Mask R-CNN, and transfer learning. *Algorithms*, v. 18, n. 12, p. 796, 2025. 35

ARLOT, S.; CELISSE, A. A survey of cross-validation procedures for model selection. *Statistics Surveys*, v. 4, p. 40–79, 2010. 21, 49

Beckett Grading Services. *BGS Grading Standards*. 2026. Acesso em: 15 mar. 2026. Disponível em: <http://web.archive.org/web/20260305114255/https://beckett.com/grading-standards>. 11, 21

BOUTHILLIER, X. et al. Accounting for variance in machine learning benchmarks. In: *Proceedings of Machine Learning and Systems 3 (MLSys 2021)*. San Jose, CA, USA: [s.n.], 2021. Disponível em: <https://proceedings.mlsys.org/paper_files/paper/2021/file/0184b0cd3cfb185989f858a1d9f5c1eb-Paper.pdf>. 39

Business Research Insights. *Collectible Card Game Market Size, Share, Growth, Trends, Global Industry Analysis*. 2026. Acesso em: 15 mar. 2026. Disponível em: <https://www.businessresearchinsights.com/market-reports/collectible-card-game-market-101837>. 11, 21

CAWLEY, G. C.; TALBOT, N. L. C. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, v. 11, p. 2079–2107, 2010. Disponível em: <https://www.jmlr.org/papers/volume11/cawley10a/cawley10a.pdf>. 21, 38

CHEN, F. et al. NHD-YOLO: Improved YOLOv8 using optimized neck and head for product surface defect detection with data augmentation. *IET Image Processing*, v. 18, n. 7, p. 1915–1926, 2024. 37, 42, 43

CHEN, Y. et al. Surface defect detection methods for industrial products: A review. *Applied Sciences*, v. 11, n. 16, p. 7657, 2021. 17, 18, 25, 31, 32, 33

CHENG, G. et al. Towards large-scale small object detection: Survey and benchmarks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 45, n. 11, p. 13467–13488, 2023. 35

DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, v. 7, p. 1–30, 2006. Disponível em: <https://www.jmlr.org/papers/v7/demsar06a.html>. 21, 39, 40

DICICCIO, T. J.; EFRON, B. Bootstrap confidence intervals. *Statistical Science*, v. 11, n. 3, p. 189–228, 1996. 21, 40

DOBRZYCKI, A. D.; BERNARDOS, A. M.; CASAR, J. R. An analysis of layer-freezing strategies for enhanced transfer learning in YOLO architectures. *Mathematics*, v. 13, n. 15, p. 2539, 2025. 29, 30, 37

FRANGI, A. F. et al. Multiscale vessel enhancement filtering. In: WELLS, W. M.; COLCHESTER, A.; DELP, S. (Ed.). *Medical Image Computing and Computer-Assisted Intervention, MICCAI'98*. Berlin, Heidelberg: Springer, 1998, (Lecture Notes in Computer Science, v. 1496). p. 130–137. 21, 34

GRUBER, D. P.; HASELMANN, M. Inspection of transparent objects with varying light scattering using a Frangi filter. *Journal of Imaging*, v. 7, n. 2, p. 27, 2021. 33

HE, K.; GIRSHICK, R.; DOLLÁR, P. Rethinking ImageNet pre-training. In: *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*. Seoul, Korea (South): IEEE, 2019. p. 4917–4926. 21, 30

HOIEM, D. et al. Learning curves for analysis of deep networks. In: MEILA, M.; ZHANG, T. (Ed.). *Proceedings of the 38th International Conference on Machine Learning (ICML)*. PMLR, 2021. (Proceedings of Machine Learning Research, v. 139), p. 4287–4296. Disponível em: <https://proceedings.mlr.press/v139/hoiem21a.html>. 32, 33

HUSSAIN, M. YOLO-v1 to YOLO-v8, the rise of YOLO and its complementary nature toward digital manufacturing and industrial defect detection. *Machines*, v. 11, n. 7, p. 677, 2023. 13, 22, 25, 26, 27, 29

JIANG, J. et al. High-speed lightweight ship detection algorithm based on YOLO-V4 for three-channels RGB SAR image. *Remote Sensing*, v. 13, n. 10, p. 1909, 2021. 34, 35

JIANG, S. et al. Automatic detection of surface defects on underwater pile-pier of bridges based on image fusion and deep learning. *Structural Control and Health Monitoring*, v. 2023, p. 8429099, 2023. 13, 33, 34

JOCHER, G.; CHAURASIA, A.; QIU, J. *Ultralytics YOLO*. 2023. <https://github.com/ultralytics/ultralytics>. Versão 8. Documentação e código-fonte. Acesso em: 2 set. 2026. 21, 28, 29, 32, 35, 51, 56, 57, 58, 59

KIM, M.-G.; OKWUOSA, C. N.; HUR, J.-W. Scan path optimization and YOLO-based detection for defect inspection of curved and glossy surfaces. *Sensors*, v. 26, n. 10, p. 3026, 2026. 13

KOHAVI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: *Proceedings of the Fourteenth International Joint Conference on Artificial Intelligence (IJCAI-95)*. Montreal, Quebec, Canada: Morgan Kaufmann, 1995. v. 2, p. 1137–1143. Disponível em: <https://www.ijcai.org/Proceedings/95-2/Papers/016.pdf>. 21, 38, 49, 50

LI, M. et al. AlignDet: Aligning pre-training and fine-tuning in object detection. In: *2023 IEEE/CVF International Conference on Computer Vision (ICCV)*. Paris, France: IEEE, 2023. p. 6843–6853. 30

LIN, T.-Y. et al. Microsoft COCO: Common objects in context. In: FLEET, D. et al. (Ed.). *Computer Vision – ECCV 2014*. Cham: Springer, 2014. (Lecture Notes in Computer Science, v. 8693), p. 740–755. 21, 29

LIU, C.-M.; JUANG, J.-C. Systematic evaluation of YOLOv8 variants for UAV-based object detection. *Applied Sciences*, v. 16, n. 7, p. 3559, 2026. 35, 36, 42, 43

LIU, W.; QUIJANO, K.; CRAWFORD, M. M. YOLOv5-Tassel: Detecting tassels in RGB UAV imagery with improved YOLOv5 based on transfer learning. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, v. 15, p. 8085–8094, 2022. 37

MAHMOOD, R. et al. How much more data do I need? Estimating requirements for downstream tasks. In: *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. [S.l.]: IEEE, 2022. p. 275–284. 32

NAHAR, L. et al. Automated corner grading of trading cards: Defect identification and confidence calibration through deep learning. *Computers in Industry*, v. 164, p. 104187, 2025. 11, 12, 13, 14, 17, 18, 23, 25, 31, 41, 43

NAHAR, L. et al. An integrated deep learning framework for trading card grading: Design, deployment, and evaluation. In: *2025 IEEE International Conference on Big Data (BigData)*. [S.l.]: IEEE, 2025. p. 2609–2615. 11, 12, 14, 17, 41

PANG, J. et al. Nonparametric bootstrap methods for interval estimation of the area under the ROC curve with correlated diagnostic test data: application to whole-virus ELISA testing in swine. *Frontiers in Veterinary Science*, v. 10, p. 1274786, 2023. 40

PRECHELT, L. Early stopping - but when? In: ORR, G. B.; MÜLLER, K.-R. (Ed.). *Neural Networks: Tricks of the Trade*. Berlin, Heidelberg: Springer, 1998, (Lecture Notes in Computer Science, v. 1524). p. 55–69. 21, 38, 57

RAMOS, L. T.; SAPPA, A. D. A decade of you only look once (YOLO) for object detection: A review. *IEEE Access*, v. 13, p. 192747–192794, 2025. 13, 25, 26, 27, 28, 29, 31

REINKE, A. et al. Understanding metric-related pitfalls in image analysis validation. *Nature Methods*, v. 21, n. 2, p. 182–194, 2024. 40

SAWADA, M.; FUJI, Y.; AIKAWA, N. Improving classification accuracy in paint surface inspection using image processing and deep learning. In: *2024 IEEE 67th International Midwest Symposium on Circuits and Systems (MWSCAS)*. Springfield, MA, USA: IEEE, 2024. p. 707–711. 13, 33

SHEIKHOLESLAMI, S. et al. AutoAblation: Automated parallel ablation studies for deep learning. In: *Proceedings of the 1st Workshop on Machine Learning and Systems (EuroMLSys '21)*. New York, NY, USA: ACM, 2021. p. 55–61. 37

SITU, Z. et al. A transfer learning-based YOLO network for sewer defect detection in comparison to classic object detection methods. *Developments in the Built Environment*, v. 15, p. 100191, 2023. 12, 18, 26, 29, 30, 31

VIERING, T.; LOOG, M. The shape of learning curves: A review. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 45, n. 6, p. 7799–7819, 2023. 31, 32

WANG, H.; LI, Z.; WANG, H. Few-shot steel surface defect detection. *IEEE Transactions on Instrumentation and Measurement*, v. 71, p. 1–12, 2022. Art. no. 5003912. 17, 31

WIESENFARTH, M. et al. Methods and open-source toolkit for analyzing and visualizing challenge results. *Scientific Reports*, v. 11, p. 2369, 2021. 39

XIA, K. et al. Global contextual attention augmented YOLO with ConvMixer prediction heads for PCB surface defect detection. *Scientific Reports*, v. 13, n. 1, p. 9805, 2023. 25, 35, 36

XU, C. et al. Detecting tiny objects in aerial images: A normalized Wasserstein distance and a new benchmark. *ISPRS Journal of Photogrammetry and Remote Sensing*, v. 190, p. 79–93, 2022. 25, 36, 47

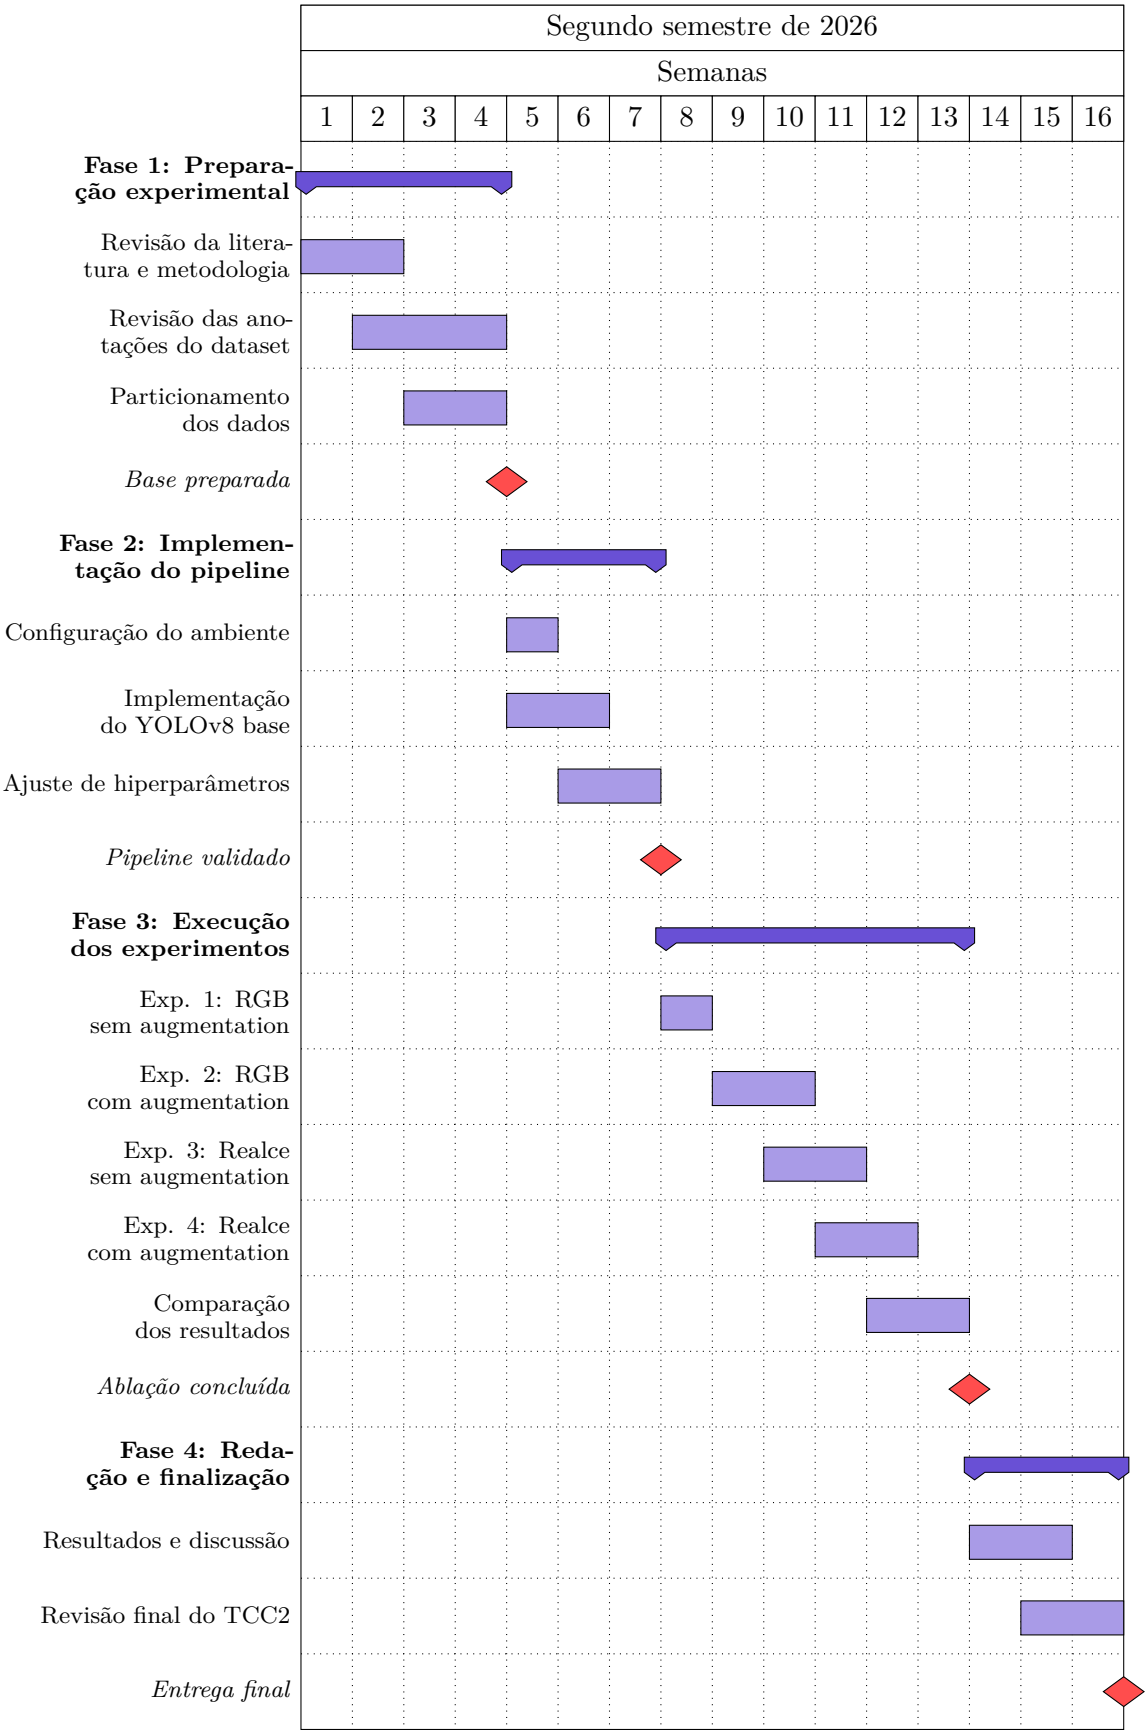
ZHENG, X. et al. Recent advances in surface defect inspection of industrial products using deep learning techniques. *The International Journal of Advanced Manufacturing Technology*, v. 113, n. 1-2, p. 35–58, 2021. 11, 13, 22, 23, 25, 33

Apêndices

APÊNDICE A – Cronograma previsto no TCC1

O cronograma de trabalho organiza as principais atividades previstas para o desenvolvimento do TCC2, contemplando desde a preparação final do conjunto de dados até a execução dos experimentos, análise dos resultados e redação da versão final do trabalho. As etapas foram distribuídas de forma sequencial, considerando a dependência entre a organização dos dados, o treinamento dos modelos, a comparação das configurações experimentais e a consolidação dos resultados obtidos.

Figura 6 – Cronograma de atividades do TCC2 para o segundo semestre de 2026 – Diagrama de Gantt



Fonte: Elaborado pelo autor (2026)